Mapeo 3D autónomo con un robot de servicio AlfredZ

Informe de Proyecto de Grado presentado por

Enzo Borges, Christian Deleon, Román Alvarez

en cumplimiento parcial de los requerimientos para la graduación de la carrera de Ingeniería en Computación de Facultad de Ingeniería de la Universidad de la República

Supervisores

Federico Andrade
Facundo Benavides

Montevideo, 18 de abril de 2026

Mapeo 3D autónomo con un robot de servicio AlfredZ
por Enzo Borges, Christian Deleon, Román Alvarez tiene licencia
CC Atribución 4.0.

Agradecimientos

Agradecer, siempre es bueno agradecer.

Resumen

El resumen (200-500 palabras) debe dar una idea completa de todo el proyecto, mencionando claramente los formalismos, técnicas, herramientas y lenguas utilizados. No debe limitarse a describir el problema abordado, sino que debe describir la solución del problema, con una evaluación de la misma. No debe incluir referencias bibliográficas ni referencias a otras partes del informe. Tampoco debe utilizar acrónimos sin explicar su significado.

Palabras clave: Template, Proyectos de Grado, Computación

Índice general

1. Introducción **1**

2. Estado del arte **3**
2.1. Active SLAM: estado del arte y desafíos abiertos 3
2.1.1. Limitaciones y conexión con alfredZ 4
2.2. Exploración basada en fronteras 4
2.2.1. Limitaciones y conexión con alfredZ 5
2.3. SLAM con detección y seguimiento de objetos en movimiento . . 5
2.3.1. Limitaciones y conexión con alfredZ 6

3. Solución propuesta **7**
3.1. Visión general del sistema 7
3.2. Filtrado semántico de objetos dinámicos 8
3.3. Detección y agrupamiento de fronteras 9
3.3.1. Representación del mapa de ocupación 9
3.3.2. Definición e identificación de fronteras 9
3.3.3. Agrupamiento en clusters 9
3.3.4. Pre-filtrado por ganancia de información 10
3.4. Función de utilidad para selección de Next Best View 11
3.5. Estrategias de exploración 12
3.5.1. Greedy (baseline) 12
3.5.2. Estrategia E1: Frontera 12
3.5.3. Estrategia E2: Ruta planificada 12
3.5.4. Estrategia E3: Predictiva 12
3.6. Métricas de evaluación semántica 13
3.6.1. Celdas fantasma 13
3.6.2. Entropía del mapa 13
3.6.3. Métricas de detección de personas 15

4. Experimentación **17**
4.1. Configuración experimental 17
4.1.1. Entornos de simulación 17
4.1.2. Configuración del sistema 18
4.1.3. Métricas de evaluación 18

4.1.4. Puntuación compuesta 19
4.2. Estrategia de comparación: Greedy 19
4.3. Etapa de calibración 20
4.3.1. Diseño de los experimentos de calibración 20
4.3.2. Resultados por estrategia 21
4.3.3. Análisis global de hiperparámetros 23
4.3.4. Selección de parámetros para la validación 23
4.4. Frontera: utilidad dinámica por centro de frontera 25
4.4.1. Diseño de los experimentos 26
4.4.2. Resultados por métrica 27
4.4.3. Puntuación compuesta y análisis global 30
4.4.4. Análisis por entorno 31
4.4.5. Discusión 31
4.5. Ruta Planificada: utilidad dinámica por trayecto de acceso 32
4.5.1. Diseño de los experimentos 32
4.5.2. Resultados por métrica 33
4.5.3. Puntuación compuesta y análisis global 37
4.5.4. Análisis por entorno 38
4.5.5. Discusión 38
4.6. Predictiva: estimación de interferencia con predicción de trayectorias 39
4.6.1. Diseño de los experimentos 39
4.6.2. Resultados por métrica 39
4.6.3. Puntuación compuesta y análisis global 43
4.6.4. Análisis por entorno 44
4.6.5. Análisis del costo computacional 45
4.6.6. Discusión 46
4.7. Análisis comparativo de estrategias 47
4.7.1. Resultados comparativos por métrica 47
4.7.2. Puntuación compuesta 49
4.7.3. Trade-offs y recomendaciones de uso 51
4.7.4. Conclusión del capítulo 52

5. Conclusiones y Trabajo Futuro **55**

Referencias **57**

Anexo 1 **59**
.1. Sección del Anexo 59

Capítulo 1

Introducción

Aquí se motiva el trabajo, se plantea y define el problema, se deja claro cuáles son los objetivos (general del proyecto, si correspondiese o si está inmerso en un proyecto de mayor alcance, y los específicos), se plantean los resultados esperados, se establecen resumidamente las conclusiones y se describe la organización general del documento.

Este y los siguientes capítulos pueden incluir referencias; algunos ejemplos pueden ser (Cohen, 1963), (Susskind y Hrabovsky, 2014), (Holleis, Wagner, y Koolwaaij, 2010), (R Core Team, 2018) y (NASA, 2015). Se sugiere citar usando el formato APA.

Capítulo 2

Estado del arte

En este capítulo se presentan los trabajos relacionados más relevantes para el proyecto alfredZ. Los trabajos seleccionados abordan dos ejes temáticos complementarios: por un lado, el estado del arte en mapeo y localización activa (Active SLAM) considerando entornos estáticos; por otro, los enfoques propuestos para navegación y mapeo en presencia de agentes dinámicos. Para cada trabajo se describen la solución propuesta, la metodología de evaluación y los resultados obtenidos, con especial atención a las limitaciones identificadas. Estas limitaciones constituyen la motivación directa de las estrategias implementadas en alfredZ.

2.1. Active SLAM: estado del arte y desafíos abiertos

En 2023, Placed et al. (Placed y cols., 2023) publicaron un relevamiento exhaustivo del estado del arte en Active SLAM en IEEE Transactions on Robotics. Los autores definen el Active SLAM como el problema de planificar y controlar el movimiento de un robot con el fin de construir el modelo más preciso y completo posible del entorno que lo rodea. A diferencia del SLAM pasivo —que se limita a integrar observaciones conforme el robot se desplaza— el Active SLAM incorpora la toma de decisiones sobre las acciones del robot: qué explorar, qué ruta seguir y cuándo detener la exploración.

El trabajo presenta una formulación unificada del problema, organizada en tres etapas modulares: (i) identificación de posibles acciones o metas de navegación, (ii) estimación de la utilidad esperada de cada acción, y (iii) ejecución de la acción más conveniente. Esta arquitectura modular constituye la base de la mayoría de los enfoques actuales, incluyendo métodos basados en entropía de información, planificación en espacio de creencias (*belief-space planning*) y aprendizaje por refuerzo profundo.

2.1.1. Limitaciones y conexión con alfredZ

El survey identifica como uno de los desafíos abiertos más relevantes el manejo de **entornos dinámicos**. La gran mayoría de los sistemas de Active SLAM descritos en la literatura asumen que el entorno es estático: los elementos que no son el robot permanecen en su lugar durante toda la exploración. Esta suposición simplifica considerablemente el problema, pero resulta inadecuada en escenarios reales donde personas u otros agentes se desplazan durante la tarea de mapeo. Los autores señalan que la investigación en Active SLAM en entornos dinámicos se ha limitado en su mayoría a la etapa de re-planificación reactiva, sin incorporar los agentes dinámicos de manera integral en la función de utilidad ni en la representación del mapa.

Otra limitación señalada por los autores es la **falta de benchmarks estandarizados** que permitan comparar objetivamente los distintos enfoques. La mayoría de los trabajos validan sus propuestas en escenarios específicos que no son reproducibles por otros grupos. El trabajo hace un llamado explícito a desarrollar métricas más allá de las comúnmente utilizadas (tiempo de exploración y cobertura del mapa), señalando que la calidad de las estimaciones debería ser el objetivo central a medir.

Estas limitaciones son directamente relevantes para el proyecto alfredZ. La suposición de entorno estático, omnipresente en los sistemas de Active SLAM, produce mapas contaminados en escenarios con peatones: celdas que momentáneamente estuvieron ocupadas por personas en movimiento quedan marcadas como obstáculos permanentes. El proyecto alfredZ aborda esta problemática incorporando detección semántica de objetos dinámicos mediante YOLOv8, lo que permite identificar y filtrar estas falsas ocupaciones —denominadas *ghost cells* en este trabajo— antes de que corrompan el mapa estático. Asimismo, alfredZ propone métricas específicas para entornos dinámicos, como la cantidad de *ghost cells* y la entropía del mapa, respondiendo a la necesidad de evaluación objetiva señalada por Placed et al.

2.2. Exploración basada en fronteras

Topiwala e Inani (Topiwala y Inani, 2018), del Maryland Robotics Center (Universidad de Maryland), describieron e implementaron el algoritmo Wavefront Frontier Detector (WFD) para la exploración autónoma de entornos desconocidos. El objetivo del trabajo es demostrar que un robot puede explorar de manera autónoma tanto espacios abiertos de gran extensión como espacios pequeños y recargados de obstáculos, generando un mapa de mayor precisión que el producido mediante teleoperación manual.

El algoritmo WFD se fundamenta en el concepto de *frontera*: las regiones del mapa de ocupación que se encuentran en el límite entre el espacio ya explorado y el espacio aún desconocido. El robot se desplaza iterativamente hacia la frontera más cercana a su posición actual, realiza un barrido de 360° al llegar para actualizar el mapa y repite el proceso hasta que no quedan más fronteras por

explorar. La principal ventaja del WFD sobre el método original de Yamauchi es que solo escanea las regiones conocidas de la grilla de ocupación en cada iteración, reduciendo significativamente la complejidad temporal del algoritmo.

El sistema fue implementado utilizando ROS (*Robot Operating System*), el paquete `gmapping` para SLAM y `move_base` para planificación de rutas. Las pruebas se realizaron en dos modalidades: en simulación, replicando el laboratorio de robótica de la Universidad de Maryland en Gazebo, y en hardware real, sobre una plataforma TurtleBot2 Kobuki equipada con un sensor Astra. Los resultados mostraron que los mapas generados autónomamente son más precisos que los producidos mediante teleoperación, con trayectorias más suaves y menor tiempo y distancia total recorrida para cubrir el área de exploración.

2.2.1. Limitaciones y conexión con alfredZ

La solución propuesta presenta limitaciones importantes cuando se aplica a entornos con personas en movimiento. El algoritmo WFD asume implícitamente que el entorno es estático: las fronteras se detectan y priorizan en función de la geometría del mapa de ocupación, sin ningún mecanismo para distinguir si una celda fue ocupada por un obstáculo permanente o por un agente dinámico. En un entorno con peatones, personas que transitan brevemente por una zona son incorporadas al mapa como obstáculos estáticos, corrompiendo la representación del espacio libre. Asimismo, la selección de fronteras basada únicamente en distancia euclídea no considera la presencia de agentes dinámicos que podrían bloquear el camino hacia una frontera, ocasionando re-planificaciones frecuentes y movimientos ineficientes.

La estrategia de Exploración por Frontera implementada en alfredZ (Estrategia E1 en este trabajo) toma como punto de partida el enfoque WFD y lo extiende con capas de procesamiento semántico. Las celdas que corresponden a detecciones de personas son identificadas como *ghost cells* y excluidas del proceso de selección de fronteras, evitando que el mapa estático quede contaminado. Esto permite que la exploración por fronteras sea robusta ante la presencia de múltiples peatones, un escenario no contemplado en el trabajo original.

2.3. SLAM con detección y seguimiento de objetos en movimiento

Wang et al. (Wang, Thorpe, Hebert, Thrun, y Durrant-Whyte, 2007) propusieron un marco teórico para abordar de manera conjunta el problema del SLAM y el seguimiento de objetos en movimiento, denominando esta formulación SLAMMOT (*Simultaneous Localization, Mapping and Moving Object Tracking*). El trabajo, desarrollado por investigadores del Instituto de Robótica de Carnegie Mellon University, la Universidad de Stanford y la Universidad de Sydney, tiene como motivación principal la operación de vehículos autónomos en entornos urbanos concurridos, donde tanto la precisión del mapa estático como la detección de obstáculos dinámicos son críticas para la seguridad.

Los autores presentan dos formulaciones del problema. La primera, SLAM con objetos generalizados, calcula una posterior conjunta sobre todos los objetos del entorno —estáticos y en movimiento— junto con la pose del robot. Si bien esta formulación es matemáticamente completa, los propios autores reconocen que es computacionalmente intractable para escenarios reales. La segunda formulación, SLAM con DATMO (*Detection and Tracking of Moving Objects*), descompone el problema en dos estimadores separados: uno para los objetos estáticos (el mapa) y otro para los objetos en movimiento. Al mantener posteriors independientes, la dimensionalidad del problema se reduce considerablemente, haciéndolo viable en tiempo real.

El sistema fue validado utilizando el vehículo Navlab11 equipado con escáneres láser SICK, recorriendo intersecciones concurridas de zonas urbanas. Los resultados demostraron la viabilidad del enfoque para operar a altas velocidades en entornos con múltiples vehículos en movimiento, con seguimiento robusto incluso ante situaciones de oclusión prolongada.

2.3.1. Limitaciones y conexión con alfredZ

A pesar de los avances presentados, el trabajo exhibe limitaciones relevantes para el problema abordado por alfredZ. En primer lugar, el **costo computacional de DATMO**, aunque menor que el enfoque generalizado, sigue siendo elevado: mantener posteriors separadas para cada objeto en movimiento requiere recursos significativos, especialmente cuando el número de agentes dinámicos es alto. En segundo lugar, el sistema fue diseñado y validado para **entornos exteriores con vehículos**; su aplicabilidad a entornos interiores con peatones, donde los patrones de movimiento son más impredecibles y el espacio es más reducido, no fue explorada. En tercer lugar, el enfoque **requiere modelos de movimiento previos** para los objetos rastreados, lo que limita su generalización a nuevos tipos de agentes dinámicos sin reentrenamiento.

En alfredZ se adopta un enfoque diferente para el problema del mapeo en entornos con personas en movimiento. En lugar de mantener un estimador probabilístico explícito para cada agente dinámico, se recurre a detección semántica mediante redes neuronales convolucionales (YOLOv8) para identificar y filtrar en tiempo real las detecciones correspondientes a personas. Este enfoque reduce sustancialmente la carga computacional respecto de DATMO, y no requiere modelos de movimiento previos para los agentes. El impacto de los agentes dinámicos en la calidad del mapa se cuantifica a través de métricas específicas como las *ghost cells* y la entropía del mapa, permitiendo evaluar de manera objetiva el desempeño de las distintas estrategias de exploración bajo diferentes niveles de concurrencia de peatones.

Capítulo 3

Solución propuesta

En este capítulo se describe la solución desarrollada en el proyecto alfredZ. El objetivo del sistema es explorar autónomamente entornos interiores dinámicos —con personas en movimiento— construyendo un mapa de ocupación de alta calidad. Para lograrlo se combinan técnicas de SLAM activo, detección semántica de objetos dinámicos y planificación de rutas. En las secciones siguientes se presentan los componentes del sistema, la lógica de selección de fronteras de exploración y las estrategias implementadas para manejar la presencia de personas.

3.1. Visión general del sistema

El sistema alfredZ opera en un entorno de simulación construido con Gazebo, donde un robot de tracción diferencial equipado con una cámara estéreo ZED debe explorar un espacio desconocido que puede contener actores dinámicos (personas) en movimiento. La plataforma de software utilizada es ROS 2 Humble, sobre la cual se integran los siguientes componentes principales:

- **RTAB-Map** (*Real-Time Appearance-Based Mapping*): sistema de SLAM que construye el mapa de ocupación y estima la posición del robot a partir del flujo RGB-D de la cámara ZED.

- **Nav2**: pila de navegación de ROS 2 responsable de planificar rutas libres de obstáculos y ejecutar el movimiento del robot hacia las metas asignadas.

- **YOLOv8**: modelo de detección de objetos utilizado para identificar en tiempo real las personas presentes en el campo visual del robot.

- **DynamicMasker**: nodo propio que intercepta el flujo RGB-D antes de que llegue a RTAB-Map y enmascara las regiones correspondientes a personas detectadas, evitando que sean incorporadas al mapa estático.

- **SemanticNBVPlanner** (*Next Best View Planner*): nodo central de toma de decisiones que detecta fronteras, calcula su utilidad y envía la meta de navegación a Nav2.

- **SemanticMetricsNode**: nodo que calcula y publica en tiempo real métricas de calidad del mapa y de detección de personas.

En la Figura 3.1 se presenta un diagrama de los componentes del sistema y el flujo de datos entre ellos.

[Imagen: diagrama de componentes y flujo de datos del sistema; mostrar el robot con la cámara ZED, la salida RGB-D llegando al DynamicMasker (que también recibe detecciones de YOLOv8), la salida enmascarada llegando a RTAB-Map, el mapa publicado en /map llegando al SemanticNBVPlanner (que también recibe la pose del robot de RTAB-Map y las detecciones de personas), el goal enviado a Nav2 y el cmd_vel resultante al robot; SemanticMetricsNode se suscribe a /map y a /yolo/detections.]

Figura 3.1: Diagrama de componentes y flujo de datos del sistema alfredZ.

3.2. Filtrado semántico de objetos dinámicos

El principal desafío del mapeo en entornos dinámicos es que los sistemas de SLAM convencionales asumen que el entorno es estático. Cuando una persona se desplaza por el campo visual del robot, las lecturas de profundidad correspondientes a su cuerpo se incorporan al mapa de ocupación como obstáculos permanentes. Con el tiempo, esto produce *ghost cells*: celdas que el mapa marca como ocupadas pero que en realidad corresponden a espacio libre donde la persona ya no se encuentra.

Para mitigar este problema se desarrolló el nodo **DynamicMasker**. Este nodo se suscribe simultáneamente al flujo de imágenes de la cámara ZED (imagen de color e imagen de profundidad) y a las detecciones publicadas por YOLOv8. Cada vez que YOLOv8 detecta una persona, su bounding box se utiliza para generar una máscara binaria sobre la imagen de profundidad: los píxeles comprendidos dentro de la caja detectada se anulan (se les asigna profundidad cero), de modo que RTAB-Map no recibe información de profundidad en esas regiones y, por lo tanto, no las incorpora al mapa. La imagen de color se enmascara de manera análoga.

Adicionalmente, el nodo mantiene un mapa de calor dinámico acumulado (*dynamic heatmap*) que registra las zonas del campo visual donde se detectaron personas con mayor frecuencia, aplicando un factor de decaimiento exponencial ($\alpha = 0{,}95$) para dar mayor peso a las detecciones recientes. Este mapa de calor se publica como un `OccupancyGrid` y puede ser utilizado por el planificador para tener noción de las zonas de mayor actividad dinámica.

3.3. Detección y agrupamiento de fronteras

La exploración autónoma se basa en el concepto de **frontera**: el borde entre el espacio ya conocido y el espacio aún desconocido del mapa. Moviéndose hacia las fronteras, el robot amplía iterativamente la región mapeada hasta que no quedan zonas por explorar.

3.3.1. Representación del mapa de ocupación

El mapa se recibe como un mensaje `nav_msgs/OccupancyGrid`, que consiste en una grilla regular de celdas con tres estados posibles:

- -1: celda **desconocida** (no observada).
- 0: celda **libre** (espacio navegable confirmado).
- 1–100: celda **ocupada** (presencia de obstáculo, proporcional a la probabilidad de ocupación).

Cada celda se identifica por su índice $(fila, columna)$ en la grilla. La posición en metros se obtiene a partir de la resolución y el origen del mapa.

3.3.2. Definición e identificación de fronteras

Una celda se considera **frontera** si cumple simultáneamente dos condiciones: es libre ($valor = 0$) y al menos una de las ocho celdas que forman su vecindad es desconocida ($valor = -1$). Esta vecindad de 8 celdas, llamada vecindad 8 o conectividad 8, incluye las celdas adyacentes en las cuatro direcciones cardinales y las cuatro diagonales.

En la Figura 3.2 se ilustra esta definición con un ejemplo.

La identificación se implementa mediante operaciones matriciales con la biblioteca SciPy. Primero se obtiene la máscara de celdas desconocidas y se la dilata con una estructura de conectividad 8; el resultado representa todas las celdas adyacentes a zonas desconocidas. La intersección de esta máscara dilatada con la máscara de celdas libres produce el conjunto de celdas frontera, de forma equivalente a la definición anterior pero de manera vectorizada y eficiente.

3.3.3. Agrupamiento en clusters

Las celdas frontera identificadas no se tratan de forma individual sino que se agrupan en **clusters** mediante un algoritmo de etiquetado de componentes conexas con conectividad 8. Cada cluster representa una zona continua de frontera y se caracteriza por tres elementos:

- **Representante**: la celda del cluster más cercana a su centroide geométrico, utilizada como objetivo de navegación.

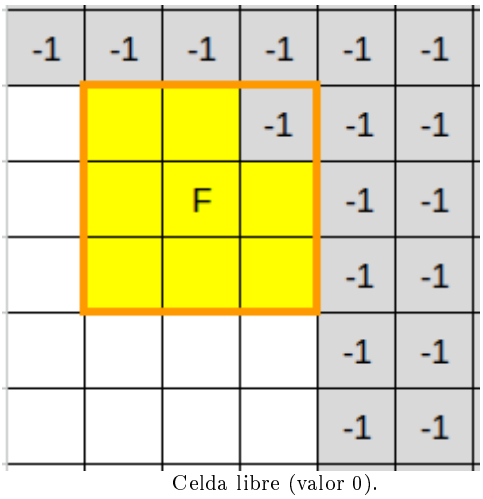

Blanco	Celda libre (valor 0).
Gris con "-1"	Celda desconocida (no observada).
F	Celda *frontera*: libre con al menos un vecino desconocido en su vecindad 8.
Borde naranja (3×3)	Vecindad 8 (conectividad de Moore) centrada en la celda **F**.
Sombreado amarillo	Celdas incluidas en la vecindad usada en el ejemplo.

Figura 3.2: Definición de frontera: celda libre con al menos una celda desconocida en su vecindad 8 (recuadro 3×3).

- **Celdas**: el conjunto completo de celdas $(fila, columna)$ que conforman el cluster.

- **Ganancia de información estática** ($IG_{estática}$): el número de celdas desconocidas en la vecindad del cluster, que estima cuánta información nueva se obtendría al visitarlo.

Los clusters con menos de un número mínimo configurable de celdas (`min_cluster_cells`) son descartados para evitar fronteras espurias.

3.3.4. Pre-filtrado por ganancia de información

Dado que calcular el costo de trayecto hasta cada frontera mediante Nav2 es una operación costosa, se aplica un **pre-filtrado** antes de evaluar la función de utilidad completa: se ordenan los clusters por $IG_{estática}$ de mayor a menor y se retienen solo los `max_frontiers_to_evaluate` más prometedores. Los costos de trayecto se calculan en paralelo solo para estas fronteras preseleccionadas.

3.4. Función de utilidad para selección de Next Best View

Para decidir cuál frontera visitar en cada iteración, se define una función de utilidad $U(v)$ que balancea tres factores: la cantidad de información nueva que se obtendría al visitar la frontera, el costo de llegar a ella y la presencia de personas en su entorno. La frontera seleccionada es aquella que maximiza $U(v)$:

$$U(v) = IG_{estática}(v) - \lambda \cdot Dinámica(v) - \mu \cdot Costo_{trayecto}(v) \tag{3.1}$$

donde:

- $IG_{estática}(v)$: número de celdas desconocidas en la vecindad del cluster v. Cuanto mayor, más información nueva se espera obtener al visitar esa zona.
- $Dinámica(v)$: estimación de la interferencia de personas en el entorno de v. El cálculo concreto depende de la estrategia seleccionada (Sección 3.5).
- $Costo_{trayecto}(v)$: longitud en metros de la ruta planificada por Nav2 desde la posición actual del robot hasta el representante de v. Se calcula en paralelo para todas las fronteras preseleccionadas.
- λ: parámetro de penalización sobre la interferencia dinámica. Un valor $\lambda = 0$ equivale a ignorar completamente la presencia de personas.
- μ: parámetro de penalización sobre el costo de trayecto. Valores más altos favorecen fronteras más cercanas al robot.

En la Figura 3.3 se ilustra cómo varía $IG_{estática}$ según la configuración de celdas desconocidas alrededor de una frontera.

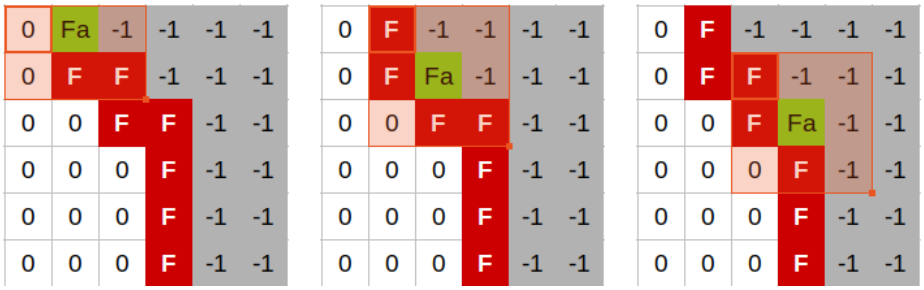

(a) $IG_{estática} = 1$ (b) $IG_{estática} = 3$ (c) $IG_{estática} = 4$

Figura 3.3: Ejemplos de $IG_{estática}$ para distintas configuraciones de celdas desconocidas alrededor de una frontera F_a.

3.5. Estrategias de exploración

Se implementaron cuatro modos de operación del planificador que difieren en la forma en que se calcula el término $Dinámica(v)$ de la función de utilidad. Tres de ellos constituyen las estrategias propias de alfredZ (E1, E2 y E3) y uno actúa como *baseline* de referencia (Greedy).

3.5.1. Greedy (baseline)

En el modo Greedy el planificador selecciona siempre la frontera más cercana al robot según la distancia euclídea, sin considerar el costo de trayecto planificado ni la presencia de personas ($\lambda = 0$, $\mu = 0$). Esta estrategia es el punto de comparación mínimo: explora el mapa de forma simple y rápida pero es completamente ciega a los agentes dinámicos.

3.5.2. Estrategia E1: Frontera

La Estrategia E1 define $Dinámica(v)$ como la cantidad de personas detectadas dentro de un radio r alrededor del representante de la frontera v:

$$Dinámica_{E1}(v) = |\{p \in P \mid \|pos(p) - centro(v)\| \leq r\}| \tag{3.2}$$

donde P es el conjunto de personas detectadas y $pos(p)$ es la posición estimada de la persona p en el plano del mapa. Cuantas más personas haya cerca de una frontera, mayor es su costo dinámico y menor su utilidad. De esta forma el planificador tiende a evitar fronteras en zonas concurridas en favor de aquellas en zonas libres de personas.

3.5.3. Estrategia E2: Ruta planificada

La Estrategia E2 amplía el criterio de E1 considerando no solo la proximidad a la frontera destino sino la presencia de personas a lo largo de todo el trayecto planificado por Nav2 hasta ella:

$$Dinámica_{E2}(v) = |\{p \in P \mid \exists\, q \in Ruta(v) : \|pos(p) - q\| \leq r\}| \tag{3.3}$$

donde $Ruta(v)$ es el conjunto de puntos de la ruta planificada hasta v. El planificador penaliza las fronteras cuyo camino de acceso está bloqueado o concurrido, priorizando rutas que puedan recorrerse con menor interferencia.

3.5.4. Estrategia E3: Predictiva

La Estrategia E3 incorpora un modelo de predicción de movimiento para anticipar la posición futura de las personas. A partir del historial de posiciones de cada actor, se estima su velocidad promedio y se predice dónde estará al momento en que el robot llegue a la frontera (en un tiempo de viaje t segundos):

$$\hat{pos}(p,t) = pos(p) + \bar{v}(p) \cdot t \tag{3.4}$$

El costo dinámico se calcula entonces como en E2 pero usando las posiciones predichas $\hat{pos}(p,t)$ en lugar de las posiciones actuales. Esta estrategia permite al planificador evitar proactivamente rutas que, aunque libres en el momento de la decisión, se estima que estarán bloqueadas cuando el robot las recorra.

En la Figura 3.4 se presenta una comparación conceptual de las tres estrategias.

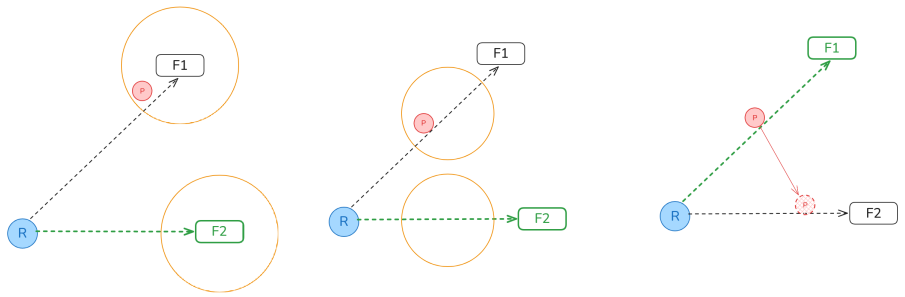

(a) E1 (Frontera): se penaliza la proximidad de personas a la frontera.

(b) E2 (Ruta planificada): se penaliza la interferencia sobre la ruta.

(c) E3 (Predictiva): se penaliza la interferencia esperada en el futuro.

Convenciones: **R** = robot, **P** = persona detectada, F_1/F_2 = fronteras candidatas, **flecha verde** = ruta/fontera seleccionada, **línea negra punteada** = alternativa no seleccionada, **círculo naranja** = zona de evaluación local, y en E3 la **persona rayada** representa la posición predicha.

Figura 3.4: Comparación conceptual de las estrategias E1 (Frontera), E2 (Ruta planificada) y E3 (Predictiva). La frontera seleccionada en cada caso se indica con un recuadro verde.

3.6. Métricas de evaluación semántica

Para cuantificar el impacto de los agentes dinámicos en la calidad del mapa se diseñaron métricas específicas que se calculan y publican en tiempo real por el nodo SemanticMetricsNode.

3.6.1. Celdas fantasma

Las **celdas fantasma** (*ghost cells*) son celdas que el mapa registra como ocupadas en el momento actual pero que en observaciones recientes estaban libres. Formalmente, dado el mapa actual M_t y los mapas de los últimos k instantes $\{M_{t-k}, \ldots, M_{t-1}\}$, el número de celdas fantasma se calcula como:

$$GC(t) = \sum_{i=1}^{k} |\{(r,c) \mid M_t(r,c) > 50 \ \wedge \ M_{t-i}(r,c) < 50\}| \tag{3.5}$$

Un valor elevado de GC indica que el mapa contiene muchas ocupaciones transitorias causadas por personas en movimiento. A medida que el sistema de filtrado semántico funciona correctamente, el valor de GC debería mantenerse bajo incluso en escenarios con muchos actores.

3.6.2. Entropía del mapa

La **entropía del mapa** cuantifica la incertidumbre global del mapa de ocupación. Un mapa de alta calidad debería presentar celdas con valores claramente definidos (libre u ocupado), mientras que un mapa degradado por agentes dinámicos tendrá más celdas con valores intermedios o inconsistentes. La entropía se calcula sobre las celdas conocidas (valor ≥ 0) del mapa:

$$H = -\sum_{(r,c)\,:\,M(r,c)\geq 0} p_{r,c} \cdot \log_2(p_{r,c}) \tag{3.6}$$

donde $p_{r,c} = M(r,c)/100$ es la probabilidad de ocupación de la celda. Valores de entropía más altos indican mayor incertidumbre en el mapa.

3.6.3. Métricas de detección de personas

Complementariamente se registran métricas sobre la actividad de los actores dinámicos durante cada experimento:

- **Total de frames procesados**: número de frames en los que YOLOv8 realizó al menos una detección.
- **Promedio de personas por frame**: promedio de personas detectadas en cada frame procesado, indicador de la densidad de actividad dinámica.
- **Máximo de personas detectadas simultáneamente**: número máximo de personas presentes en un mismo frame, útil para caracterizar los picos de concurrencia.

Capítulo 4

Experimentación

Este capítulo describe los experimentos realizados para validar las estrategias de planificación de siguiente mejor vista (*Next Best View*, NBV) implementadas en AlfredZ. El objetivo es comparar el comportamiento de cada estrategia frente a una línea de base Greedy en entornos de simulación con distintas densidades de actores dinámicos, evaluando métricas de precisión de mapa, exploración y eficiencia de procesado.

Los experimentos se organizaron en tres etapas: una etapa de calibración para determinar los hiperparámetros óptimos del sistema, seguida de tres etapas de validación, una por cada estrategia de utilidad dinámica propuesta. En cada etapa de validación se compara la estrategia correspondiente con la misma línea de base Greedy ejecutada en condiciones idénticas.

4.1. Configuración experimental

4.1.1. Entornos de simulación

Los experimentos se ejecutaron en simulación mediante Gazebo con dos entornos de interior de diferente distribución espacial:

- **house**: planta residencial compacta, con pasillos estrechos y múltiples habitaciones de tamaño reducido. Su geometría favorece la acumulación de obstáculos dinámicos en zonas de paso.
- **office**: planta de bloque de oficinas de mayor superficie, con espacios abiertos y áreas de circulación más amplias. La distribución genera rutas de exploración más largas entre fronteras.

En cada entorno se ejecutaron experimentos con cinco niveles de densidad de actores dinámicos: 0, 5, 10, 15 y 20 personas simuladas con trayectorias autónomas. La combinación de dos entornos y cinco niveles de densidad produce **10 configuraciones** de prueba por estrategia.

Todos los experimentos tuvieron una duración de **1800 segundos** (30 minutos). AlfredZ contó con los mismos parámetros de navegación, percepción y mapa en todas las ejecuciones, con la única variación en la estrategia de planificación NBV.

4.1.2. Configuración del sistema

El sistema AlfredZ integra los siguientes componentes en cada experimento:

- **RTAB-Map**: construcción y actualización del mapa de ocupación 3D.
- **Nav2**: planificación de rutas y ejecución de la navegación autónoma.
- **YOLO**: detección de personas en tiempo real a partir de imágenes de la cámara del robot.
- **Planificador NBV semántico**: selección de la frontera destino según la estrategia configurada, implementada en el nodo `ExplorerNode`.

La función de utilidad empleada por las estrategias dinámicas sigue la forma general:

$$U(v) = IG_{\text{estático}}(v) - \lambda \cdot D(v) - \mu \cdot C_{\text{trayecto}}(v) \tag{4.1}$$

donde $IG_{\text{estático}}(v)$ representa la ganancia de información estática de la frontera v, $D(v)$ es el costo dinámico calculado según la estrategia activa, $C_{\text{trayecto}}(v)$ es el costo de la ruta planificada hacia v, y λ y μ son hiperparámetros que ponderan cada componente. Los valores óptimos $\lambda = 5$ y $\mu = 0{,}01$ se determinaron en la etapa de calibración descrita en la Sección 4.3.

4.1.3. Métricas de evaluación

El desempeño de cada estrategia se evaluó mediante tres métricas registradas al final de cada experimento:

- **Celdas fantasma (*ghost cells*)**: número de celdas del mapa de ocupación que aparecen marcadas como ocupadas en el instante final pero que estaban libres en los tres mapas anteriores del historial. Esta métrica cuantifica la presencia de falsos positivos de ocupación generados por obstáculos dinámicos que ya no se encuentran en esa posición. Un valor **menor** indica mayor precisión del mapa.
- **Entropía del mapa (*map entropy*)**: entropía de Shannon calculada sobre las celdas conocidas del mapa de ocupación final, definida como $H = -\sum p_i \log_2(p_i)$, donde $p_i = v_i/100$ para cada celda con valor $v_i \geq 0$. Cuantifica la variedad de estados observados en el mapa y se emplea como indicador del grado de exploración alcanzado. Un valor **mayor** indica mayor exploración.

- **Frames totales procesados (*total frames processed*)**: contador acumulativo del número de observaciones de cámara procesadas por el *pipeline* de visión durante toda la ejecución del experimento. Se utiliza como indicador de eficiencia y throughput del sistema perceptivo. Un valor **mayor** indica mayor cantidad de observaciones procesadas.

4.1.4. Puntuación compuesta

Para facilitar la comparación global entre estrategias se empleó una puntuación compuesta que agrega las tres métricas en un único valor escalar. Previamente, cada métrica se normalizó mediante normalización min-máx global sobre el conjunto de valores de ambas estrategias comparadas:

$$\hat{x} = \frac{x - x_{\text{mín}}}{x_{\text{máx}} - x_{\text{mín}}} \tag{4.2}$$

Dado que en celdas fantasma un valor menor corresponde a mejor desempeño, se invierte la normalización de esta métrica ($1 - \hat{x}_{\text{ghost}}$). La puntuación compuesta se calcula entonces como:

$$S = 0{,}40 \cdot (1 - \hat{x}_{\text{ghost}}) + 0{,}35 \cdot \hat{x}_{\text{entropy}} + 0{,}25 \cdot \hat{x}_{\text{frames}} \tag{4.3}$$

Los pesos asignados reflejan las prioridades del proyecto: la precisión del mapa (celdas fantasma) recibe el mayor peso (40 %), seguida de la exploración (entropía, 35 %) y la eficiencia de procesado (frames, 25 %).

La estrategia con mayor puntuación compuesta en una configuración dada se considera ganadora en esa configuración. Se utiliza adicionalmente el criterio de "cuasi-empate o mejor" cuando la puntuación compuesta de una estrategia alcanza al menos el 90 % de la puntuación de la estrategia contraria.

4.2. Estrategia de comparación: Greedy

La estrategia Greedy actúa como línea de base de referencia. En cada ciclo de decisión, selecciona la frontera inexplorada más cercana al robot según distancia euclídea, sin considerar factores dinámicos ni calcular rutas completas. Su función de selección se reduce a:

$$v^* = \arg\min_{v \in \mathcal{F}} \|p_{\text{robot}} - c_v\|_2 \tag{4.4}$$

donde $\mathcal{F}$ es el conjunto de fronteras disponibles y c_v es el centroide de la frontera v.

Esta estrategia maximiza el tiempo efectivo de movimiento al minimizar el costo computacional por decisión: no planifica rutas, no estima interferencia dinámica ni predice posiciones futuras de personas. La ausencia de modelado dinámico implica que el robot puede dirigirse repetidamente a zonas con alta actividad de personas, incrementando la probabilidad de generar celdas fantasma en el mapa. Los experimentos Greedy se identifican con los casos G001 a

G010, correspondientes a las mismas 10 configuraciones (entorno × número de actores) que las estrategias de validación.

4.3. Etapa de calibración

La función de utilidad (4.1) incorpora dos hiperparámetros —λ y μ— cuyos valores determinan en qué medida el planificador NBV penaliza la interferencia dinámica y el costo de trayecto, respectivamente. Valores inadecuados pueden llevar al robot a ignorar la presencia de personas (λ demasiado bajo) o a seleccionar fronteras subóptimas por sobre-penalizar rutas largas (μ demasiado alto). La etapa de calibración tuvo como objetivo identificar empíricamente la combinación de hiperparámetros que maximiza el desempeño global del sistema, medido con la puntuación compuesta definida en la Sección 4.1.4.

4.3.1. Diseño de los experimentos de calibración

Se evaluaron todas las combinaciones del producto cartesiano $\lambda \in \{0, 1, 5\}$ y $\mu \in \{0{,}01;\ 0{,}5;\ 2{,}0\}$, aplicadas sobre las tres estrategias de utilidad dinámica, lo que da lugar a $3 \times 3 \times 3 = 27$ experimentos (S001–S027). La Tabla 4.1 detalla la asignación de identificadores a cada combinación.

Tabla 4.1: Grid de experimentos de calibración. Cada celda contiene el identificador del experimento correspondiente. S015 no produjo datos válidos y fue excluido del análisis.

λ	μ	**Frontera**	**Ruta Planificada**	**Predictiva**
0	0,01	S001	S010	S019
0	0,5	S002	S011	S020
0	2,0	S003	S012	S021
1	0,01	S004	S013	S022
1	0,5	S005	S014	S023
1	2,0	S006	S015*	S024
5	0,01	S007	S016	S025
5	0,5	S008	S017	S026
5	2,0	S009	S018	S027

* Experimento fallido; excluido del análisis.

Todos los experimentos se ejecutaron en el entorno **house** con **5 actores** dinámicos y una duración de **1800 segundos**. Se realizó una única ejecución por combinación. La elección de un entorno y densidad de actores fijos permite aislar el efecto de los hiperparámetros de otras variables del sistema.

4.3.2. Resultados por estrategia

Las Tablas 4.2, 4.3 y 4.4 presentan el ranking completo de los experimentos de calibración para cada estrategia, ordenados por puntuación compuesta descendente. La Figura 4.1 compara los scores de cada estrategia en función de la combinación de hiperparámetros.

Tabla 4.2: Ranking de experimentos de calibración — Vecindad. Mejor combinación: $\lambda = 0$, $\mu = 0{,}01$ (S001).

Pos.	**Exp**	λ	μ	**Ghost**	**Entropía**	**Frames**	**Score**
1	**S001**	0	0,01	30	$1{,}64 \times 10^{-4}$	217	**0,8772**
2	S006	1	2,0	0	$1{,}55 \times 10^{-4}$	158	0,8091
3	S005	1	0,5	9	$1{,}48 \times 10^{-4}$	179	0,7708
4	S008	5	0,5	31	$1{,}34 \times 10^{-4}$	198	0,6874
5	S007	5	0,01	108	$1{,}50 \times 10^{-4}$	217	0,6666
6	S002	0	0,5	119	$1{,}49 \times 10^{-4}$	210	0,6584
7	S004	1	0,01	41	$1{,}22 \times 10^{-4}$	179	0,6520
8	S003	0	2,0	347	$1{,}94 \times 10^{-4}$	174	0,5717
9	S009	5	2,0	79	$7{,}5 \times 10^{-5}$	143	0,3089

Tabla 4.3: Ranking de experimentos de calibración — Ruta Planificada. Mejor combinación: $\lambda = 5$, $\mu = 0{,}01$ (S016). S015 excluido por fallo.

Pos.	**Exp**	λ	μ	**Ghost**	**Entropía**	**Frames**	**Score**
1	**S016**	5	0,01	70	$2{,}30 \times 10^{-4}$	601	**0,8436**
2	S011	0	0,5	29	$1{,}83 \times 10^{-4}$	421	0,8329
3	S012	0	2,0	0	$1{,}47 \times 10^{-4}$	390	0,8217
4	S010	0	0,01	0	$1{,}23 \times 10^{-4}$	380	0,7830
5	S013	1	0,01	67	$9{,}6 \times 10^{-5}$	355	0,5697
6	S014	1	0,5	126	$1{,}52 \times 10^{-4}$	440	0,5584
7	S018	5	2,0	179	$1{,}02 \times 10^{-4}$	342	0,2920
8	S017	5	0,5	156	$4{,}2 \times 10^{-5}$	307	0,0514

Los óptimos por estrategia no coinciden: Frontera alcanza su mejor resultado con $\lambda = 0$, $\mu = 0{,}01$ (S001, score 0,8772); Ruta Planificada con $\lambda = 5$, $\mu = 0{,}01$ (S016, score 0,8436); y Predictiva con $\lambda = 0$, $\mu = 0{,}5$ (S020, score 0,8953). Esta divergencia indica que la respuesta óptima a los hiperparámetros depende del mecanismo de cálculo del costo dinámico de cada estrategia, y motiva un análisis global para identificar la combinación más robusta.

Tabla 4.4: Ranking de experimentos de calibración — Predictiva. Mejor combinación: $\lambda = 0$, $\mu = 0{,}5$ (S020).

Pos.	**Exp**	λ	μ	**Ghost**	**Entropía**	**Frames**	**Score**
1	**S020**	0	0,5	56	$2{,}13 \times 10^{-4}$	530	**0,8953**
2	S025	5	0,01	35	$1{,}74 \times 10^{-4}$	500	0,8418
3	S019	0	0,01	0	$1{,}33 \times 10^{-4}$	460	0,7888
4	S023	1	0,5	11	$1{,}18 \times 10^{-4}$	470	0,7644
5	S021	0	2,0	35	$1{,}24 \times 10^{-4}$	450	0,7177
6	S027	5	2,0	56	$1{,}07 \times 10^{-4}$	420	0,6146
7	S024	1	2,0	4	$5{,}5 \times 10^{-5}$	410	0,5943
8	S026	5	0,5	214	$1{,}65 \times 10^{-4}$	490	0,4937
9	S022	1	0,01	99	$7{,}1 \times 10^{-5}$	380	0,2504

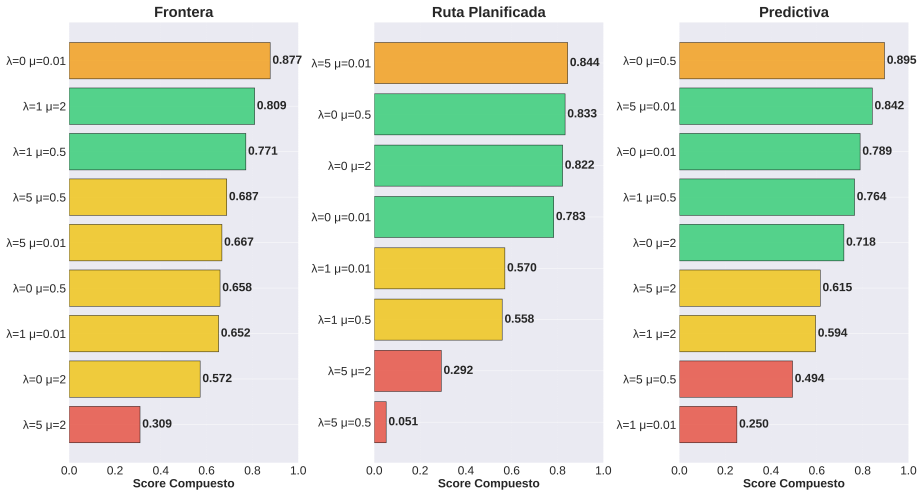

Figura 4.1: Score compuesto por experimento, agrupado por estrategia. Cada barra corresponde a una combinación (λ, μ). Se observa que los óptimos por estrategia corresponden a combinaciones distintas.

4.3.3. Análisis global de hiperparámetros

Para identificar la combinación de hiperparámetros que ofrece el mejor rendimiento promedio con independencia de la estrategia utilizada, se calculó el score promedio de cada par (λ, μ) sobre los tres experimentos correspondientes (uno por estrategia). La Tabla 4.5 presenta los resultados ordenados por score promedio descendente, y la Figura 4.2 los visualiza.

Tabla 4.5: Score promedio por combinación (λ, μ) considerando las tres estrategias. La combinación $\lambda = 5$, $\mu = 0{,}01$ ocupa el primer lugar.

Pos.	λ	μ	**Score prom.**	**Score máx.**	**Score mín.**
1	5	0,01	**0,7897**	0,8780	0,6810
2	0	0,5	0,7882	0,8640	0,6707
3	0	0,01	0,7812	0,8425	0,7502
4	1	0,5	0,7282	0,7891	0,6605
5	1	2,0	0,7030	0,8167	0,5892
6	0	2,0	0,6715	0,7918	0,5167
7	1	0,01	0,5521	0,7007	0,3399
8	5	0,5	0,5397	0,7280	0,2986
9	5	2,0	0,5276	0,6280	0,4770

Las Figuras 4.3 y 4.4 muestran el efecto individual de cada hiperparámetro promediando sobre todos los valores del otro y sobre las tres estrategias.

El análisis individual revela que $\lambda = 0$ obtiene el mayor promedio por separado (0,7470 frente a 0,6559 de $\lambda = 1$ y 0,6190 de $\lambda = 5$), mientras que $\mu = 0{,}01$ es el mejor valor de μ (0,7077 frente a 0,6854 y 0,6254). Sin embargo, el ranking por combinaciones posiciona $\lambda = 5$, $\mu = 0{,}01$ en primer lugar porque esa pareja específica produce resultados más equilibrados entre estrategias que $\lambda = 0$ con cualquier valor de μ.

4.3.4. Selección de parámetros para la validación

La selección de $\lambda = 5$, $\mu = 0{,}01$ como configuración fija para todas las etapas de validación se fundamenta en tres criterios complementarios:

1. **Necesidad de activar el costo dinámico.** Con $\lambda = 0$ la función de utilidad (4.1) se reduce a $U(v) = IG_{\text{estático}}(v) - \mu \cdot C_{\text{trayecto}}(v)$, haciendo que el término $D(v)$ de cada estrategia quede anulado. Bajo esa condición, las tres estrategias se comportan de forma idéntica y la comparación entre ellas pierde sentido. El uso de $\lambda > 0$ es, por tanto, una condición necesaria para que el experimento de validación sea informativo.

2. **Mejor rendimiento promedio entre combinaciones con $\lambda > 0$.** Entre las combinaciones que satisfacen $\lambda > 0$, la pareja $\lambda = 5$, $\mu = 0{,}01$ alcanza el mayor score promedio global (0,7897), superando a $\lambda = 1$, $\mu = 0{,}5$ (0,7282) y a las demás alternativas con $\lambda \in \{1, 5\}$.

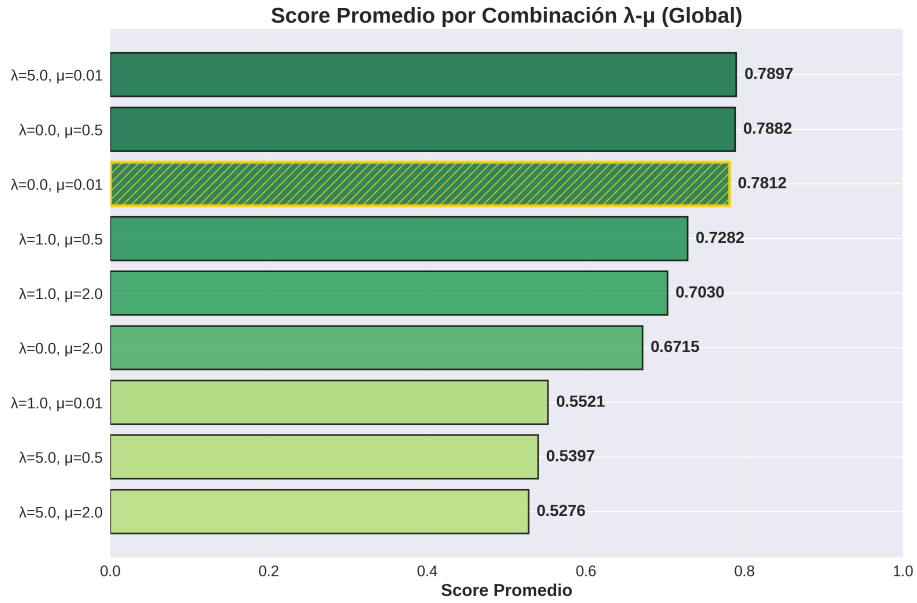

Figura 4.2: Score promedio por combinación (λ, μ) sobre las tres estrategias. Las tres primeras combinaciones tienen scores promedio similares (0,779–0,790), con $\lambda = 5$, $\mu = 0{,}01$ a la cabeza.

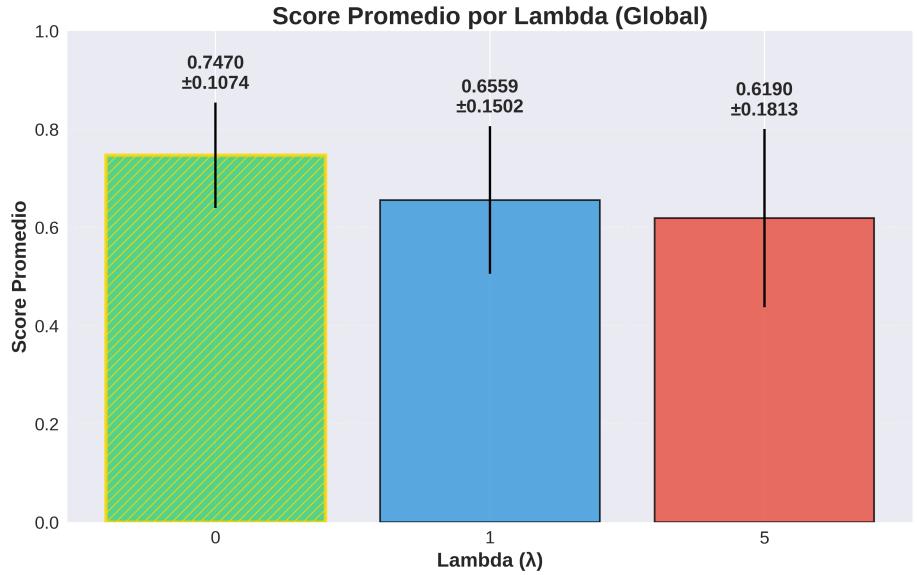

Figura 4.3: Efecto de λ sobre la puntuación compuesta promedio (promediando sobre todos los valores de μ y las tres estrategias). $\lambda = 0$ obtiene el mayor promedio individual (0,7470), mientras que $\lambda = 5$ presenta el menor (0,6190).

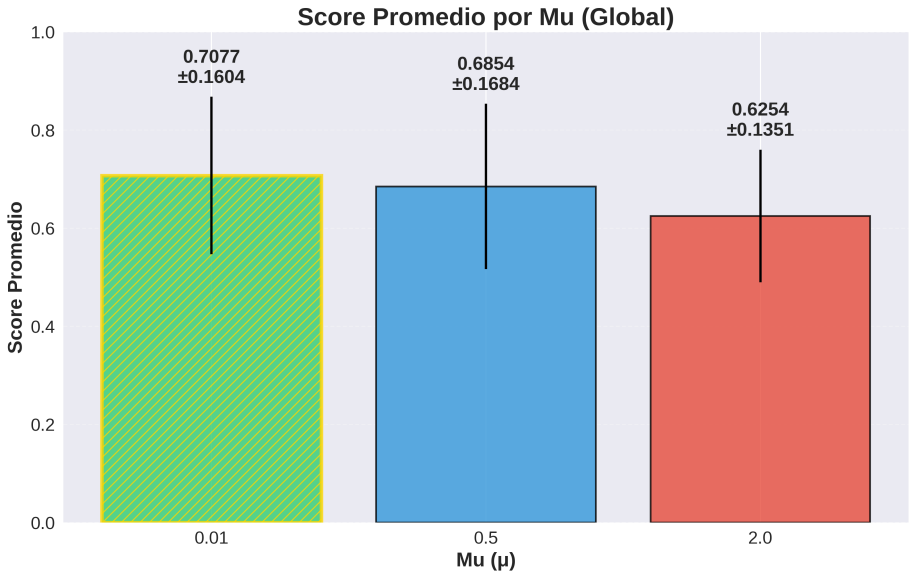

Figura 4.4: Efecto de μ sobre la puntuación compuesta promedio (promediando sobre todos los valores de λ y las tres estrategias). $\mu = 0{,}01$ es consistentemente el mejor valor en todas las estrategias (0,7077).

3. **Comparación equitativa entre estrategias.** Los óptimos individuales de cada estrategia difieren entre sí; utilizar parámetros distintos por estrategia introduciría un confusor que impediría atribuir diferencias de rendimiento a la estrategia en sí. La adopción de un único par de hiperparámetros garantiza que las comparaciones de la etapa de validación midan exclusivamente el efecto del mecanismo de cálculo del costo dinámico.

Con base en estos criterios, todos los experimentos de validación descritos en las secciones siguientes se ejecutaron con $\lambda = 5$ y $\mu = 0{,}01$.

4.4. Frontera: utilidad dinámica por centro de frontera

La estrategia **Frontera** calcula el costo dinámico $D(v)$ contando el número de personas detectadas dentro de un radio fijo r alrededor del centroide de la frontera v:

$$D_{\text{Front}}(v) = \left|\{p_i : \|c_v - p_i\|_2 \leq r\}\right| \tag{4.5}$$

La evaluación se realiza en el punto de *destino*, sin considerar el camino que el robot debe recorrer para llegar. Esta simplicidad implica un costo computacional bajo pero también una limitación estructural: el robot puede seleccionar

fronteras cuyo entorno inmediato está libre de personas, pero cuyo trayecto de acceso atraviesa zonas concurridas.

4.4.1. Diseño de los experimentos

Los experimentos de validación de la estrategia Frontera comprenden **10 casos de prueba** (TC001–TC010) con las mismas configuraciones de entorno y densidad de actores que el resto de las etapas de validación, detalladas en la Tabla 4.6. Cada caso se ejecutó con **tres réplicas independientes** (V001–V030); el valor representativo de Frontera en cada configuración es la mediana de las tres réplicas. La línea de base Greedy corresponde a los experimentos G001–G010, ejecutados bajo las mismas condiciones ($\lambda = 5$, $\mu = 0{,}01$, duración 1800 s).

Tabla 4.6: Casos de prueba de validación: estrategia Frontera y Greedy.

Caso (Frontera)	Caso (Greedy)	Entorno	Actores	Réplicas (Frontera)
TC001	G001	house	0	V001–V003
TC002	G002	office	0	V004–V006
TC003	G003	house	5	V007–V009
TC004	G004	office	5	V010–V012
TC005	G005	house	10	V013–V015
TC006	G006	office	10	V016–V018
TC007	G007	house	15	V019–V021
TC008	G008	office	15	V022–V024
TC009	G009	house	20	V025–V027
TC010	G010	office	20	V028–V030

La normalización global min-máx se aplicó sobre la unión de valores de Frontera y Greedy, con los rangos detallados en la Tabla 4.7.

Tabla 4.7: Rangos globales de normalización para la comparación Frontera vs Greedy.

Métrica	Mínimo	Máximo
Celdas fantasma	0	155
Entropía del mapa	$9{,}42 \times 10^{-6}$	$2{,}06 \times 10^{-4}$
Frames procesados	98	648

El máximo de celdas fantasma (155) corresponde al experimento TC007 (house-15) de la propia estrategia Frontera, lo que constituye un resultado relevante que se discute en la Sección 4.4.5.

4.4.2. Resultados por métrica

La Tabla 4.8 y la Figura 4.5 presentan los resultados de celdas fantasma por configuración.

Tabla 4.8: Celdas fantasma (valor final) por configuración: Frontera vs Greedy. Valores en negrita indican la estrategia ganadora. Menor es mejor.

Configuración	Frontera (mediana)	Greedy	% dif.
house-0	16	**15**	+7 %
office-0	21	**13**	+62 %
house-5	**53**	81	−35 %
office-5	92	**78**	+18 %
house-10	**0**	83	−100 %
office-10	**105**	125	−16 %
house-15	155	**118**	+31 %
office-15	**24**	153	−84 %
house-20	**0**	131	−100 %
office-20	**0**	83	−100 %

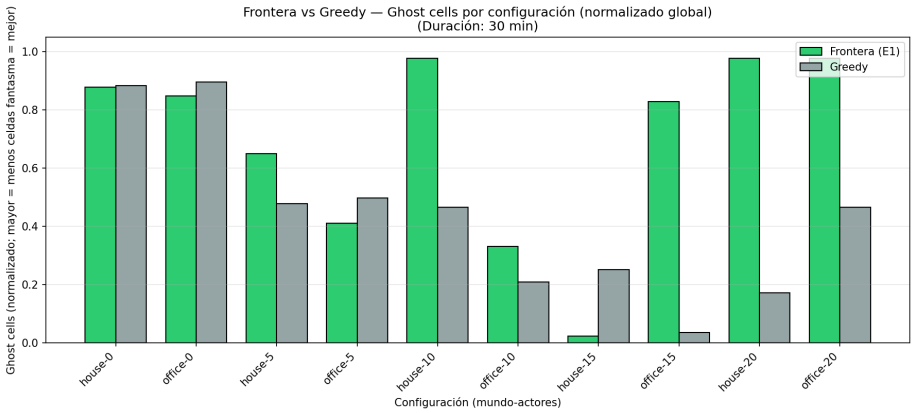

Figura 4.5: Celdas fantasma normalizadas por configuración. Valor normalizado mayor indica menor número de celdas fantasma (mejor precisión del mapa). Frontera supera a Greedy en 6 de las 10 configuraciones.

La estrategia Frontera supera a Greedy en celdas fantasma en **6 de las 10** configuraciones. Las victorias se concentran en configuraciones con densidad media-alta de actores (10, 15 y 20), donde la estrategia logra cero celdas fantasma en house-10, house-20 y office-20, y reducciones del 84 % en office-15. La excepción más destacada es TC007 (house-15), donde Frontera acumula 155 celdas fantasma frente a 118 de Greedy, el peor resultado individual de toda la

estrategia y el máximo global del conjunto de normalización; este caso se analiza en la Sección 4.4.5.

La Tabla 4.9 y la Figura 4.6 presentan los resultados de entropía del mapa.

Tabla 4.9: Entropía del mapa (valor final) por configuración: Frontera vs Greedy. Valores en negrita indican la estrategia ganadora. Mayor es mejor.

Configuración	**Frontera (mediana)**	**Greedy**	**% dif.**
house-0	$\mathbf{1{,}43 \times 10^{-4}}$	$1{,}29 \times 10^{-4}$	+10 %
office-0	$1{,}33 \times 10^{-4}$	$\mathbf{2{,}06 \times 10^{-4}}$	−36 %
house-5	$9{,}5 \times 10^{-5}$	$\mathbf{1{,}67 \times 10^{-4}}$	−43 %
office-5	$7{,}8 \times 10^{-5}$	$\mathbf{1{,}07 \times 10^{-4}}$	−27 %
house-10	$\mathbf{1{,}51 \times 10^{-4}}$	$6{,}6 \times 10^{-5}$	+127 %
office-10	$\mathbf{1{,}49 \times 10^{-4}}$	$1{,}27 \times 10^{-4}$	+17 %
house-15	$\mathbf{1{,}24 \times 10^{-4}}$	$9{,}4 \times 10^{-6}$	+1213 %
office-15	$\mathbf{1{,}12 \times 10^{-4}}$	$8{,}9 \times 10^{-5}$	+26 %
house-20	$4{,}8 \times 10^{-5}$	$\mathbf{1{,}88 \times 10^{-4}}$	−74 %
office-20	$1{,}2 \times 10^{-5}$	$\mathbf{1{,}21 \times 10^{-4}}$	−90 %

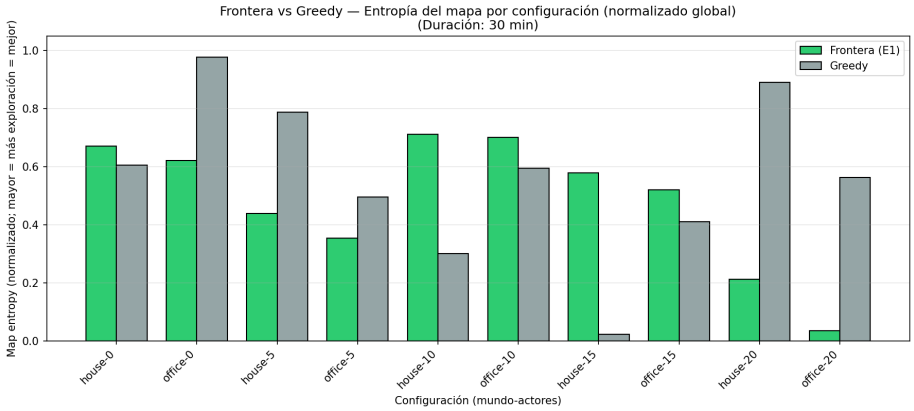

Figura 4.6: Entropía del mapa normalizada por configuración. Valor normalizado mayor indica mayor exploración. Frontera supera a Greedy en 5 de las 10 configuraciones.

En entropía del mapa Frontera supera a Greedy en **5 de las 10** configuraciones, resultado superior al esperado para una estrategia que solo evalúa el punto de destino. Las victorias se concentran en densidades medias (10 y 15 actores en ambos entornos) y en house-0. En contraste, Greedy domina con claridad en densidad baja (office-0, house-5, office-5) y alta (house-20, office-20), donde la penalización de fronteras por presencia de personas en el destino desorienta la exploración.

Tabla 4.10: Frames totales procesados (valor final acumulado) por configuración: Frontera vs Greedy. Valores en negrita indican la estrategia ganadora. Mayor es mejor.

Configuración	**Frontera (mediana)**	**Greedy**	**% dif.**
house-0	**364**	217	+68 %
office-0	478	**555**	−14 %
house-5	439	**577**	−24 %
office-5	444	**648**	−31 %
house-10	390	**454**	−14 %
office-10	400	**601**	−33 %
house-15	356	**597**	−40 %
office-15	366	**607**	−40 %
house-20	**353**	265	+33 %
office-20	**379**	98	+287 %

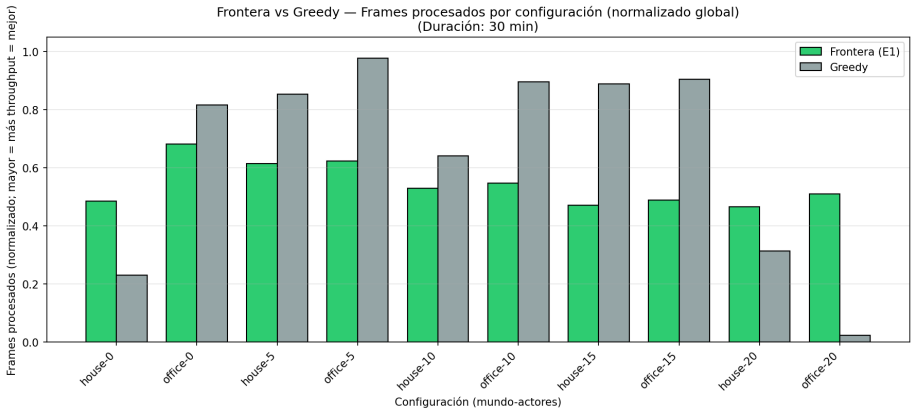

Figura 4.7: Frames procesados normalizados por configuración. Valor normalizado mayor indica mayor throughput del pipeline de visión. Frontera supera a Greedy en 3 de las 10 configuraciones.

La Tabla 4.10 y la Figura 4.7 presentan los resultados de frames procesados.

En frames procesados Frontera supera a Greedy únicamente en **3 de las 10** configuraciones: house-0 (+68 %), house-20 (+33 %) y office-20 (+287 %). En las siete configuraciones restantes —todas de densidad baja a media— Greedy procesa significativamente más frames, con diferencias del −14 % al −40 %. El patrón de victoria en los extremos de densidad (0 y 20 actores) se discute en la Sección 4.4.5.

4.4.3. Puntuación compuesta y análisis global

Las Figuras 4.8 y 4.9 resumen los resultados por puntuación compuesta.

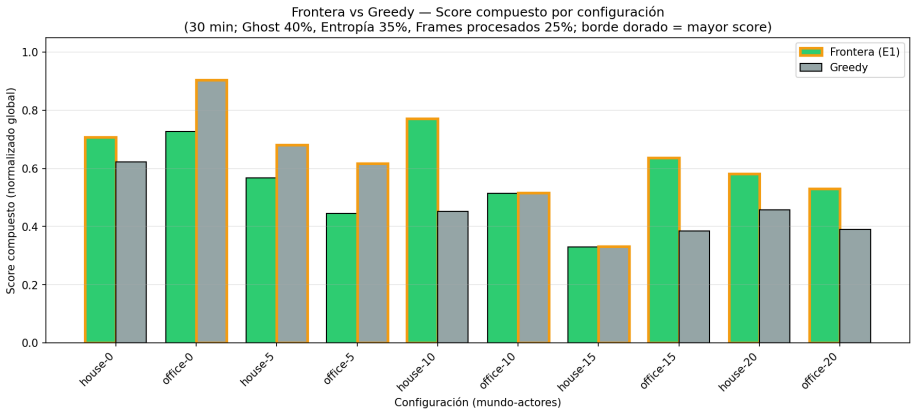

Figura 4.8: Puntuación compuesta por configuración (Frontera vs Greedy). Pesos: celdas fantasma 40 %, entropía 35 %, frames 25 %. Frontera supera a Greedy en 5 de las 10 configuraciones.

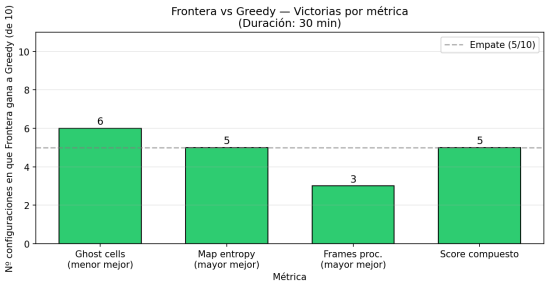

(a) Victorias por métrica individual.

(b) Victorias por puntuación compuesta.

Figura 4.9: Resumen de victorias de la estrategia Frontera frente a Greedy.

Por puntuación compuesta, la estrategia Frontera es ganadora en **5 de las 10** configuraciones: TC001 (house-0), TC005 (house-10), TC008 (office-15), TC009

(house-20) y TC010 (office-20). En las cinco configuraciones restantes Greedy obtiene mayor puntuación; cuatro de ellas corresponden a office-0, house-5, office-5 y office-10, y la quinta a house-15, donde Frontera registra su peor resultado en ghost cells.

Aplicando el criterio de cuasi-empate ($S_{\text{Front}} \geq 0{,}9 \cdot S_{\text{Greedy}}$), Frontera resulta competitiva o mejor en **7 de las 10** configuraciones, lo que indica que incluso en los casos en que Greedy supera a Frontera, la diferencia en puntuación compuesta es reducida en la mayoría de ellos.

4.4.4. Análisis por entorno

Entorno house. En celdas fantasma, Frontera supera a Greedy en house-5, house-10 y house-20, pierde en house-0 por un margen mínimo (16 vs 15) y registra su peor caso en house-15 (155 vs 118). En entropía, Frontera gana en house-0, house-10 y house-15, y pierde en house-5 y house-20. En frames, solo supera a Greedy en house-0 y house-20. La puntuación compuesta favorece a Frontera en TC001, TC005 y TC009 (house-0, house-10 y house-20).

Entorno office. En celdas fantasma, Frontera supera a Greedy en office-10, office-15 y office-20, y pierde en office-0 y office-5. En entropía, gana en office-10 y office-15, y pierde en office-0, office-5 y office-20. En frames, solo supera a Greedy en office-20 (+287 %). La puntuación compuesta favorece a Frontera en TC008 y TC010 (office-15 y office-20).

En conjunto, el beneficio de la estrategia Frontera aumenta con la densidad de actores en ambos entornos, con la excepción de house-15 que constituye un caso anómalo. Las configuraciones con 20 actores muestran las ventajas más consistentes tanto en ghost cells como en frames procesados.

4.4.5. Discusión

Los resultados permiten identificar tres aspectos centrales del comportamiento de la estrategia Frontera:

Precisión del mapa. La evaluación de personas en el entorno inmediato del centro de la frontera es efectiva para reducir ghost cells en la mayoría de las configuraciones con actores, especialmente a densidades de 10 o más. Sin embargo, la estrategia ignora el trayecto de acceso: el robot puede seleccionar una frontera libre de personas pero atravesar zonas concurridas durante el camino, generando ghost cells en el recorrido. Este mecanismo explica tanto las victorias parciales como las pérdidas en configuraciones de densidad media donde las personas se concentran en los pasillos de acceso más que en las propias fronteras.

La anomalía de house-15. El caso TC007 (house-15) presenta el peor resultado de toda la estrategia: 155 celdas fantasma frente a 118 de Greedy. Con 15 actores en el entorno compacto de house, la alta densidad de personas cerca de múltiples fronteras candidatas puede provocar que la estrategia descarte sistemáticamente las fronteras más accesibles en favor de alternativas más lejanas que, al momento de llegar, ya se encuentran igualmente ocupadas. Este efecto

de degradación por sobrepenalización es propio de estrategias que evalúan solo el punto de destino sin anticipar el estado futuro.

Frames procesados y densidad extrema. El patrón de victorias en frames a 0 y 20 actores responde a mecanismos distintos. Con 0 actores, la ausencia de personas elimina cualquier penalización dinámica y Frontera puede orientar su exploración hacia fronteras que maximizan el tiempo de observación activa. Con 20 actores, evitar las zonas más congestionadas permite al robot mantener un desplazamiento más fluido con menos interrupciones, procesando más frames en el mismo tiempo. En densidades intermedias (5–15 actores), la penalización de fronteras reduce la eficiencia de movimiento sin ofrecer un beneficio proporcional en frames.

En conjunto, los resultados validan la estrategia Frontera como alternativa competitiva a Greedy cuando se prioriza la precisión del mapa a densidades medias y altas, con la salvedad de que su comportamiento es menos predecible en configuraciones específicas donde la distribución espacial de los actores interactúa negativamente con el mecanismo de evaluación por centro de frontera.

4.5. Ruta Planificada: utilidad dinámica por trayecto de acceso

La estrategia **Ruta Planificada** extiende el costo dinámico de la estrategia Frontera al evaluar no solo el punto de destino sino el *trayecto completo* planificado hacia la frontera. El costo dinámico $D(v)$ se calcula contando las personas detectadas dentro de un radio r de cualquier punto de la ruta planificada $\mathcal{P}(v)$:

$$D_{\text{Ruta}}(v) = \left|\{p_i : \exists\, q \in \mathcal{P}(v) \text{ tal que } \|q - p_i\|_2 \leq r\}\right| \tag{4.6}$$

Esta formulación aborda la limitación estructural de la estrategia Frontera: el robot puede ahora descartar fronteras cuyo trayecto de acceso atraviesa zonas concurridas, aunque el destino en sí esté libre de personas. El costo computacional es mayor que en Frontera ya que requiere evaluar múltiples puntos de la ruta planificada para cada frontera candidata.

4.5.1. Diseño de los experimentos

Los experimentos de validación comprenden **10 casos de prueba** (TC011–TC020) con las mismas configuraciones de entorno y densidad de actores que el resto de las etapas de validación, detallados en la Tabla 4.11. Cada caso se ejecutó con **tres réplicas independientes** (V031–V060); el valor representativo de Ruta Planificada es la mediana de las tres réplicas. La línea de base Greedy corresponde a los experimentos G001–G010.

La normalización global min-máx se calculó sobre la unión de valores de Ruta Planificada y Greedy, con los rangos indicados en la Tabla 4.12. El máximo de celdas fantasma (220) pertenece a la propia estrategia Ruta Planificada en office-15, lo que es relevante para la interpretación de los resultados.

Tabla 4.11: Casos de prueba de validación: estrategia Ruta Planificada y Greedy.

Caso (Ruta Plan.)	Caso (Greedy)	Entorno	Actores	Réplicas
TC011	G001	house	0	V031–V033
TC012	G002	office	0	V034–V036
TC013	G003	house	5	V037–V039
TC014	G004	office	5	V040–V042
TC015	G005	house	10	V043–V045
TC016	G006	office	10	V046–V048
TC017	G007	house	15	V049–V051
TC018	G008	office	15	V052–V054
TC019	G009	house	20	V055–V057
TC020	G010	office	20	V058–V060

Tabla 4.12: Rangos globales de normalización para la comparación Ruta Planificada vs Greedy.

Métrica	Mínimo	Máximo
Celdas fantasma	13	220
Entropía del mapa	$9{,}42 \times 10^{-6}$	$2{,}06 \times 10^{-4}$
Frames procesados	98	648

4.5.2. Resultados por métrica

La Tabla 4.13 y la Figura 4.10 presentan los resultados de celdas fantasma por configuración.

Ruta Planificada supera a Greedy en celdas fantasma en **5 de las 10** configuraciones. A diferencia de lo que cabría esperar de una estrategia con mayor consciencia del entorno, los resultados en house-10 (130 vs 83 de Greedy), house-15 (216 vs 118) y office-15 (220 vs 153) muestran una degradación significativa. Este comportamiento, que contrasta con los resultados de la estrategia Frontera, se analiza en detalle en la Sección 4.5.5.

La Tabla 4.14 y la Figura 4.11 presentan los resultados de entropía del mapa.

En entropía del mapa Ruta Planificada supera a Greedy en **4 de las 10** configuraciones: house-0, house-10, house-15 y office-15. Greedy domina en office-0, house-5, office-5, office-10, house-20 y office-20. Las victorias de Ruta Planificada en entropía se concentran en el entorno house con densidades medias, mientras que Greedy mantiene ventaja en densidades bajas y en office con alta densidad de actores.

La Tabla 4.15 y la Figura 4.12 presentan los resultados de frames procesados.

En frames procesados Ruta Planificada supera a Greedy en **3 de las 10** configuraciones, con las victorias más pronunciadas en house-0 (+122 %) y office-20 (+482 %). En las siete configuraciones restantes Greedy procesa más frames, con diferencias que oscilan entre el −4 % (office-0) y el −43 % (house-15). El

Tabla 4.13: Celdas fantasma (valor final) por configuración: Ruta Planificada vs Greedy. Valores en negrita indican la estrategia ganadora. Menor es mejor.

Configuración	**Ruta Plan. (mediana)**	**Greedy**	**% dif.**
house-0	20	**15**	+33 %
office-0	34	**13**	+162 %
house-5	**59**	81	−27 %
office-5	**68**	78	−13 %
house-10	130	**83**	+57 %
office-10	**27**	125	−78 %
house-15	216	**118**	+83 %
office-15	220	**153**	+44 %
house-20	**72**	131	−45 %
office-20	**51**	83	−39 %

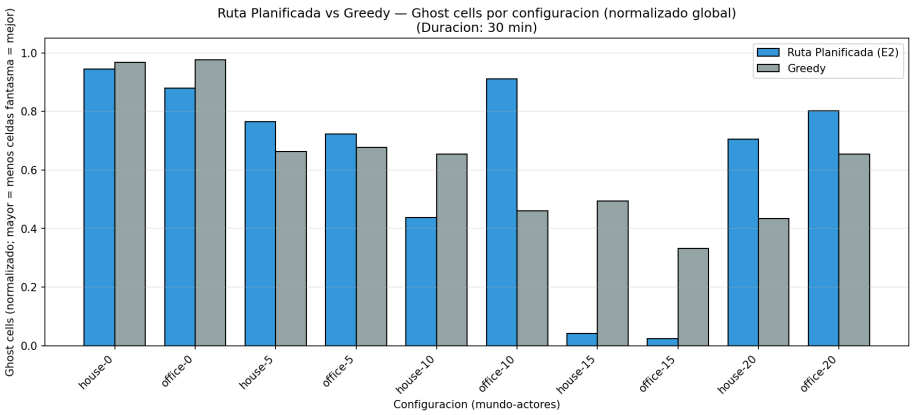

Figura 4.10: Celdas fantasma normalizadas por configuración. Valor normalizado mayor indica menor número de celdas fantasma (mejor precisión del mapa). Ruta Planificada supera a Greedy en 5 de las 10 configuraciones.

Tabla 4.14: Entropía del mapa (valor final) por configuración: Ruta Planificada vs Greedy. Valores en negrita indican la estrategia ganadora. Mayor es mejor.

Configuración	**Ruta Plan. (mediana)**	**Greedy**	**% dif.**
house-0	$\mathbf{1{,}83 \times 10^{-4}}$	$1{,}29 \times 10^{-4}$	$+42\,\%$
office-0	$1{,}21 \times 10^{-4}$	$\mathbf{2{,}06 \times 10^{-4}}$	$-41\,\%$
house-5	$5{,}5 \times 10^{-5}$	$\mathbf{1{,}67 \times 10^{-4}}$	$-67\,\%$
office-5	$1{,}01 \times 10^{-4}$	$\mathbf{1{,}07 \times 10^{-4}}$	$-5\,\%$
house-10	$\mathbf{1{,}34 \times 10^{-4}}$	$6{,}6 \times 10^{-5}$	$+101\,\%$
office-10	$7{,}8 \times 10^{-5}$	$\mathbf{1{,}27 \times 10^{-4}}$	$-39\,\%$
house-15	$\mathbf{1{,}22 \times 10^{-4}}$	$9{,}4 \times 10^{-6}$	$+1192\,\%$
office-15	$\mathbf{1{,}19 \times 10^{-4}}$	$8{,}9 \times 10^{-5}$	$+33\,\%$
house-20	$1{,}11 \times 10^{-4}$	$\mathbf{1{,}88 \times 10^{-4}}$	$-41\,\%$
office-20	$1{,}5 \times 10^{-5}$	$\mathbf{1{,}21 \times 10^{-4}}$	$-88\,\%$

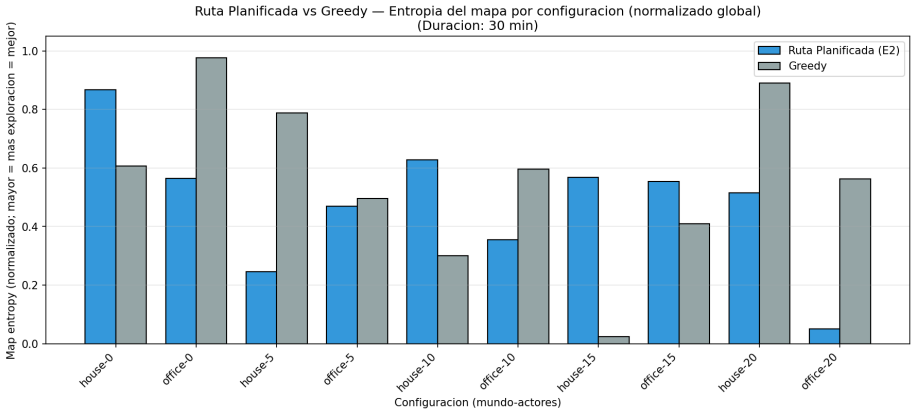

Figura 4.11: Entropía del mapa normalizada por configuración. Valor normalizado mayor indica mayor exploración. Ruta Planificada supera a Greedy en 4 de las 10 configuraciones.

Tabla 4.15: Frames totales procesados (valor final acumulado) por configuración: Ruta Planificada vs Greedy. Valores en negrita indican la estrategia ganadora. Mayor es mejor.

Configuración	**Ruta Plan. (mediana)**	**Greedy**	**% dif.**
house-0	**481**	217	+122 %
office-0	534	**555**	−4 %
house-5	471	**577**	−18 %
office-5	519	**648**	−20 %
house-10	401	**454**	−12 %
office-10	499	**601**	−17 %
house-15	339	**597**	−43 %
office-15	377	**607**	−38 %
house-20	**477**	265	+80 %
office-20	**570**	98	+482 %

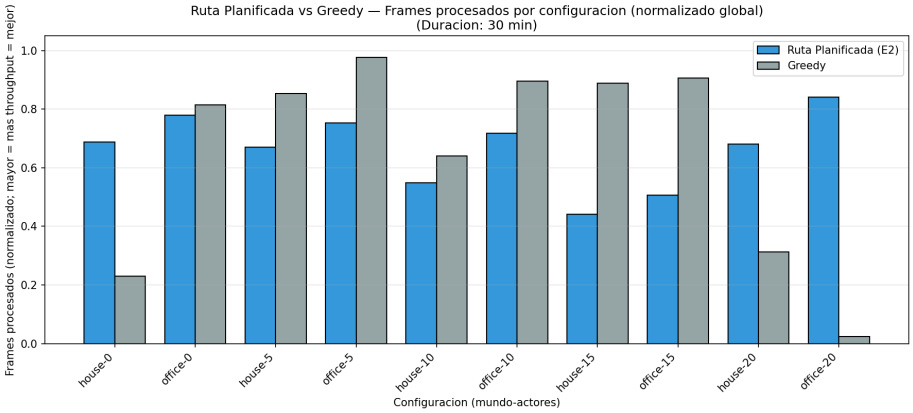

Figura 4.12: Frames procesados normalizados por configuración. Valor normalizado mayor indica mayor throughput del pipeline de visión. Ruta Planificada supera a Greedy en 3 de las 10 configuraciones.

patrón de victorias en los extremos de densidad (0 y 20 actores) es consistente con el observado en la estrategia Frontera, aunque con magnitudes superiores.

4.5.3. Puntuación compuesta y análisis global

Las Figuras 4.13 y 4.14 resumen los resultados por puntuación compuesta.

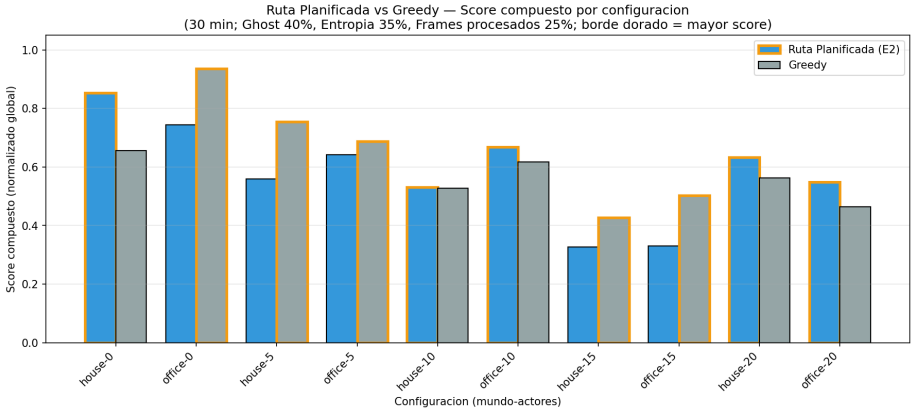

Figura 4.13: Puntuación compuesta por configuración (Ruta Planificada vs Greedy). Pesos: celdas fantasma 40 %, entropía 35 %, frames 25 %. Ruta Planificada supera a Greedy en 5 de las 10 configuraciones.

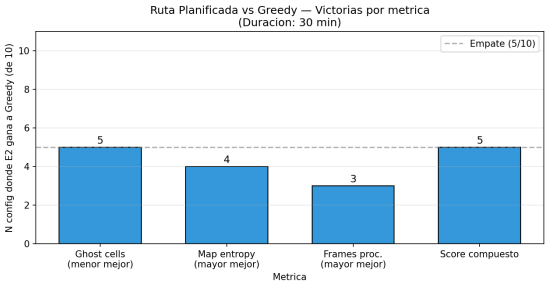

(a) Victorias por métrica individual.

(b) Victorias por puntuación compuesta.

Figura 4.14: Resumen de victorias de Ruta Planificada frente a Greedy.

Por puntuación compuesta, Ruta Planificada gana en **5 de las 10** configuraciones: TC011 (house-0), TC015 (house-10), TC016 (office-10), TC019 (house-20) y TC020 (office-20). Aplicando el criterio de cuasi-empate ($S_{\text{Ruta}} \geq 0{,}9 \cdot S_{\text{Greedy}}$), la estrategia es competitiva o mejor en **6 de las 10** configuraciones.

4.5.4. Análisis por entorno

Entorno house. En celdas fantasma, Ruta Planificada supera a Greedy en house-5 y house-20; pierde en house-0, house-10 y house-15. En entropía, gana en house-0, house-10 y house-15; pierde en house-5 y house-20. En frames, supera a Greedy solo en house-0 y house-20. La puntuación compuesta favorece a Ruta Planificada en house-0, house-10 y house-20 (TC011, TC015, TC019).

Entorno office. En celdas fantasma, supera a Greedy en office-5, office-10 y office-20; pierde en office-0 y office-15. En entropía, gana únicamente en office-15; Greedy domina en el resto. En frames, supera a Greedy solo en office-20 (+482 %). La puntuación compuesta favorece a Ruta Planificada en office-10 y office-20 (TC016, TC020).

El entorno office muestra un comportamiento más desigual que house: Ruta Planificada obtiene la victoria más contundente en frames (office-20, +482 %) pero también registra su peor resultado en ghost cells (office-15, 220 celdas).

4.5.5. Discusión

Los resultados de la estrategia Ruta Planificada revelan una relación no monotónica entre la sofisticación del modelo de costo dinámico y el rendimiento observado. Tres hallazgos centrales estructuran la discusión:

La consciencia del trayecto no reduce las celdas fantasma. A pesar de evaluar el camino completo hacia la frontera, Ruta Planificada genera más celdas fantasma que la estrategia Frontera en **7 de las 10** configuraciones. Las diferencias son especialmente pronunciadas en house-10 (130 vs 0 de Frontera), office-15 (220 vs 24) y house-20 (72 vs 0). El mecanismo subyacente es el siguiente: al penalizar fronteras con rutas concurridas, la estrategia selecciona alternativas con trayectos más largos o más sinuosos. Estas rutas alternativas atraviesan zonas más amplias del mapa, aumentando la probabilidad de que el robot pase por áreas con obstáculos dinámicos en distintos momentos, lo que resulta en una acumulación mayor de celdas fantasma. La evaluación de la ruta resuelve el problema de la congestión en el trayecto directo, pero crea un nuevo problema de exposición acumulada en rutas alternativas.

Ventaja consistente en frames procesados. Comparando directamente con la estrategia Frontera, Ruta Planificada procesa más frames en **8 de las 10** configuraciones, con ventajas que van desde +4 % hasta +50 %. Las rutas seleccionadas, aunque más largas, evitan detenciones y recálculos causados por personas en el trayecto, lo que se traduce en un movimiento más continuo y un mayor throughput del pipeline de visión. Este resultado confirma que la evaluación por ruta sí tiene un efecto positivo sobre la eficiencia de movimiento.

Las victorias en score compuesto no mejoran respecto a Frontera. Ambas estrategias obtienen **5/10 victorias** por puntuación compuesta, aunque en configuraciones distintas. La mejora en frames no compensa la degradación en ghost cells, dado que este último tiene el mayor peso en el score compuesto (40 %). Este resultado ilustra una limitación de diseño: una estrategia que optimiza el trayecto de acceso sin anticipar el estado futuro de las zonas alternativas

puede desplazar el problema de congestión en lugar de resolverlo.

Este análisis motiva directamente la necesidad de la estrategia Predictiva (Sección 4.6), que incorpora predicción de trayectorias para estimar el estado futuro del entorno a lo largo de la ruta planificada, abordando así el problema de exposición acumulada identificado en Ruta Planificada.

4.6. Predictiva: estimación de interferencia con predicción de trayectorias

Esta sección presenta los experimentos de validación para la **estrategia Predictiva**. La estrategia Predictiva extiende la Ruta Planificada incorporando predicción de trayectorias: en lugar de evaluar la posición actual de las personas, estima sus posiciones futuras al momento en que el robot llegará a cada punto de la ruta. El costo dinámico se calcula como el número de personas cuya posición predicha se encontrará dentro de un radio r de algún punto de la ruta planificada:

$$D_{\text{Pred}}(v) = \left|\{p_i : \exists\,(q, t_q) \in \text{ruta_temporal}(v),\ \|q - \hat{p}_i(t_q)\|_2 \leq r\}\right| \tag{4.7}$$

donde $\hat{p}_i(t_q)$ es la posición predicha de la persona i en el instante t_q, estimada a partir del historial de posiciones mediante velocidad promedio:

$$\hat{p}_i(t) = p_i^{\text{actual}} + \bar{v}_i \cdot t \tag{4.8}$$

La predicción lineal con velocidad promedio permite anticipar qué personas cruzarán la ruta futura del robot, lo que en principio reduce la frecuencia con que se seleccionan fronteras hacia zonas de alta actividad dinámica.

4.6.1. Diseño de los experimentos

Los experimentos de validación de la estrategia Predictiva comprenden **10 casos de prueba** (TC021–TC030), correspondientes a las configuraciones house $\times$ {0, 5, 10, 15, 20} y office $\times$ {0, 5, 10, 15, 20} actores, detalladas en la Tabla 4.16. Cada caso se ejecutó con **tres réplicas independientes**; el valor representativo de la estrategia Predictiva en cada configuración es la mediana de las tres réplicas. La línea de base Greedy corresponde a los experimentos G001–G010, ejecutados una vez por configuración en las mismas condiciones (duración 1800 s, $\lambda = 5$, $\mu = 0{,}01$).

La normalización global min-máx de la Ecuación (4.2) se aplicó sobre la unión de valores de Predictiva y Greedy, con los rangos globales detallados en la Tabla 4.17.

4.6.2. Resultados por métrica

La Tabla 4.18 y la Figura 4.15 presentan los resultados de celdas fantasma para cada configuración.

Tabla 4.16: Casos de prueba de validación: estrategia Predictiva y Greedy. Cada caso corresponde a una combinación de entorno y número de actores.

Caso (Predictiva)	**Caso (Greedy)**	**Entorno**	**Actores**	**Réplicas (Predictiva)**
TC021	G001	house	0	V061–V063
TC022	G002	office	0	V064–V066
TC023	G003	house	5	V067–V069
TC024	G004	office	5	V070–V072
TC025	G005	house	10	V073–V075
TC026	G006	office	10	V076–V078
TC027	G007	house	15	V079–V081
TC028	G008	office	15	V082–V084
TC029	G009	house	20	V085–V087
TC030	G010	office	20	V088–V090

Tabla 4.17: Rangos globales de normalización para la comparación Predictiva vs Greedy.

Métrica	**Mínimo**	**Máximo**
Celdas fantasma	0	153
Entropía del mapa	$9{,}42 \times 10^{-6}$	$2{,}06 \times 10^{-4}$
Frames procesados	98	648

Tabla 4.18: Celdas fantasma (valor final) por configuración: Predictiva vs Greedy. Valores en negrita indican la estrategia ganadora. Menor es mejor.

Configuración	**Predictiva (mediana)**	**Greedy**	**% dif.**
house-0	30	**15**	+100 %
office-0	14	**13**	+8 %
house-5	**0**	81	−100 %
office-5	99	**78**	+27 %
house-10	**0**	83	−100 %
office-10	**18**	125	−86 %
house-15	**0**	118	−100 %
office-15	**0**	153	−100 %
house-20	**0**	131	−100 %
office-20	**63**	83	−24 %

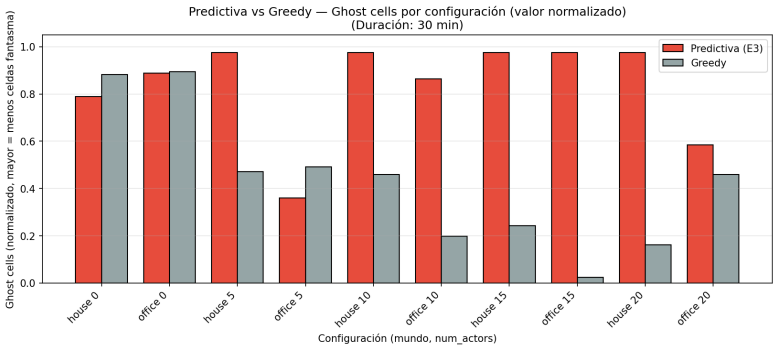

Figura 4.15: Celdas fantasma normalizadas por configuración. Valor normalizado mayor indica menor número de celdas fantasma (mejor precisión del mapa). Predictiva supera a Greedy en 7 de las 10 configuraciones.

La estrategia Predictiva supera a Greedy en celdas fantasma en **7 de las 10** configuraciones. Las tres excepciones corresponden a los escenarios sin actores o con densidad baja (house-0, office-0, office-5), donde la interferencia dinámica es nula o escasa y la predicción de trayectorias no aporta ventaja alguna. En el entorno house, la estrategia Predictiva logra cero celdas fantasma en todas las configuraciones con actores (house-5 a house-20). En office, la ventaja es también consistente a partir de 10 actores, aunque con magnitudes variables: una reducción del 86 % en office-10, eliminación total en office-15 y una reducción del 24 % en office-20.

La Tabla 4.19 y la Figura 4.16 presentan los resultados de entropía del mapa.

Tabla 4.19: Entropía del mapa (valor final) por configuración: Predictiva vs Greedy. Valores en negrita indican la estrategia ganadora. Mayor es mejor.

Configuración	**Predictiva (mediana)**	**Greedy**	**% dif.**
house-0	$1{,}0 \times 10^{-5}$	$\mathbf{1{,}3 \times 10^{-4}}$	−92 %
office-0	$1{,}1 \times 10^{-4}$	$\mathbf{2{,}1 \times 10^{-4}}$	−45 %
house-5	$1{,}1 \times 10^{-4}$	$\mathbf{1{,}7 \times 10^{-4}}$	−32 %
office-5	$8{,}5 \times 10^{-5}$	$\mathbf{1{,}1 \times 10^{-4}}$	−20 %
house-10	$6{,}2 \times 10^{-5}$	$\mathbf{6{,}6 \times 10^{-5}}$	−7 %
office-10	$\mathbf{1{,}4 \times 10^{-4}}$	$1{,}3 \times 10^{-4}$	+12 %
house-15	$\mathbf{7{,}6 \times 10^{-5}}$	$9{,}4 \times 10^{-6}$	+710 %
office-15	$1{,}2 \times 10^{-5}$	$\mathbf{8{,}9 \times 10^{-5}}$	−86 %
house-20	$1{,}0 \times 10^{-5}$	$\mathbf{1{,}9 \times 10^{-4}}$	−95 %
office-20	$5{,}4 \times 10^{-5}$	$\mathbf{1{,}2 \times 10^{-4}}$	−55 %

En entropía del mapa Greedy supera a la estrategia Predictiva en **8 de las 10** configuraciones. Predictiva únicamente supera a Greedy en office-10 (+12 %) y en house-15 (+710 %, caso particular con entropía muy baja de Greedy). Esta

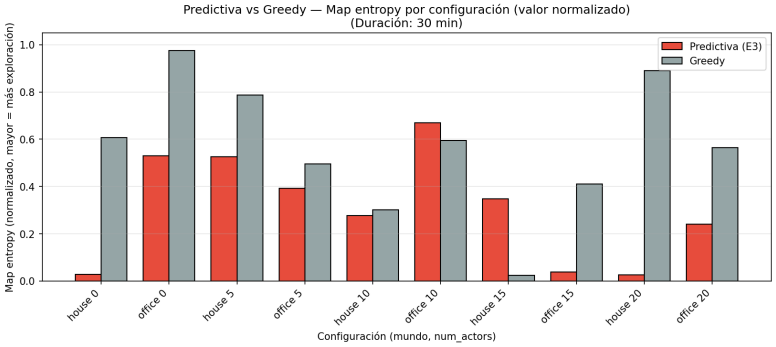

Figura 4.16: Entropía del mapa normalizada por configuración. Valor normalizado mayor indica mayor exploración. Greedy supera a Predictiva en 8 de las 10 configuraciones.

desventaja generalizada en exploración se atribuye al mayor costo computacional de la estrategia Predictiva, detallado en la Sección 4.6.5.

La Tabla 4.20 y la Figura 4.17 presentan los resultados de frames procesados.

Tabla 4.20: Frames totales procesados (valor final acumulado) por configuración: Predictiva vs Greedy. Valores en negrita indican la estrategia ganadora. Mayor es mejor.

Configuración	**Predictiva (mediana)**	**Greedy**	**% dif.**
house-0	**620**	217	+186 %
office-0	**613**	555	+10 %
house-5	449	**577**	−22 %
office-5	523	**648**	−19 %
house-10	419	**454**	−8 %
office-10	**638**	601	+6 %
house-15	340	**597**	−43 %
office-15	509	**607**	−16 %
house-20	**437**	265	+65 %
office-20	**596**	98	+508 %

En frames procesados la estrategia Predictiva supera a Greedy en **5 de las 10** configuraciones. Las ventajas más marcadas se observan en house-0 (+186 %) y en office-20 (+508 %). En los casos con densidad intermedia de actores (house-5, office-5, house-10, house-15, office-15) Greedy procesa más frames, lo que es coherente con su menor tiempo de cómputo por decisión.

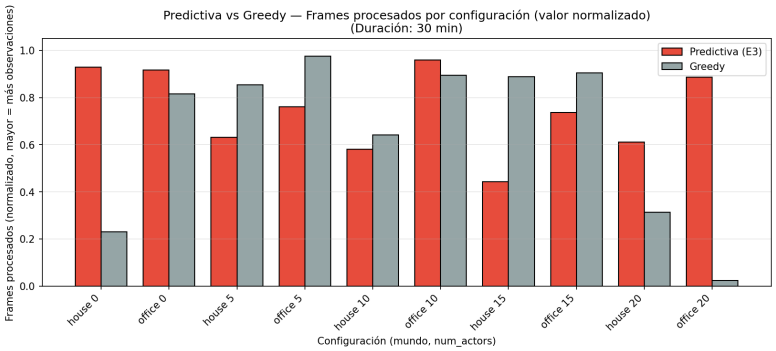

Figura 4.17: Frames procesados normalizados por configuración. Valor normalizado mayor indica mayor throughput del pipeline de visión. Predictiva supera a Greedy en 5 de las 10 configuraciones.

4.6.3. Puntuación compuesta y análisis global

La Figura 4.18 presenta la puntuación compuesta calculada con la Ecuación (4.3) para cada configuración, y la Figura 4.19 resume el recuento de victorias por métrica.

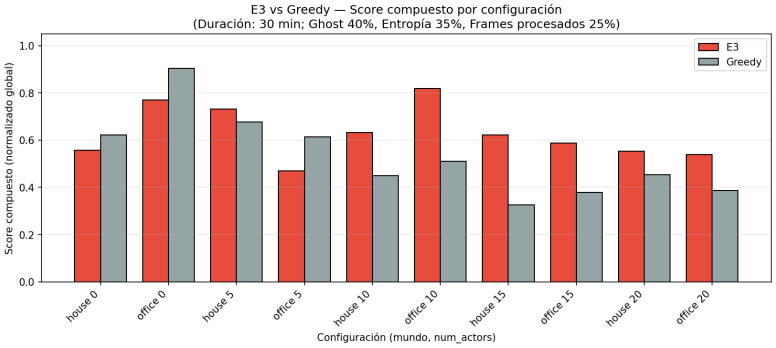

Figura 4.18: Puntuación compuesta por configuración (Predictiva vs Greedy). Pesos: celdas fantasma 40 %, entropía 35 %, frames 25 %. Predictiva supera a Greedy en 7 de las 10 configuraciones.

Por puntuación compuesta, la estrategia Predictiva es la ganadora en **7 de las 10** configuraciones: TC023 (house-5), TC025 (house-10), TC026 (office-10), TC027 (house-15), TC028 (office-15), TC029 (house-20) y TC030 (office-20). En las tres configuraciones restantes (TC021, TC022, TC024, correspondientes a house-0, office-0 y office-5) Greedy obtiene mayor puntuación, en todos los casos sin actores o con densidad muy baja donde Predictiva no dispone de información dinámica relevante para guiar su planificación.

Aplicando el criterio de cuasi-empate ($S_{\text{Pred}} \geq 0{,}9 \cdot S_{\text{Greedy}}$), la estrategia

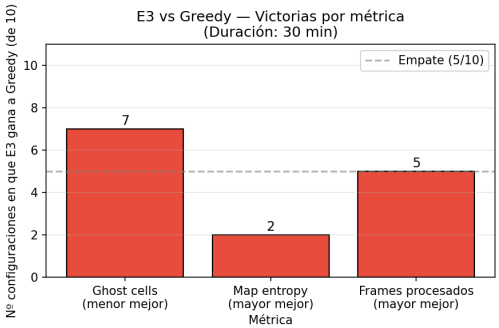

(a) Victorias por métrica individual.

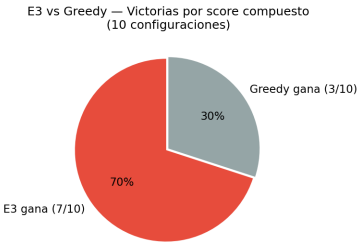

(b) Victorias por puntuación compuesta.

Figura 4.19: Resumen de victorias de la estrategia Predictiva frente a Greedy. Predictiva gana en 7/10 configuraciones por puntuación compuesta.

Predictiva resulta competitiva o mejor en **7 de las 10** configuraciones. Este resultado indica que Predictiva no solo supera a la línea de base en la mayoría de los casos, sino que incluso en las configuraciones que no gana, la diferencia en puntuación compuesta es reducida en la mayor parte de ellas.

4.6.4. Análisis por entorno

Entorno house. En celdas fantasma, Predictiva supera a Greedy en todas las configuraciones con actores (5, 10, 15 y 20) y únicamente pierde en el caso sin actores. En entropía, Predictiva supera a Greedy solo en house-15; en los demás casos Greedy explora más del mapa. En frames procesados, Predictiva supera a Greedy en house-0 y house-20. La puntuación compuesta es favorable a Predictiva en cuatro de las cinco configuraciones de house (TC023, TC025, TC027, TC029).

Entorno office. En celdas fantasma, Predictiva supera a Greedy en las configuraciones con 10, 15 y 20 actores, mientras que pierde con 0 y 5. En entropía, Predictiva supera a Greedy únicamente en office-10. En frames procesados, Predictiva supera a Greedy en office-0, office-10 y con una diferencia muy marcada en office-20 (+508 %). La puntuación compuesta favorece a Predictiva en TC026, TC028 y TC030 (office-10, office-15 y office-20).

En conjunto, los resultados revelan que el beneficio de la estrategia Predictiva se incrementa con la densidad de actores en ambos entornos. La ventaja en precisión de mapa (celdas fantasma) es robusta a partir de densidades de 5 actores en house y 10 actores en office. La ventaja en exploración (entropía) es menos frecuente, lo que se discute en la sección siguiente.

4.6.5. Análisis del costo computacional

La desventaja de la estrategia Predictiva en exploración (entropía del mapa) en los experimentos de 30 minutos motivó el planteamiento de la **hipótesis del costo computacional**: la menor exploración de Predictiva puede deberse en parte a la demora en el cálculo de la utilidad dinámica, que involucra la planificación de la ruta completa hacia cada frontera candidata, el cómputo del tiempo de viaje a cada punto de la ruta y la predicción de posiciones futuras de cada persona detectada. Esta demora reduce el tiempo efectivo de movimiento del robot por ciclo de decisión.

Para contrastar esta hipótesis, se ejecutaron dos experimentos de mayor duración (aproximadamente tres horas) con la configuración de mayor densidad de actores en cada entorno:

- **VH001**: house-20, duración $\approx$ 2,99 h.
- **VH002**: office-20, duración $\approx$ 2,99 h.

La Figura 4.20 muestra la evolución temporal de la entropía del mapa y los frames procesados a lo largo de los experimentos extendidos. La Figura 4.21 compara los valores finales de los experimentos de 30 minutos con los de 3 horas.

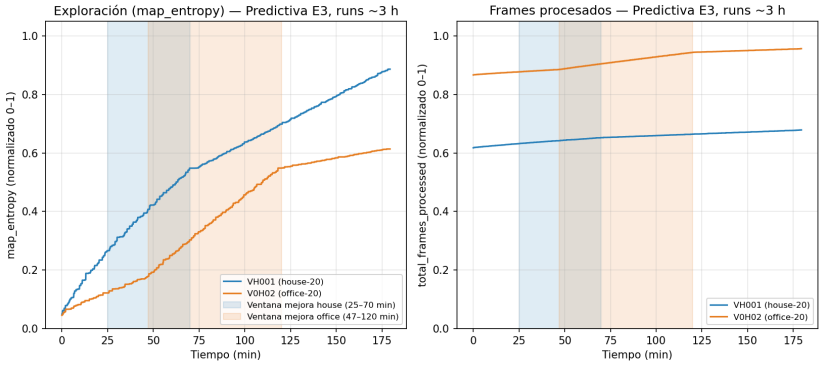

Figura 4.20: Evolución temporal de la entropía del mapa y los frames procesados en los experimentos extendidos (VH001 y VH002, $\approx$ 3 h). Se observa una ventana de crecimiento acelerado entre los 25–70 min en house y entre los 47 min y 2 h en office, seguida de una fase de mejora leve.

Los resultados de los experimentos extendidos se resumen a continuación:

- **house-20 (VH001):** a 30 min, Predictiva registró 437 frames y entropía $9{,}83 \times 10^{-6}$. A 3 h, los valores alcanzaron 3054 frames y entropía $1{,}95 \times 10^{-4}$, superando ampliamente los valores de Greedy a 30 min (265 frames, $1{,}88 \times 10^{-4}$).
- **office-20 (VH002):** a 30 min, Predictiva registró 596 frames y entropía $5{,}41 \times 10^{-5}$. A 3 h, los valores alcanzaron 4304 frames y entropía $1{,}35 \times 10^{-4}$, superando también a Greedy a 30 min (98 frames, $1{,}21 \times 10^{-4}$).

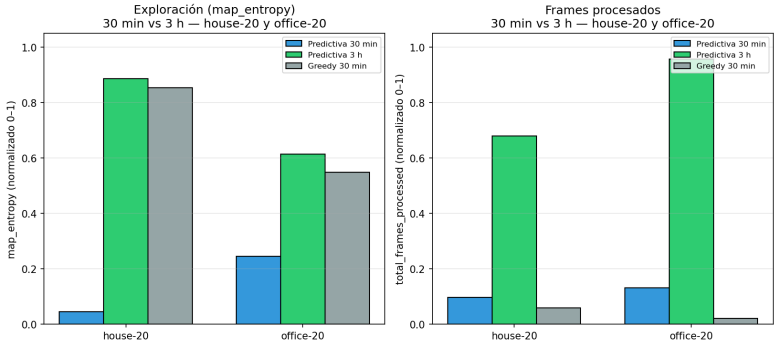

Figura 4.21: Comparación de métricas finales entre los experimentos de validación (30 min) y los experimentos extendidos ($\approx$ 3 h) para las configuraciones house-20 y office-20. Se incluyen los valores de Greedy a 30 min como referencia.

Estos resultados apoyan la hipótesis: dado tiempo suficiente, la estrategia Predictiva recupera y supera la exploración de Greedy en ambos entornos. La ventana de crecimiento acelerado es distinta en cada entorno (25–70 min en house; 47 min–2 h en office), lo que sugiere que la dificultad de recuperación depende de la geometría del entorno y la complejidad de las rutas calculadas. Para que Predictiva exprese su potencial de exploración junto con su ventaja en precisión, se recomienda asignar al menos 1–2 horas de ejecución.

4.6.6. Discusión

Los resultados permiten identificar tres aspectos centrales del comportamiento de la estrategia Predictiva:

Precisión del mapa. La predicción de interferencia es el mecanismo que explica la reducción de celdas fantasma. Al estimar qué personas cruzarán la ruta hacia cada frontera, AlfredZ evita o posterga las fronteras donde la presencia futura de personas generaría ocupaciones transitorias en el mapa. Este efecto es estructural: crece con la densidad de actores y es independiente del entorno, razón por la que se observa en house y office a partir de 5–10 actores. La estrategia Greedy, que selecciona únicamente por distancia, no dispone de este mecanismo y acumula celdas fantasma en proporción a la actividad dinámica del entorno.

Exploración. La desventaja de Predictiva en entropía del mapa en los experimentos de 30 minutos no obedece a decisiones subóptimas de exploración, sino principalmente al mayor costo computacional por ciclo de decisión. Los experimentos extendidos demuestran que, con tiempo suficiente, Predictiva alcanza y supera el nivel de exploración de Greedy. Este hallazgo sugiere que la comparación a 30 minutos subestima el potencial de la estrategia Predictiva en aplicaciones de mayor duración.

El caso house-0 (0 actores) constituye una excepción dentro de este patrón

y requiere una explicación diferente. Con entropía de $1{,}0 \times 10^{-5}$ —el valor más bajo registrado por cualquier estrategia en toda la validación, incluyendo configuraciones con alta densidad de actores— la estrategia Predictiva muestra un comportamiento atípico a pesar de procesar 620 frames, el mayor throughput en esa configuración. En ausencia de actores, el módulo de predicción de trayectorias no tiene personas que modelar y el costo dinámico $D_{\text{Pred}}(v)$ es cero para todas las fronteras candidatas. La utilidad se reduce, por tanto, a la ganancia de información estática menos el costo de trayecto: $U(v) = I(v) - \mu \cdot \ell(v)$. Con este balance, la estrategia tiende a seleccionar repetidamente las fronteras de mayor ganancia de información local —que suelen concentrarse en zonas cercanas ya parcialmente exploradas— sin dispersarse hacia regiones distantes del mapa. El resultado es un alto número de frames procesados desde un área acotada, pero una distribución de celdas conocidas poco diversa que se traduce en entropía baja. En contraste, Greedy navega siempre a la frontera más cercana por distancia euclidiana, lo que produce un patrón de exploración más uniforme en entornos sin personas. Este hallazgo indica que, cuando la densidad de actores es nula, la función de utilidad de la estrategia Predictiva no genera suficiente incentivo para dispersarse geográficamente, lo que limita su capacidad de exploración en ese escenario específico.

Eficiencia. El comportamiento de los frames procesados es heterogéneo: Predictiva supera a Greedy en las configuraciones sin actores y en las de mayor densidad, mientras que Greedy procesa más frames en densidades intermedias. Esta variabilidad refleja la interacción entre el costo computacional adicional de Predictiva y la reducción de interrupciones por colisión con personas que proporciona la predicción de interferencia.

En conjunto, los resultados **validan la estrategia Predictiva** como alternativa superior a Greedy cuando se prioriza la precisión del mapa o cuando el tiempo de exploración disponible es suficiente. La estrategia Greedy resulta preferible únicamente cuando se requiere maximizar la exploración en ventanas de tiempo cortas y la densidad de actores es baja o nula.

4.7. Análisis comparativo de estrategias

En esta sección se presenta una comparación directa de las tres estrategias propuestas —Frontera (Sección 4.4), Ruta Planificada (Sección 4.5) y Predictiva (Sección 4.6)— entre sí y frente a la línea de base Greedy, sobre las mismas 10 configuraciones (entorno × número de actores). El análisis se organiza en tres bloques: resultados desagregados por métrica, puntuación compuesta global y análisis de trade-offs con recomendaciones de uso.

4.7.1. Resultados comparativos por métrica

Las Tablas 4.21, 4.22 y 4.23 presentan los valores finales de cada métrica para las cuatro estrategias. En cada fila se resalta en negrita el mejor valor por

configuración. Para celdas fantasma el mejor valor es el menor; para entropía y frames, el mayor.

Tabla 4.21: Celdas fantasma (valor final, menor es mejor) por configuración y estrategia. En negrita, el mejor valor de cada fila.

Configuración	**Frontera**	**Ruta Plan.**	**Predictiva**	**Greedy**
house-0	16	20	30	**15**
office-0	21	34	14	**13**
house-5	53	59	**0**	81
office-5	92	**68**	99	78
house-10	**0**	130	**0**	83
office-10	105	27	**18**	125
house-15	155	216	**0**	118
office-15	**24**	220	**0**	153
house-20	**0**	72	**0**	131
office-20	**0**	51	63	83

En la Tabla 4.21 se observa que la estrategia Predictiva obtiene el mejor resultado en **7 de las 10** configuraciones en celdas fantasma, logrando cero ghost cells en cinco de ellas. La estrategia Frontera comparte el mejor resultado en house-10 y house-20, y es la única que alcanza cero en office-20. La estrategia Ruta Planificada solo predomina en office-5, y presenta los peores resultados de las tres estrategias propuestas en house-10, house-15 y office-15, donde supera incluso a Greedy en número de ghost cells. Las configuraciones de 0 actores son las únicas en que Greedy registra el menor número de celdas fantasma, lo que es coherente con la ausencia de obstáculos dinámicos que penalicen a las tres estrategias propuestas.

Tabla 4.22: Entropía del mapa (valor final $\times 10^{-4}$, mayor es mejor) por configuración y estrategia. En negrita, el mejor valor de cada fila.

Configuración	**Frontera**	**Ruta Plan.**	**Predictiva**	**Greedy**
house-0	1,43	**1,83**	0,10	1,29
office-0	1,33	1,21	1,10	**2,06**
house-5	0,95	0,55	1,10	**1,67**
office-5	0,78	1,01	0,85	**1,07**
house-10	**1,51**	1,34	0,62	0,66
office-10	**1,49**	0,78	1,40	1,27
house-15	**1,24**	1,22	0,76	0,09
office-15	1,12	**1,19**	0,12	0,89
house-20	0,48	1,11	0,10	**1,88**
office-20	0,12	0,15	0,54	**1,21**

La Tabla 4.22 revela que la estrategia Frontera es la que más frecuentemente

maximiza la entropía del mapa, ganando en **5 de las 10** configuraciones, seguida de Ruta Planificada con 4 y Predictiva con solo 2. Greedy domina en las configuraciones con 0 actores (ambos entornos) y con alta densidad (house-20 y office-20). Este patrón indica que la estrategia Predictiva, al priorizar rutas con menor interferencia dinámica, tiende a concentrar la exploración en zonas ya conocidas, sacrificando la diversidad del mapa. La estrategia Frontera, con su evaluación simple del punto de destino, produce un patrón de exploración más diversificado.

Tabla 4.23: Frames totales procesados (valor final acumulado, mayor es mejor) por configuración y estrategia. En negrita, el mejor valor de cada fila.

Configuración	**Frontera**	**Ruta Plan.**	**Predictiva**	**Greedy**
house-0	364	481	**620**	217
office-0	478	534	**613**	555
house-5	439	471	449	**577**
office-5	444	519	523	**648**
house-10	390	401	419	**454**
office-10	400	499	**638**	601
house-15	356	339	340	**597**
office-15	366	377	509	**607**
house-20	353	**477**	437	265
office-20	379	570	**596**	98

En la Tabla 4.23 se observa que la estrategia Predictiva procesa más frames en **5 de las 10** configuraciones, siendo la de mayor throughput en 0 actores (ambos entornos) y en office-10 y office-20. Greedy domina en densidades de 5 y 15 actores, donde las estrategias propuestas penalizan la selección de fronteras y reducen la frecuencia de desplazamiento. Las tres estrategias propuestas superan ampliamente a Greedy en las configuraciones de 20 actores, donde Greedy sufre interrupciones frecuentes por congestión.

4.7.2. Puntuación compuesta

La Figura 4.22 presenta la puntuación compuesta de las cuatro estrategias en cada configuración, calculada con los pesos establecidos en la Sección 4.3: 40 % celdas fantasma, 35 % entropía del mapa y 25 % frames procesados, sobre normalización global min-máx aplicada a la unión de los valores de las cuatro estrategias.

En las Figuras 4.22 y 4.23 se aprecia que la estrategia Predictiva obtiene la puntuación compuesta más alta en **7 de las 10** configuraciones frente a Greedy, mientras que Frontera y Ruta Planificada ganan en **5 de las 10** cada una. Las Figuras 4.24a y 4.24b resumen este resultado.

La Figura 4.24b pone de manifiesto los perfiles diferenciados de cada estrategia:

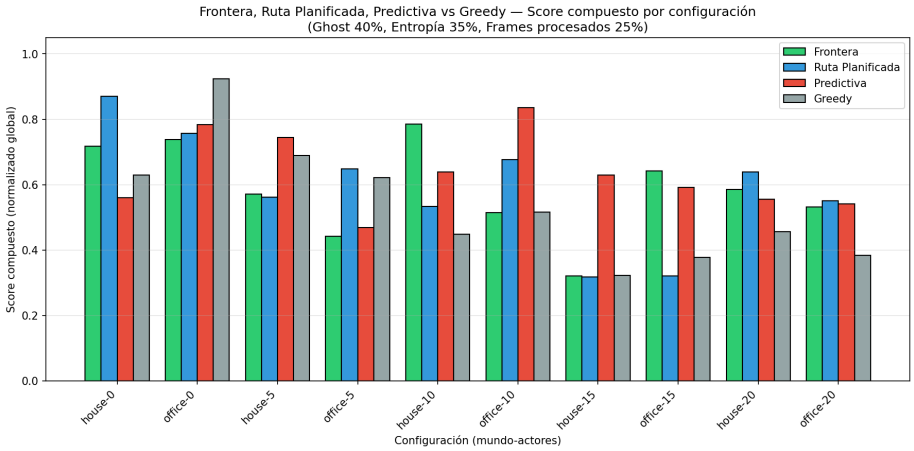

Figura 4.22: Puntuación compuesta de las cuatro estrategias por configuración. Se muestra en qué configuraciones cada estrategia propuesta supera a Greedy.

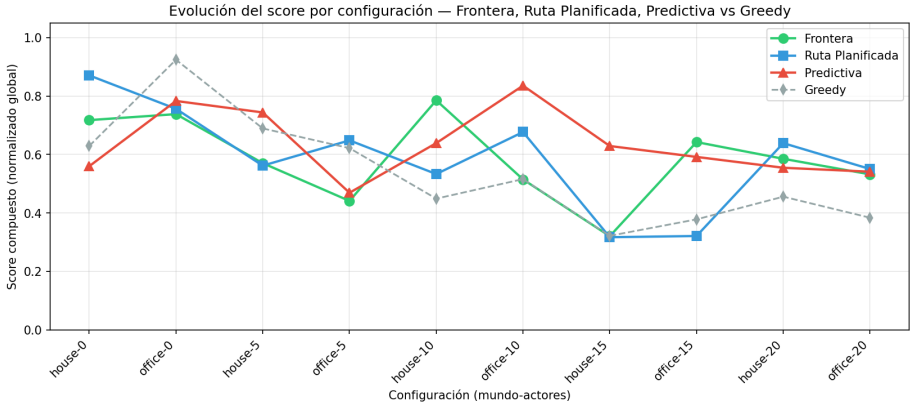

Figura 4.23: Evolución de la puntuación compuesta por configuración (representación en líneas). Permite identificar el comportamiento relativo de las estrategias a lo largo del gradiente de densidad de actores.

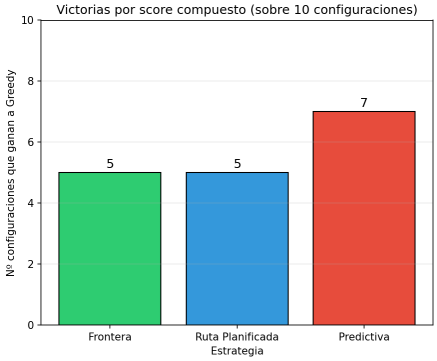

(a) Victorias por estrategia (vs Greedy, score compuesto).

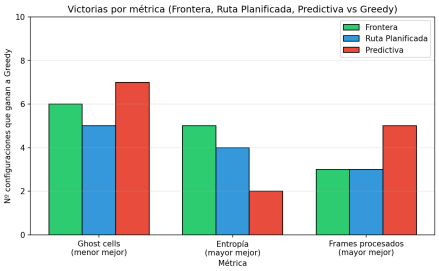

(b) Victorias por métrica individual (vs Greedy).

Figura 4.24: Recuento de victorias de cada estrategia propuesta frente a Greedy, por score compuesto y por métrica individual.

- **Predictiva**: máximo rendimiento en celdas fantasma (7/10) y en frames procesados (5/10); rendimiento mínimo en entropía (2/10).
- **Frontera**: perfil más equilibrado; mejor estrategia en entropía (5/10) y segunda en celdas fantasma (6/10).
- **Ruta Planificada**: menor rendimiento en celdas fantasma (5/10) que Frontera, a pesar de su mayor sofisticación en el modelo de costo dinámico; igual rendimiento en frames (3/10) pero mejores magnitudes en los casos que gana.

La Tabla 4.24 sintetiza, para cada configuración, qué estrategia propuesta obtuvo el mayor score compuesto entre las tres.

Se observa que ninguna estrategia domina en todas las configuraciones: Predictiva lidera en 5 de 10, Frontera en 2 de 10 y Ruta Planificada en 3 de 10. Las únicas dos configuraciones en que ninguna de las tres estrategias supera a Greedy son office-0 y office-5, ambas con baja densidad de actores en el entorno más grande, donde la exploración sin restricciones dinámicas resulta más eficiente.

4.7.3. Trade-offs y recomendaciones de uso

Los resultados permiten identificar tres trade-offs estructurales que caracterizan el comportamiento del sistema:

Precisión vs. exploración. La estrategia Predictiva minimiza las celdas fantasma a costa de reducir la entropía del mapa. Al evitar proactivamente las rutas con mayor interferencia dinámica futura, el robot tiende a regresar a zonas ya conocidas, lo que limita la diversidad de observaciones. La estrategia Frontera, con su evaluación más simple, produce un patrón de exploración más

Tabla 4.24: Estrategia con mayor puntuación compuesta entre Frontera, Ruta Planificada y Predictiva, por configuración. Se indica si esa estrategia además supera a Greedy.

Configuración	Mejor estrategia	Supera a Greedy
house-0	Ruta Planificada	Sí
office-0	Predictiva	No
house-5	Predictiva	Sí
office-5	Ruta Planificada	No
house-10	Frontera	Sí
office-10	Predictiva	Sí
house-15	Predictiva	Sí
office-15	Frontera	Sí
house-20	Ruta Planificada	Sí
office-20	Predictiva	Sí

amplio aunque con mayor riesgo de acumular ghost cells. Este trade-off sugiere que la elección entre Predictiva y Frontera depende de si la prioridad es la precisión del mapa o su cobertura.

Sofisticación del modelo vs. rendimiento observado. La estrategia Ruta Planificada incorpora más información que Frontera —evaluando el trayecto completo— pero obtiene peores resultados en celdas fantasma en 7 de las 10 configuraciones. Esto ilustra que un modelo de costo dinámico más complejo no garantiza mejor rendimiento si no anticipa el estado futuro del entorno. Solo la estrategia Predictiva, que incorpora predicción de trayectorias, logra superar consistentemente a las dos estrategias anteriores en la métrica de mayor peso (celdas fantasma).

Densidad de actores. Las tres estrategias propuestas muestran mayor ventaja sobre Greedy a medida que aumenta la densidad de actores. Con 0 o 5 actores, Greedy es competitivo o superior en la mayoría de configuraciones, especialmente en el entorno office. A partir de 10 actores las estrategias propuestas ganan de forma más consistente, siendo la densidad de 15–20 actores el escenario donde la diferencia es más marcada.

Sobre la base de estos trade-offs, se presenta la Tabla 4.25 como guía de selección de estrategia según el objetivo del sistema.

4.7.4. Conclusión del capítulo

En este capítulo se evaluaron tres estrategias de planificación de próxima vista para el sistema AlfredZ bajo distintas condiciones de densidad de actores dinámicos, comparándolas frente a la línea de base Greedy en los entornos house y office.

Los resultados muestran que la progresión de complejidad de Frontera a Predictiva no produce una mejora lineal en todas las métricas, sino perfiles de

Tabla 4.25: Recomendaciones de selección de estrategia según el objetivo de optimización.

Objetivo principal	**Estrategia recomendada**
Maximizar precisión del mapa (menos ghost cells)	Predictiva
Maximizar exploración (mayor entropía)	Frontera
Maximizar throughput (más frames procesados)	Predictiva
Balance entre las tres métricas	Frontera
Entorno con ≤ 5 actores	Greedy o Frontera
Entorno con ≥ 10 actores	Predictiva

rendimiento diferenciados. La estrategia Predictiva obtiene el mayor número de victorias frente a Greedy por puntuación compuesta (7/10) y es la más efectiva en precisión de mapa y throughput, pero sacrifica exploración. La estrategia Frontera presenta el perfil más equilibrado, con el mejor rendimiento en entropía y una ventaja consistente en precisión a densidades medias y altas. La estrategia Ruta Planificada, a pesar de su mayor información sobre el entorno, no supera a Frontera en la métrica de mayor peso y presenta los peores casos individuales de ghost cells entre las tres estrategias propuestas.

Si bien los resultados validan el enfoque general de planificación con costo dinámico frente a Greedy, también señalan que el modelo de predicción de trayectorias es el componente que genera el mayor impacto en precisión del mapa. Hace falta más experimentación para establecer el comportamiento del sistema en entornos de mayor complejidad estructural o con patrones de movimiento de actores más heterogéneos, lo que se plantea como una línea de trabajo futuro en el Capítulo 5.

Capítulo 5

Conclusiones y Trabajo Futuro

En este capítulo se evalúan los resultados alcanzados y dificultades encontradas, se establece lo que se planteó hacer y lo que se hizo realmente, cuáles fueron los aportes, se muestran posibles extensiones al trabajo, se realiza una autocrítica de lo que se hizo y lo que faltó (por problemas de tiempo, recursos, cómo se puede continuar, qué cosas hacer, prioridades, etc.) y se incluye información sobre la gestión del proyecto, si aplica.

Referencias

Cohen, P. J. (1963). The independence of the continuum hypothesis. *Proceedings of the National Academy of Sciences*, *50*(6), 1143–1148.

Holleis, P., Wagner, M., y Koolwaaij, J. (2010). Studying mobile context-aware social services in the wild. En *Proc. of the 6th nordic conf. on human-computer interaction* (pp. 207–216). New York, NY: ACM.

NASA. (2015). *Pluto: The 'other' red planet.* https://www.nasa.gov/nh/pluto-the-other-red-planet. (Accessed: 2018-12-06)

Placed, J. A., Strader, J., Carrillo, H., Atanasov, N., Indelman, V., Carlone, L., y Castellanos, J. A. (2023). A survey on active simultaneous localization and mapping: State of the art and new frontiers. *IEEE Transactions on Robotics*, *39*(3), 1686–1705. doi: 10.1109/TRO.2023.3248510

R Core Team. (2018). R: A language and environment for statistical computing [Manual de software informático]. Vienna, Austria.

Susskind, L., y Hrabovsky, G. (2014). *Classical mechanics: the theoretical minimum.* New York, NY: Penguin Random House.

Topiwala, A., y Inani, P. (2018). *Frontier based exploration for autonomous robot.* Technical Report, Maryland Robotics Center, University of Maryland.

Wang, C.-C., Thorpe, C., Hebert, M., Thrun, S., y Durrant-Whyte, H. (2007). Simultaneous localization, mapping and moving object tracking. *The International Journal of Robotics Research*, *26*(9), 889–916. doi: 10.1177/0278364907081165

Anexo 1

Los anexos contienen información adjunta al proyecto pero que no es fundamental para entender el trabajo. Por ejemplo, determinado material de los antecedentes o la implementación, que en el cuerpo principal del informe se encuentre resumido, aquí puede presentarse de forma completa. En caso de proyectos de desarrollo de software, se debería incluir un manual de usuario.

.1. Sección del Anexo

Los anexos pueden tener secciones.