Mapeo 3D autónomo con un robot de servicio AlfredZ

Informe de Proyecto de Grado presentado por

Enzo Borges, Christian Deleon, Román Alvarez

en cumplimiento parcial de los requerimientos para la graduación de la carrera de Ingeniería en Computación de Facultad de Ingeniería de la Universidad de la República

Supervisores

Federico Andrade
Facundo Benavides

Montevideo, 22 de marzo de 2026

Mapeo 3D autónomo con un robot de servicio AlfredZ
por Enzo Borges, Christian Deleon, Román Alvarez tiene licencia
CC Atribución 4.0.

Agradecimientos

Agradecer, siempre es bueno agradecer.

Resumen

El resumen (200-500 palabras) debe dar una idea completa de todo el proyecto, mencionando claramente los formalismos, técnicas, herramientas y lenguas utilizados. No debe limitarse a describir el problema abordado, sino que debe describir la solución del problema, con una evaluación de la misma. No debe incluir referencias bibliográficas ni referencias a otras partes del informe. Tampoco debe utilizar acrónimos sin explicar su significado.

Palabras clave: Template, Proyectos de Grado, Computación

Índice general

1. Introducción **1**

2. Revisión de antecedentes **3**
2.1. Primera Sección 3
2.2. Segunda Sección 3
2.2.1. La Subsección 3

3. Parte Central **5**

4. Experimentación **7**
4.1. Configuración experimental 7
4.1.1. Entornos de simulación 7
4.1.2. Configuración del sistema 8
4.1.3. Métricas de evaluación 8
4.1.4. Puntuación compuesta 9
4.2. Estrategia de comparación: Greedy 9
4.3. Etapa de calibración 10
4.3.1. Diseño de los experimentos de calibración 10
4.3.2. Resultados por estrategia 11
4.3.3. Análisis global de hiperparámetros 13
4.3.4. Selección de parámetros para la validación 13
4.4. Frontera: utilidad dinámica por centro de frontera 15
4.4.1. Diseño de los experimentos 16
4.4.2. Resultados por métrica 17
4.4.3. Puntuación compuesta y análisis global 20
4.4.4. Análisis por entorno 21
4.4.5. Discusión 21
4.5. Ruta Planificada: utilidad dinámica por ruta planificada 22
4.6. Predictiva: estimación de interferencia con predicción de trayectorias 22
4.6.1. Diseño de los experimentos 23
4.6.2. Resultados por métrica 24
4.6.3. Puntuación compuesta y análisis global 27
4.6.4. Análisis por entorno 28

4.6.5. Análisis del costo computacional 28
4.6.6. Discusión 30
4.7. Análisis comparativo de estrategias 31

5. Conclusiones y Trabajo Futuro **33**

Referencias **35**

Anexo 1 **37**
.1. Sección del Anexo 37

Capítulo 1

Introducción

Aquí se motiva el trabajo, se plantea y define el problema, se deja claro cuáles son los objetivos (general del proyecto, si correspondiese o si está inmerso en un proyecto de mayor alcance, y los específicos), se plantean los resultados esperados, se establecen resumidamente las conclusiones y se describe la organización general del documento.

Este y los siguientes capítulos pueden incluir referencias; algunos ejemplos pueden ser (Cohen, 1963), (Susskind y Hrabovsky, 2014), (Holleis, Wagner, y Koolwaaij, 2010), (R Core Team, 2018) y (NASA, 2015). Se sugiere citar usando el formato APA.

Capítulo 2

Revisión de antecedentes

Revisión de antecedentes (ya sea productos, procesos, publicaciones, etc., a nivel académico o comercial) en el tema del trabajo. Puede incluir además (si es necesario) una breve introducción a los conceptos necesarios para entender el trabajo.

2.1. Primera Sección

Los capítulos pueden incluir secciones como esta, que además pueden hacer referencia a otras secciones, como por ejemplo a la Sección 2.2.

2.2. Segunda Sección

Esta sección además tiene una subsección.

2.2.1. La Subsección

Esta es la subsección.

Capítulo 3

Parte Central

La parte central del trabajo refiere a lo que es producción propia o aporte del proyecto de grado, incluyendo las decisiones tomadas. Por ejemplo, puede incluir los requerimientos, el análisis y el diseño de la solución. Si el proyecto tiene una implementación, debe describirse en términos de decisiones tomadas en ese sentido. Los detalles de programación se dejan para los anexos.

Se pueden incluir figuras y tablas en el documento; las mismas deben estar referenciadas en el texto. Por ejemplo, la Figura 3.1 muestra los logos de Facultad de Ingeniería y de la Universidad de la República, mientras que la Tabla 3.1 tiene números aleatorios.

Figura 3.1: Logos de FIng y UdelaR

Col1	Col2	Col2	Col3
1	970	67	941
2	668	845	141
3	800	383	464
4	143	683	502

Tabla 3.1: Tabla con datos

Capítulo 4

Experimentación

Este capítulo describe los experimentos realizados para validar las estrategias de planificación de siguiente mejor vista (*Next Best View*, NBV) implementadas en AlfredZ. El objetivo es comparar el comportamiento de cada estrategia frente a una línea de base Greedy en entornos de simulación con distintas densidades de actores dinámicos, evaluando métricas de precisión de mapa, exploración y eficiencia de procesado.

Los experimentos se organizaron en tres etapas: una etapa de calibración para determinar los hiperparámetros óptimos del sistema, seguida de tres etapas de validación, una por cada estrategia de utilidad dinámica propuesta. En cada etapa de validación se compara la estrategia correspondiente con la misma línea de base Greedy ejecutada en condiciones idénticas.

4.1. Configuración experimental

4.1.1. Entornos de simulación

Los experimentos se ejecutaron en simulación mediante Gazebo con dos entornos de interior de diferente distribución espacial:

- **house**: planta residencial compacta, con pasillos estrechos y múltiples habitaciones de tamaño reducido. Su geometría favorece la acumulación de obstáculos dinámicos en zonas de paso.
- **office**: planta de bloque de oficinas de mayor superficie, con espacios abiertos y áreas de circulación más amplias. La distribución genera rutas de exploración más largas entre fronteras.

En cada entorno se ejecutaron experimentos con cinco niveles de densidad de actores dinámicos: 0, 5, 10, 15 y 20 personas simuladas con trayectorias autónomas. La combinación de dos entornos y cinco niveles de densidad produce **10 configuraciones** de prueba por estrategia.

Todos los experimentos tuvieron una duración de **1800 segundos** (30 minutos). AlfredZ contó con los mismos parámetros de navegación, percepción y mapa en todas las ejecuciones, con la única variación en la estrategia de planificación NBV.

4.1.2. Configuración del sistema

El sistema AlfredZ integra los siguientes componentes en cada experimento:

- **RTAB-Map**: construcción y actualización del mapa de ocupación 3D.
- **Nav2**: planificación de rutas y ejecución de la navegación autónoma.
- **YOLO**: detección de personas en tiempo real a partir de imágenes de la cámara del robot.
- **Planificador NBV semántico**: selección de la frontera destino según la estrategia configurada, implementada en el nodo `ExplorerNode`.

La función de utilidad empleada por las estrategias dinámicas sigue la forma general:

$$U(v) = IG_{\text{estático}}(v) - \lambda \cdot D(v) - \mu \cdot C_{\text{trayecto}}(v) \tag{4.1}$$

donde $IG_{\text{estático}}(v)$ representa la ganancia de información estática de la frontera v, $D(v)$ es el costo dinámico calculado según la estrategia activa, $C_{\text{trayecto}}(v)$ es el costo de la ruta planificada hacia v, y λ y μ son hiperparámetros que ponderan cada componente. Los valores óptimos $\lambda = 5$ y $\mu = 0{,}01$ se determinaron en la etapa de calibración descrita en la Sección 4.3.

4.1.3. Métricas de evaluación

El desempeño de cada estrategia se evaluó mediante tres métricas registradas al final de cada experimento:

- **Celdas fantasma (*ghost cells*)**: número de celdas del mapa de ocupación que aparecen marcadas como ocupadas en el instante final pero que estaban libres en los tres mapas anteriores del historial. Esta métrica cuantifica la presencia de falsos positivos de ocupación generados por obstáculos dinámicos que ya no se encuentran en esa posición. Un valor **menor** indica mayor precisión del mapa.
- **Entropía del mapa (*map entropy*)**: entropía de Shannon calculada sobre las celdas conocidas del mapa de ocupación final, definida como $H = -\sum p_i \log_2(p_i)$, donde $p_i = v_i/100$ para cada celda con valor $v_i \geq 0$. Cuantifica la variedad de estados observados en el mapa y se emplea como indicador del grado de exploración alcanzado. Un valor **mayor** indica mayor exploración.

- **Frames totales procesados (*total frames processed*)**: contador acumulativo del número de observaciones de cámara procesadas por el *pipeline* de visión durante toda la ejecución del experimento. Se utiliza como indicador de eficiencia y throughput del sistema perceptivo. Un valor **mayor** indica mayor cantidad de observaciones procesadas.

4.1.4. Puntuación compuesta

Para facilitar la comparación global entre estrategias se empleó una puntuación compuesta que agrega las tres métricas en un único valor escalar. Previamente, cada métrica se normalizó mediante normalización min-máx global sobre el conjunto de valores de ambas estrategias comparadas:

$$\hat{x} = \frac{x - x_{\text{mín}}}{x_{\text{máx}} - x_{\text{mín}}} \tag{4.2}$$

Dado que en celdas fantasma un valor menor corresponde a mejor desempeño, se invierte la normalización de esta métrica ($1 - \hat{x}_{\text{ghost}}$). La puntuación compuesta se calcula entonces como:

$$S = 0{,}40 \cdot (1 - \hat{x}_{\text{ghost}}) + 0{,}35 \cdot \hat{x}_{\text{entropy}} + 0{,}25 \cdot \hat{x}_{\text{frames}} \tag{4.3}$$

Los pesos asignados reflejan las prioridades del proyecto: la precisión del mapa (celdas fantasma) recibe el mayor peso (40 %), seguida de la exploración (entropía, 35 %) y la eficiencia de procesado (frames, 25 %).

La estrategia con mayor puntuación compuesta en una configuración dada se considera ganadora en esa configuración. Se utiliza adicionalmente el criterio de "cuasi-empate o mejor" cuando la puntuación compuesta de una estrategia alcanza al menos el 90 % de la puntuación de la estrategia contraria.

4.2. Estrategia de comparación: Greedy

La estrategia Greedy actúa como línea de base de referencia. En cada ciclo de decisión, selecciona la frontera inexplorada más cercana al robot según distancia euclídea, sin considerar factores dinámicos ni calcular rutas completas. Su función de selección se reduce a:

$$v^* = \arg\min_{v \in \mathcal{F}} \|p_{\text{robot}} - c_v\|_2 \tag{4.4}$$

donde $\mathcal{F}$ es el conjunto de fronteras disponibles y c_v es el centroide de la frontera v.

Esta estrategia maximiza el tiempo efectivo de movimiento al minimizar el costo computacional por decisión: no planifica rutas, no estima interferencia dinámica ni predice posiciones futuras de personas. La ausencia de modelado dinámico implica que el robot puede dirigirse repetidamente a zonas con alta actividad de personas, incrementando la probabilidad de generar celdas fantasma en el mapa. Los experimentos Greedy se identifican con los casos G001 a

G010, correspondientes a las mismas 10 configuraciones (entorno × número de actores) que las estrategias de validación.

4.3. Etapa de calibración

La función de utilidad (4.1) incorpora dos hiperparámetros —λ y μ— cuyos valores determinan en qué medida el planificador NBV penaliza la interferencia dinámica y el costo de trayecto, respectivamente. Valores inadecuados pueden llevar al robot a ignorar la presencia de personas (λ demasiado bajo) o a seleccionar fronteras subóptimas por sobre-penalizar rutas largas (μ demasiado alto). La etapa de calibración tuvo como objetivo identificar empíricamente la combinación de hiperparámetros que maximiza el desempeño global del sistema, medido con la puntuación compuesta definida en la Sección 4.1.4.

4.3.1. Diseño de los experimentos de calibración

Se evaluaron todas las combinaciones del producto cartesiano $\lambda \in \{0, 1, 5\}$ y $\mu \in \{0{,}01;\ 0{,}5;\ 2{,}0\}$, aplicadas sobre las tres estrategias de utilidad dinámica, lo que da lugar a $3 \times 3 \times 3 = 27$ experimentos (S001–S027). La Tabla 4.1 detalla la asignación de identificadores a cada combinación.

Tabla 4.1: Grid de experimentos de calibración. Cada celda contiene el identificador del experimento correspondiente. S015 no produjo datos válidos y fue excluido del análisis.

λ	μ	**Frontera**	**Ruta Planificada**	**Predictiva**
0	0,01	S001	S010	S019
0	0,5	S002	S011	S020
0	2,0	S003	S012	S021
1	0,01	S004	S013	S022
1	0,5	S005	S014	S023
1	2,0	S006	S015*	S024
5	0,01	S007	S016	S025
5	0,5	S008	S017	S026
5	2,0	S009	S018	S027

* Experimento fallido; excluido del análisis.

Todos los experimentos se ejecutaron en el entorno **house** con **5 actores** dinámicos y una duración de **1800 segundos**. Se realizó una única ejecución por combinación. La elección de un entorno y densidad de actores fijos permite aislar el efecto de los hiperparámetros de otras variables del sistema.

4.3.2. Resultados por estrategia

Las Tablas 4.2, 4.3 y 4.4 presentan el ranking completo de los experimentos de calibración para cada estrategia, ordenados por puntuación compuesta descendente. La Figura 4.1 compara los scores de cada estrategia en función de la combinación de hiperparámetros.

Tabla 4.2: Ranking de experimentos de calibración — Vecindad. Mejor combinación: $\lambda = 0$, $\mu = 0{,}01$ (S001).

Pos.	**Exp**	λ	μ	**Ghost**	**Entropía**	**Frames**	**Score**
1	**S001**	0	0,01	30	$1{,}64 \times 10^{-4}$	217	**0,8772**
2	S006	1	2,0	0	$1{,}55 \times 10^{-4}$	158	0,8091
3	S005	1	0,5	9	$1{,}48 \times 10^{-4}$	179	0,7708
4	S008	5	0,5	31	$1{,}34 \times 10^{-4}$	198	0,6874
5	S007	5	0,01	108	$1{,}50 \times 10^{-4}$	217	0,6666
6	S002	0	0,5	119	$1{,}49 \times 10^{-4}$	210	0,6584
7	S004	1	0,01	41	$1{,}22 \times 10^{-4}$	179	0,6520
8	S003	0	2,0	347	$1{,}94 \times 10^{-4}$	174	0,5717
9	S009	5	2,0	79	$7{,}5 \times 10^{-5}$	143	0,3089

Tabla 4.3: Ranking de experimentos de calibración — Ruta Planificada. Mejor combinación: $\lambda = 5$, $\mu = 0{,}01$ (S016). S015 excluido por fallo.

Pos.	**Exp**	λ	μ	**Ghost**	**Entropía**	**Frames**	**Score**
1	**S016**	5	0,01	70	$2{,}30 \times 10^{-4}$	601	**0,8436**
2	S011	0	0,5	29	$1{,}83 \times 10^{-4}$	421	0,8329
3	S012	0	2,0	0	$1{,}47 \times 10^{-4}$	390	0,8217
4	S010	0	0,01	0	$1{,}23 \times 10^{-4}$	380	0,7830
5	S013	1	0,01	67	$9{,}6 \times 10^{-5}$	355	0,5697
6	S014	1	0,5	126	$1{,}52 \times 10^{-4}$	440	0,5584
7	S018	5	2,0	179	$1{,}02 \times 10^{-4}$	342	0,2920
8	S017	5	0,5	156	$4{,}2 \times 10^{-5}$	307	0,0514

Los óptimos por estrategia no coinciden: Frontera alcanza su mejor resultado con $\lambda = 0$, $\mu = 0{,}01$ (S001, score 0,8772); Ruta Planificada con $\lambda = 5$, $\mu = 0{,}01$ (S016, score 0,8436); y Predictiva con $\lambda = 0$, $\mu = 0{,}5$ (S020, score 0,8953). Esta divergencia indica que la respuesta óptima a los hiperparámetros depende del mecanismo de cálculo del costo dinámico de cada estrategia, y motiva un análisis global para identificar la combinación más robusta.

Tabla 4.4: Ranking de experimentos de calibración — Predictiva. Mejor combinación: $\lambda = 0$, $\mu = 0{,}5$ (S020).

Pos.	**Exp**	λ	μ	**Ghost**	**Entropía**	**Frames**	**Score**
1	**S020**	0	0,5	56	$2{,}13 \times 10^{-4}$	530	**0,8953**
2	S025	5	0,01	35	$1{,}74 \times 10^{-4}$	500	0,8418
3	S019	0	0,01	0	$1{,}33 \times 10^{-4}$	460	0,7888
4	S023	1	0,5	11	$1{,}18 \times 10^{-4}$	470	0,7644
5	S021	0	2,0	35	$1{,}24 \times 10^{-4}$	450	0,7177
6	S027	5	2,0	56	$1{,}07 \times 10^{-4}$	420	0,6146
7	S024	1	2,0	4	$5{,}5 \times 10^{-5}$	410	0,5943
8	S026	5	0,5	214	$1{,}65 \times 10^{-4}$	490	0,4937
9	S022	1	0,01	99	$7{,}1 \times 10^{-5}$	380	0,2504

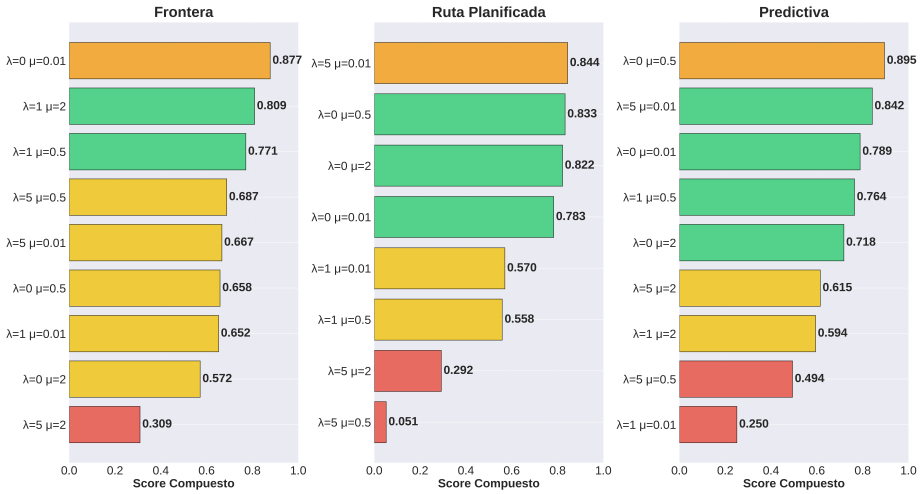

Figura 4.1: Score compuesto por experimento, agrupado por estrategia. Cada barra corresponde a una combinación (λ, μ). Se observa que los óptimos por estrategia corresponden a combinaciones distintas.

4.3.3. Análisis global de hiperparámetros

Para identificar la combinación de hiperparámetros que ofrece el mejor rendimiento promedio con independencia de la estrategia utilizada, se calculó el score promedio de cada par (λ, μ) sobre los tres experimentos correspondientes (uno por estrategia). La Tabla 4.5 presenta los resultados ordenados por score promedio descendente, y la Figura 4.2 los visualiza.

Tabla 4.5: Score promedio por combinación (λ, μ) considerando las tres estrategias. La combinación $\lambda = 5$, $\mu = 0{,}01$ ocupa el primer lugar.

Pos.	λ	μ	**Score prom.**	**Score máx.**	**Score mín.**
1	5	0,01	**0,7897**	0,8780	0,6810
2	0	0,5	0,7882	0,8640	0,6707
3	0	0,01	0,7812	0,8425	0,7502
4	1	0,5	0,7282	0,7891	0,6605
5	1	2,0	0,7030	0,8167	0,5892
6	0	2,0	0,6715	0,7918	0,5167
7	1	0,01	0,5521	0,7007	0,3399
8	5	0,5	0,5397	0,7280	0,2986
9	5	2,0	0,5276	0,6280	0,4770

Las Figuras 4.3 y 4.4 muestran el efecto individual de cada hiperparámetro promediando sobre todos los valores del otro y sobre las tres estrategias.

El análisis individual revela que $\lambda = 0$ obtiene el mayor promedio por separado (0,7470 frente a 0,6559 de $\lambda = 1$ y 0,6190 de $\lambda = 5$), mientras que $\mu = 0{,}01$ es el mejor valor de μ (0,7077 frente a 0,6854 y 0,6254). Sin embargo, el ranking por combinaciones posiciona $\lambda = 5$, $\mu = 0{,}01$ en primer lugar porque esa pareja específica produce resultados más equilibrados entre estrategias que $\lambda = 0$ con cualquier valor de μ.

4.3.4. Selección de parámetros para la validación

La selección de $\lambda = 5$, $\mu = 0{,}01$ como configuración fija para todas las etapas de validación se fundamenta en tres criterios complementarios:

1. **Necesidad de activar el costo dinámico.** Con $\lambda = 0$ la función de utilidad (4.1) se reduce a $U(v) = IG_{\text{estático}}(v) - \mu \cdot C_{\text{trayecto}}(v)$, haciendo que el término $D(v)$ de cada estrategia quede anulado. Bajo esa condición, las tres estrategias se comportan de forma idéntica y la comparación entre ellas pierde sentido. El uso de $\lambda > 0$ es, por tanto, una condición necesaria para que el experimento de validación sea informativo.

2. **Mejor rendimiento promedio entre combinaciones con $\lambda > 0$.** Entre las combinaciones que satisfacen $\lambda > 0$, la pareja $\lambda = 5$, $\mu = 0{,}01$ alcanza el mayor score promedio global (0,7897), superando a $\lambda = 1$, $\mu = 0{,}5$ (0,7282) y a las demás alternativas con $\lambda \in \{1, 5\}$.

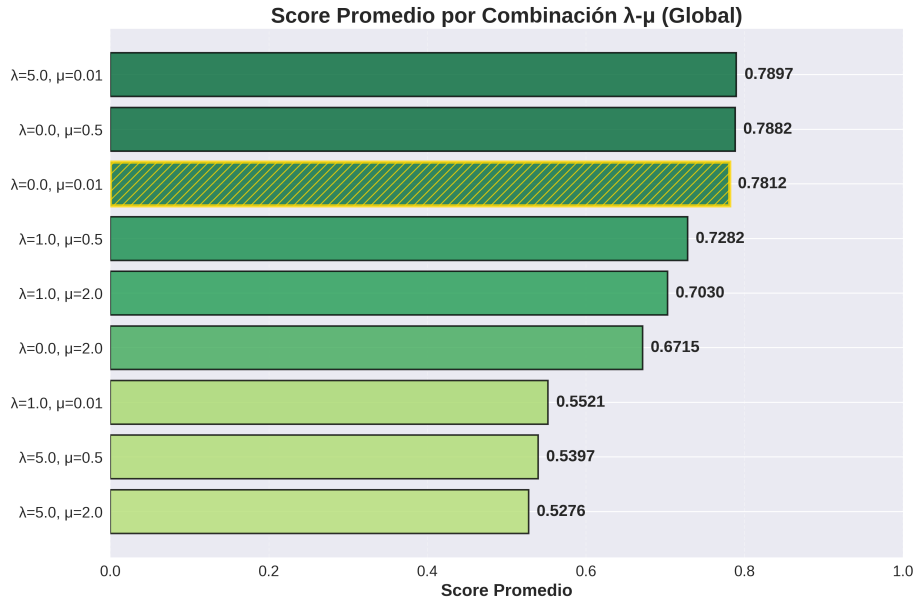

Figura 4.2: Score promedio por combinación (λ, μ) sobre las tres estrategias. Las tres primeras combinaciones tienen scores promedio similares (0,779–0,790), con $\lambda = 5$, $\mu = 0{,}01$ a la cabeza.

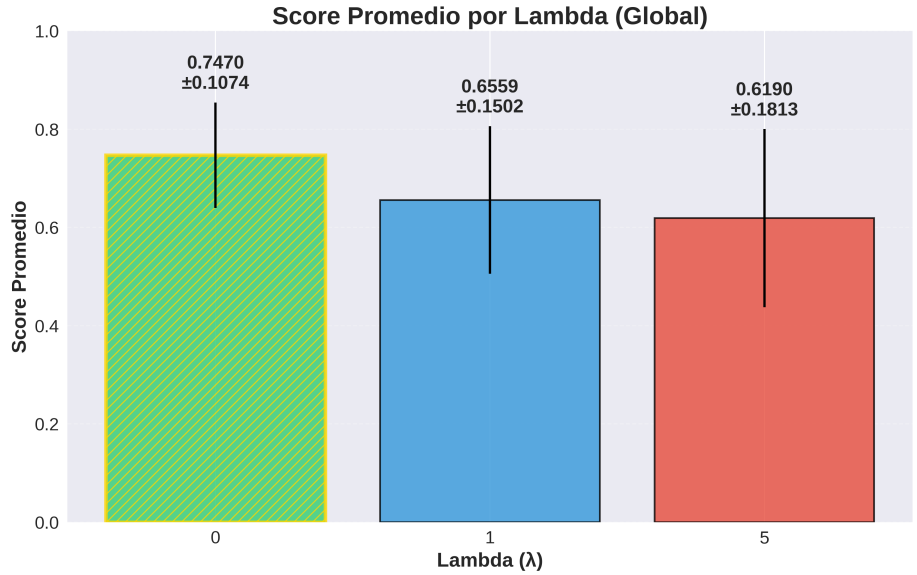

Figura 4.3: Efecto de λ sobre la puntuación compuesta promedio (promediando sobre todos los valores de μ y las tres estrategias). $\lambda = 0$ obtiene el mayor promedio individual (0,7470), mientras que $\lambda = 5$ presenta el menor (0,6190).

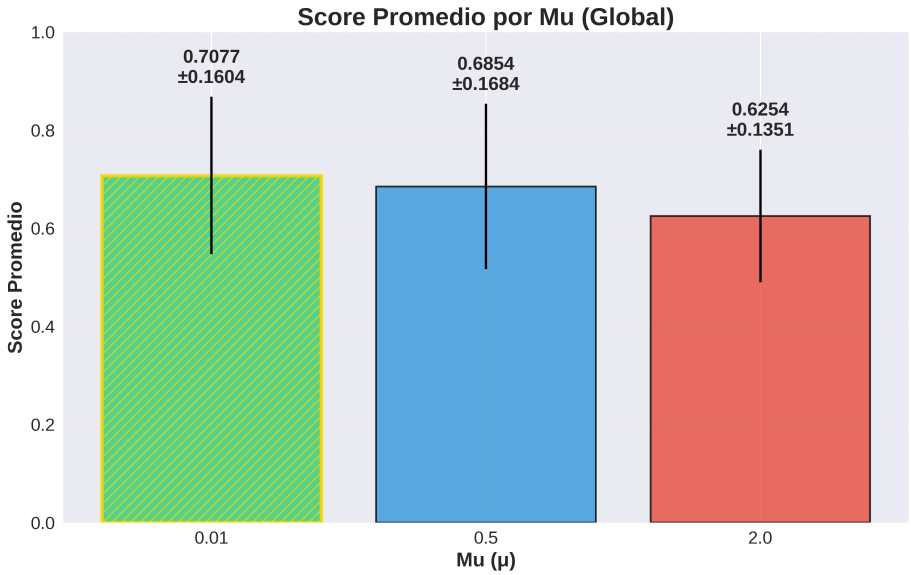

Figura 4.4: Efecto de μ sobre la puntuación compuesta promedio (promediando sobre todos los valores de λ y las tres estrategias). $\mu = 0{,}01$ es consistentemente el mejor valor en todas las estrategias (0,7077).

3. **Comparación equitativa entre estrategias.** Los óptimos individuales de cada estrategia difieren entre sí; utilizar parámetros distintos por estrategia introduciría un confusor que impediría atribuir diferencias de rendimiento a la estrategia en sí. La adopción de un único par de hiperparámetros garantiza que las comparaciones de la etapa de validación midan exclusivamente el efecto del mecanismo de cálculo del costo dinámico.

Con base en estos criterios, todos los experimentos de validación descritos en las secciones siguientes se ejecutaron con $\lambda = 5$ y $\mu = 0{,}01$.

4.4. Frontera: utilidad dinámica por centro de frontera

La estrategia **Frontera** calcula el costo dinámico $D(v)$ contando el número de personas detectadas dentro de un radio fijo r alrededor del centroide de la frontera v:

$$D_{\text{Front}}(v) = \left|\{p_i : \|c_v - p_i\|_2 \leq r\}\right| \tag{4.5}$$

La evaluación se realiza en el punto de *destino*, sin considerar el camino que el robot debe recorrer para llegar. Esta simplicidad implica un costo computacional bajo pero también una limitación estructural: el robot puede seleccionar

fronteras cuyo entorno inmediato está libre de personas, pero cuyo trayecto de acceso atraviesa zonas concurridas.

4.4.1. Diseño de los experimentos

Los experimentos de validación de la estrategia Frontera comprenden **10 casos de prueba** (TC001–TC010) con las mismas configuraciones de entorno y densidad de actores que el resto de las etapas de validación, detalladas en la Tabla 4.6. Cada caso se ejecutó con **tres réplicas independientes** (V001–V030); el valor representativo de Frontera en cada configuración es la mediana de las tres réplicas. La línea de base Greedy corresponde a los experimentos G001–G010, ejecutados bajo las mismas condiciones ($\lambda = 5$, $\mu = 0{,}01$, duración 1800 s).

Tabla 4.6: Casos de prueba de validación: estrategia Frontera y Greedy.

Caso (Frontera)	Caso (Greedy)	Entorno	Actores	Réplicas (Frontera)
TC001	G001	house	0	V001–V003
TC002	G002	office	0	V004–V006
TC003	G003	house	5	V007–V009
TC004	G004	office	5	V010–V012
TC005	G005	house	10	V013–V015
TC006	G006	office	10	V016–V018
TC007	G007	house	15	V019–V021
TC008	G008	office	15	V022–V024
TC009	G009	house	20	V025–V027
TC010	G010	office	20	V028–V030

La normalización global min-máx se aplicó sobre la unión de valores de Frontera y Greedy, con los rangos detallados en la Tabla 4.7.

Tabla 4.7: Rangos globales de normalización para la comparación Frontera vs Greedy.

Métrica	Mínimo	Máximo
Celdas fantasma	0	155
Entropía del mapa	$9{,}42 \times 10^{-6}$	$2{,}06 \times 10^{-4}$
Frames procesados	98	648

El máximo de celdas fantasma (155) corresponde al experimento TC007 (house-15) de la propia estrategia Frontera, lo que constituye un resultado relevante que se discute en la Sección 4.4.5.

4.4.2. Resultados por métrica

La Tabla 4.8 y la Figura 4.5 presentan los resultados de celdas fantasma por configuración.

Tabla 4.8: Celdas fantasma (valor final) por configuración: Frontera vs Greedy. Valores en negrita indican la estrategia ganadora. Menor es mejor.

Configuración	Frontera (mediana)	Greedy	% dif.
house-0	16	**15**	+7 %
office-0	21	**13**	+62 %
house-5	**53**	81	−35 %
office-5	92	**78**	+18 %
house-10	**0**	83	−100 %
office-10	**105**	125	−16 %
house-15	155	**118**	+31 %
office-15	**24**	153	−84 %
house-20	**0**	131	−100 %
office-20	**0**	83	−100 %

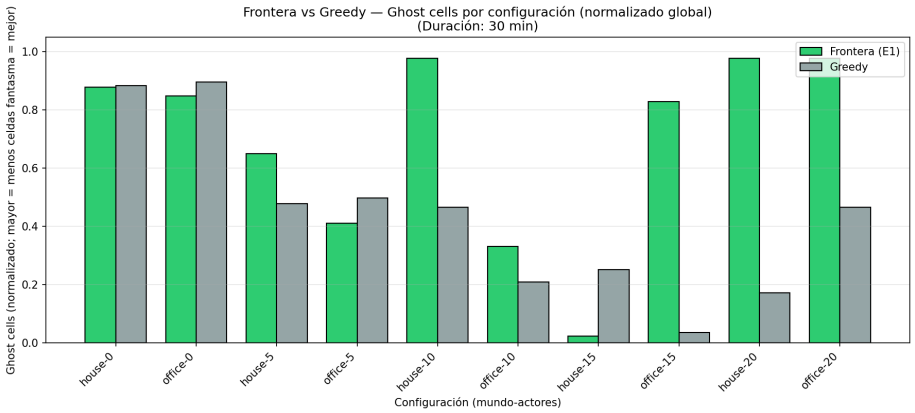

Figura 4.5: Celdas fantasma normalizadas por configuración. Valor normalizado mayor indica menor número de celdas fantasma (mejor precisión del mapa). Frontera supera a Greedy en 6 de las 10 configuraciones.

La estrategia Frontera supera a Greedy en celdas fantasma en **6 de las 10** configuraciones. Las victorias se concentran en configuraciones con densidad media-alta de actores (10, 15 y 20), donde la estrategia logra cero celdas fantasma en house-10, house-20 y office-20, y reducciones del 84 % en office-15. La excepción más destacada es TC007 (house-15), donde Frontera acumula 155 celdas fantasma frente a 118 de Greedy, el peor resultado individual de toda la

estrategia y el máximo global del conjunto de normalización; este caso se analiza en la Sección 4.4.5.

La Tabla 4.9 y la Figura 4.6 presentan los resultados de entropía del mapa.

Tabla 4.9: Entropía del mapa (valor final) por configuración: Frontera vs Greedy. Valores en negrita indican la estrategia ganadora. Mayor es mejor.

Configuración	**Frontera (mediana)**	**Greedy**	**% dif.**
house-0	$\mathbf{1{,}43 \times 10^{-4}}$	$1{,}29 \times 10^{-4}$	+10 %
office-0	$1{,}33 \times 10^{-4}$	$\mathbf{2{,}06 \times 10^{-4}}$	−36 %
house-5	$9{,}5 \times 10^{-5}$	$\mathbf{1{,}67 \times 10^{-4}}$	−43 %
office-5	$7{,}8 \times 10^{-5}$	$\mathbf{1{,}07 \times 10^{-4}}$	−27 %
house-10	$\mathbf{1{,}51 \times 10^{-4}}$	$6{,}6 \times 10^{-5}$	+127 %
office-10	$\mathbf{1{,}49 \times 10^{-4}}$	$1{,}27 \times 10^{-4}$	+17 %
house-15	$\mathbf{1{,}24 \times 10^{-4}}$	$9{,}4 \times 10^{-6}$	+1213 %
office-15	$\mathbf{1{,}12 \times 10^{-4}}$	$8{,}9 \times 10^{-5}$	+26 %
house-20	$4{,}8 \times 10^{-5}$	$\mathbf{1{,}88 \times 10^{-4}}$	−74 %
office-20	$1{,}2 \times 10^{-5}$	$\mathbf{1{,}21 \times 10^{-4}}$	−90 %

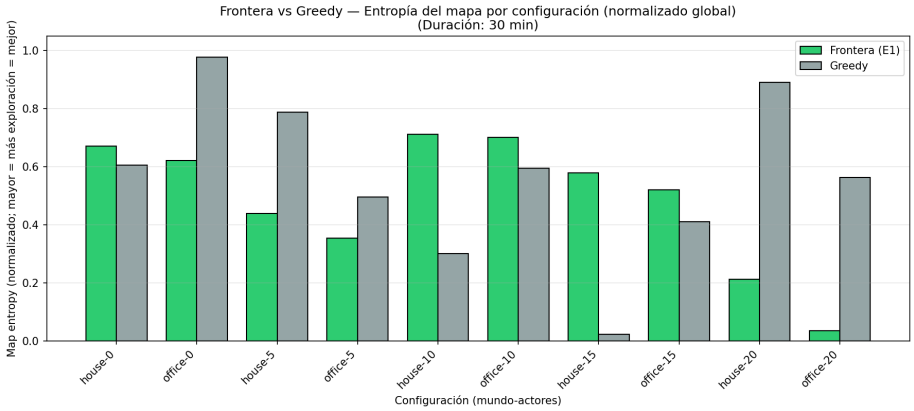

Figura 4.6: Entropía del mapa normalizada por configuración. Valor normalizado mayor indica mayor exploración. Frontera supera a Greedy en 5 de las 10 configuraciones.

En entropía del mapa Frontera supera a Greedy en **5 de las 10** configuraciones, resultado superior al esperado para una estrategia que solo evalúa el punto de destino. Las victorias se concentran en densidades medias (10 y 15 actores en ambos entornos) y en house-0. En contraste, Greedy domina con claridad en densidad baja (office-0, house-5, office-5) y alta (house-20, office-20), donde la penalización de fronteras por presencia de personas en el destino desorienta la exploración.

Tabla 4.10: Frames totales procesados (valor final acumulado) por configuración: Frontera vs Greedy. Valores en negrita indican la estrategia ganadora. Mayor es mejor.

Configuración	**Frontera (mediana)**	**Greedy**	**% dif.**
house-0	**364**	217	+68 %
office-0	478	**555**	−14 %
house-5	439	**577**	−24 %
office-5	444	**648**	−31 %
house-10	390	**454**	−14 %
office-10	400	**601**	−33 %
house-15	356	**597**	−40 %
office-15	366	**607**	−40 %
house-20	**353**	265	+33 %
office-20	**379**	98	+287 %

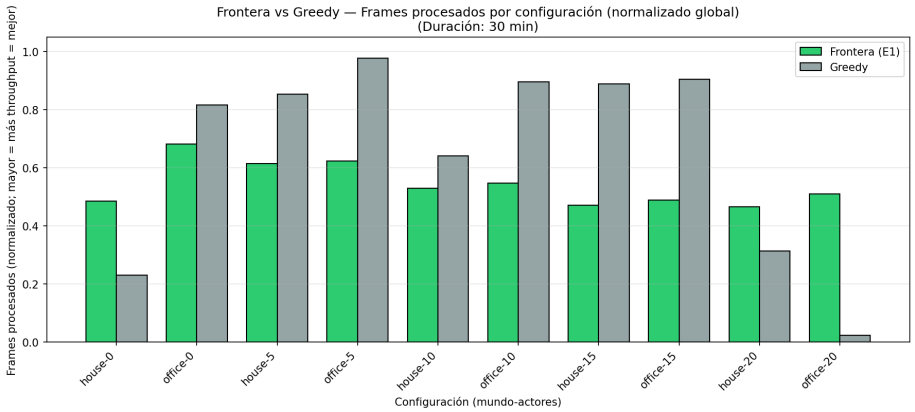

Figura 4.7: Frames procesados normalizados por configuración. Valor normalizado mayor indica mayor throughput del pipeline de visión. Frontera supera a Greedy en 3 de las 10 configuraciones.

La Tabla 4.10 y la Figura 4.7 presentan los resultados de frames procesados.

En frames procesados Frontera supera a Greedy únicamente en **3 de las 10** configuraciones: house-0 (+68 %), house-20 (+33 %) y office-20 (+287 %). En las siete configuraciones restantes —todas de densidad baja a media— Greedy procesa significativamente más frames, con diferencias del −14 % al −40 %. El patrón de victoria en los extremos de densidad (0 y 20 actores) se discute en la Sección 4.4.5.

4.4.3. Puntuación compuesta y análisis global

Las Figuras 4.8 y 4.9 resumen los resultados por puntuación compuesta.

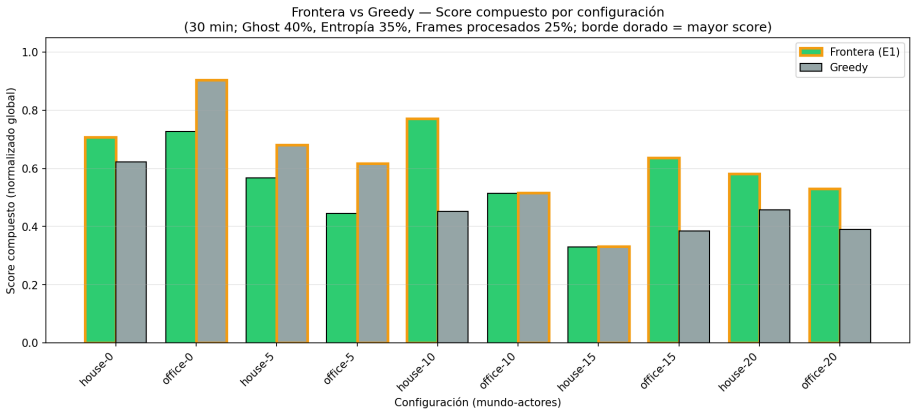

Figura 4.8: Puntuación compuesta por configuración (Frontera vs Greedy). Pesos: celdas fantasma 40 %, entropía 35 %, frames 25 %. Frontera supera a Greedy en 5 de las 10 configuraciones.

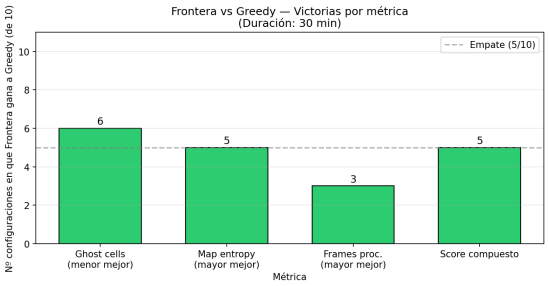

(a) Victorias por métrica individual.

(b) Victorias por puntuación compuesta.

Figura 4.9: Resumen de victorias de la estrategia Frontera frente a Greedy.

Por puntuación compuesta, la estrategia Frontera es ganadora en **5 de las 10** configuraciones: TC001 (house-0), TC005 (house-10), TC008 (office-15), TC009

(house-20) y TC010 (office-20). En las cinco configuraciones restantes Greedy obtiene mayor puntuación; cuatro de ellas corresponden a office-0, house-5, office-5 y office-10, y la quinta a house-15, donde Frontera registra su peor resultado en ghost cells.

Aplicando el criterio de cuasi-empate ($S_{\text{Front}} \geq 0{,}9 \cdot S_{\text{Greedy}}$), Frontera resulta competitiva o mejor en **7 de las 10** configuraciones, lo que indica que incluso en los casos en que Greedy supera a Frontera, la diferencia en puntuación compuesta es reducida en la mayoría de ellos.

4.4.4. Análisis por entorno

Entorno house. En celdas fantasma, Frontera supera a Greedy en house-5, house-10 y house-20, pierde en house-0 por un margen mínimo (16 vs 15) y registra su peor caso en house-15 (155 vs 118). En entropía, Frontera gana en house-0, house-10 y house-15, y pierde en house-5 y house-20. En frames, solo supera a Greedy en house-0 y house-20. La puntuación compuesta favorece a Frontera en TC001, TC005 y TC009 (house-0, house-10 y house-20).

Entorno office. En celdas fantasma, Frontera supera a Greedy en office-10, office-15 y office-20, y pierde en office-0 y office-5. En entropía, gana en office-10 y office-15, y pierde en office-0, office-5 y office-20. En frames, solo supera a Greedy en office-20 (+287 %). La puntuación compuesta favorece a Frontera en TC008 y TC010 (office-15 y office-20).

En conjunto, el beneficio de la estrategia Frontera aumenta con la densidad de actores en ambos entornos, con la excepción de house-15 que constituye un caso anómalo. Las configuraciones con 20 actores muestran las ventajas más consistentes tanto en ghost cells como en frames procesados.

4.4.5. Discusión

Los resultados permiten identificar tres aspectos centrales del comportamiento de la estrategia Frontera:

Precisión del mapa. La evaluación de personas en el entorno inmediato del centro de la frontera es efectiva para reducir ghost cells en la mayoría de las configuraciones con actores, especialmente a densidades de 10 o más. Sin embargo, la estrategia ignora el trayecto de acceso: el robot puede seleccionar una frontera libre de personas pero atravesar zonas concurridas durante el camino, generando ghost cells en el recorrido. Este mecanismo explica tanto las victorias parciales como las pérdidas en configuraciones de densidad media donde las personas se concentran en los pasillos de acceso más que en las propias fronteras.

La anomalía de house-15. El caso TC007 (house-15) presenta el peor resultado de toda la estrategia: 155 celdas fantasma frente a 118 de Greedy. Con 15 actores en el entorno compacto de house, la alta densidad de personas cerca de múltiples fronteras candidatas puede provocar que la estrategia descarte sistemáticamente las fronteras más accesibles en favor de alternativas más lejanas que, al momento de llegar, ya se encuentran igualmente ocupadas. Este efecto

de degradación por sobrepenalización es propio de estrategias que evalúan solo el punto de destino sin anticipar el estado futuro.

Frames procesados y densidad extrema. El patrón de victorias en frames a 0 y 20 actores responde a mecanismos distintos. Con 0 actores, la ausencia de personas elimina cualquier penalización dinámica y Frontera puede orientar su exploración hacia fronteras que maximizan el tiempo de observación activa. Con 20 actores, evitar las zonas más congestionadas permite al robot mantener un desplazamiento más fluido con menos interrupciones, procesando más frames en el mismo tiempo. En densidades intermedias (5–15 actores), la penalización de fronteras reduce la eficiencia de movimiento sin ofrecer un beneficio proporcional en frames.

En conjunto, los resultados validan la estrategia Frontera como alternativa competitiva a Greedy cuando se prioriza la precisión del mapa a densidades medias y altas, con la salvedad de que su comportamiento es menos predecible en configuraciones específicas donde la distribución espacial de los actores interactúa negativamente con el mecanismo de evaluación por centro de frontera.

4.5. Ruta Planificada: utilidad dinámica por ruta planificada

[SCAFFOLDING — Esta sección presenta los experimentos de validación para la estrategia Ruta Planificada, que calcula el costo dinámico $D(v)$ contando el número de personas detectadas dentro de un radio r de cualquier punto de la ruta planificada hacia la frontera v:

$$D_{\text{Ruta}}(v) = \left|\{p_i : \exists\, q \in \text{ruta}(v),\ \|q - p_i\|_2 \leq r\}\right|$$

A diferencia de la estrategia Frontera, la estrategia Ruta Planificada evalúa la interferencia a lo largo de todo el camino que recorrerá el robot, en lugar de solo en el entorno inmediato del destino final. Los casos de prueba son TC011–TC020, con tres réplicas por caso (V031–V060). Los hallazgos principales son: Ruta Planificada supera a Greedy en celdas fantasma en 5/10 configuraciones, en entropía en 4/10 y en frames en 3/10; por puntuación compuesta, Ruta Planificada es competitiva o mejor en 5/10 configuraciones. — Completar con análisis detallado, tablas y figuras de Ruta Planificada vs Greedy.]

4.6. Predictiva: estimación de interferencia con predicción de trayectorias

Esta sección presenta los experimentos de validación para la **estrategia Predictiva**. La estrategia Predictiva extiende la Ruta Planificada incorporando predicción de trayectorias: en lugar de evaluar la posición actual de las personas, estima sus posiciones futuras al momento en que el robot llegará a cada punto de

la ruta. El costo dinámico se calcula como el número de personas cuya posición predicha se encontrará dentro de un radio r de algún punto de la ruta planificada:

$$D_{\text{Pred}}(v) = \left|\{p_i : \exists\,(q, t_q) \in \text{ruta_temporal}(v),\ \|q - \hat{p}_i(t_q)\|_2 \leq r\}\right| \tag{4.6}$$

donde $\hat{p}_i(t_q)$ es la posición predicha de la persona i en el instante t_q, estimada a partir del historial de posiciones mediante velocidad promedio:

$$\hat{p}_i(t) = p_i^{\text{actual}} + \bar{v}_i \cdot t \tag{4.7}$$

La predicción lineal con velocidad promedio permite anticipar qué personas cruzarán la ruta futura del robot, lo que en principio reduce la frecuencia con que se seleccionan fronteras hacia zonas de alta actividad dinámica.

4.6.1. Diseño de los experimentos

Los experimentos de validación de la estrategia Predictiva comprenden **10 casos de prueba** (TC021–TC030), correspondientes a las configuraciones house × {0, 5, 10, 15, 20} y office × {0, 5, 10, 15, 20} actores, detalladas en la Tabla 4.11. Cada caso se ejecutó con **tres réplicas independientes**; el valor representativo de la estrategia Predictiva en cada configuración es la mediana de las tres réplicas. La línea de base Greedy corresponde a los experimentos G001–G010, ejecutados una vez por configuración en las mismas condiciones (duración 1800 s, $\lambda = 5$, $\mu = 0{,}01$).

Tabla 4.11: Casos de prueba de validación: estrategia Predictiva y Greedy. Cada caso corresponde a una combinación de entorno y número de actores.

Caso (Predictiva)	Caso (Greedy)	Entorno	Actores	Réplicas (Predictiva)
TC021	G001	house	0	V061–V063
TC022	G002	office	0	V064–V066
TC023	G003	house	5	V067–V069
TC024	G004	office	5	V070–V072
TC025	G005	house	10	V073–V075
TC026	G006	office	10	V076–V078
TC027	G007	house	15	V079–V081
TC028	G008	office	15	V082–V084
TC029	G009	house	20	V085–V087
TC030	G010	office	20	V088–V090

La normalización global min-máx de la Ecuación (4.2) se aplicó sobre la unión de valores de Predictiva y Greedy, con los rangos globales detallados en la Tabla 4.12.

Tabla 4.12: Rangos globales de normalización para la comparación Predictiva vs Greedy.

Métrica	**Mínimo**	**Máximo**
Celdas fantasma	0	153
Entropía del mapa	$9{,}42 \times 10^{-6}$	$2{,}06 \times 10^{-4}$
Frames procesados	98	648

4.6.2. Resultados por métrica

La Tabla 4.13 y la Figura 4.10 presentan los resultados de celdas fantasma para cada configuración.

Tabla 4.13: Celdas fantasma (valor final) por configuración: Predictiva vs Greedy. Valores en negrita indican la estrategia ganadora. Menor es mejor.

Configuración	**Predictiva (mediana)**	**Greedy**	**% dif.**
house-0	30	**15**	+100 %
office-0	14	**13**	+8 %
house-5	**0**	81	−100 %
office-5	99	**78**	+27 %
house-10	**0**	83	−100 %
office-10	**18**	125	−86 %
house-15	**0**	118	−100 %
office-15	**0**	153	−100 %
house-20	**0**	131	−100 %
office-20	**63**	83	−24 %

La estrategia Predictiva supera a Greedy en celdas fantasma en **7 de las 10** configuraciones. Las tres excepciones corresponden a los escenarios sin actores o con densidad baja (house-0, office-0, office-5), donde la interferencia dinámica es nula o escasa y la predicción de trayectorias no aporta ventaja alguna. En el entorno house, la estrategia Predictiva logra cero celdas fantasma en todas las configuraciones con actores (house-5 a house-20). En office, la ventaja es también consistente a partir de 10 actores, aunque con magnitudes variables: una reducción del 86 % en office-10, eliminación total en office-15 y una reducción del 24 % en office-20.

La Tabla 4.14 y la Figura 4.11 presentan los resultados de entropía del mapa.

En entropía del mapa Greedy supera a la estrategia Predictiva en **8 de las 10** configuraciones. Predictiva únicamente supera a Greedy en office-10 (+12 %) y en house-15 (+710 %, caso particular con entropía muy baja de Greedy). Esta desventaja generalizada en exploración se atribuye al mayor costo computacional de la estrategia Predictiva, detallado en la Sección 4.6.5.

La Tabla 4.15 y la Figura 4.12 presentan los resultados de frames procesados.

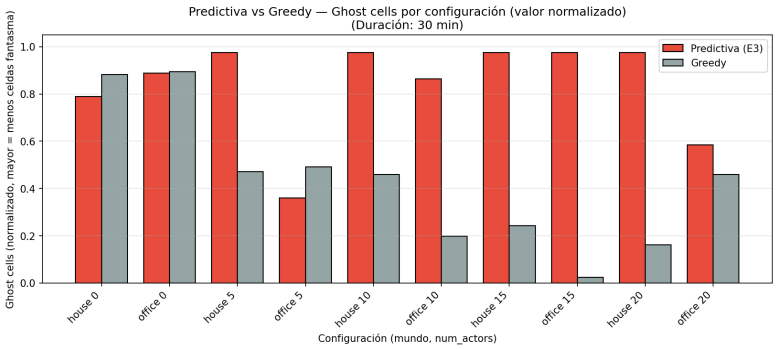

Figura 4.10: Celdas fantasma normalizadas por configuración. Valor normalizado mayor indica menor número de celdas fantasma (mejor precisión del mapa). Predictiva supera a Greedy en 7 de las 10 configuraciones.

Tabla 4.14: Entropía del mapa (valor final) por configuración: Predictiva vs Greedy. Valores en negrita indican la estrategia ganadora. Mayor es mejor.

Configuración	**Predictiva (mediana)**	**Greedy**	**% dif.**
house-0	$1{,}0 \times 10^{-5}$	$\mathbf{1{,}3 \times 10^{-4}}$	$-92\,\%$
office-0	$1{,}1 \times 10^{-4}$	$\mathbf{2{,}1 \times 10^{-4}}$	$-45\,\%$
house-5	$1{,}1 \times 10^{-4}$	$\mathbf{1{,}7 \times 10^{-4}}$	$-32\,\%$
office-5	$8{,}5 \times 10^{-5}$	$\mathbf{1{,}1 \times 10^{-4}}$	$-20\,\%$
house-10	$6{,}2 \times 10^{-5}$	$\mathbf{6{,}6 \times 10^{-5}}$	$-7\,\%$
office-10	$\mathbf{1{,}4 \times 10^{-4}}$	$1{,}3 \times 10^{-4}$	$+12\,\%$
house-15	$\mathbf{7{,}6 \times 10^{-5}}$	$9{,}4 \times 10^{-6}$	$+710\,\%$
office-15	$1{,}2 \times 10^{-5}$	$\mathbf{8{,}9 \times 10^{-5}}$	$-86\,\%$
house-20	$1{,}0 \times 10^{-5}$	$\mathbf{1{,}9 \times 10^{-4}}$	$-95\,\%$
office-20	$5{,}4 \times 10^{-5}$	$\mathbf{1{,}2 \times 10^{-4}}$	$-55\,\%$

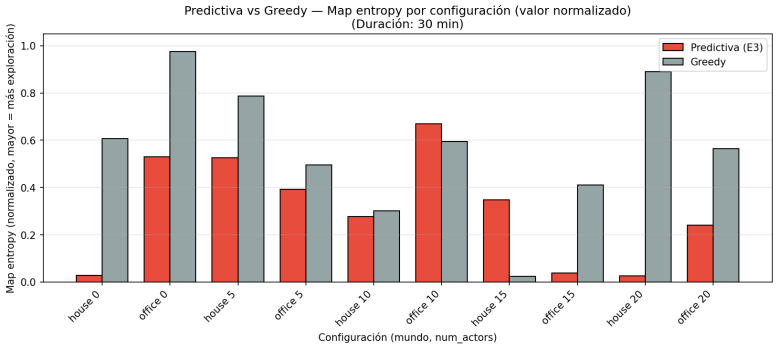

Figura 4.11: Entropía del mapa normalizada por configuración. Valor normalizado mayor indica mayor exploración. Greedy supera a Predictiva en 8 de las 10 configuraciones.

Tabla 4.15: Frames totales procesados (valor final acumulado) por configuración: Predictiva vs Greedy. Valores en negrita indican la estrategia ganadora. Mayor es mejor.

Configuración	**Predictiva (mediana)**	**Greedy**	**% dif.**
house-0	**620**	217	+186 %
office-0	**613**	555	+10 %
house-5	449	**577**	−22 %
office-5	523	**648**	−19 %
house-10	419	**454**	−8 %
office-10	**638**	601	+6 %
house-15	340	**597**	−43 %
office-15	509	**607**	−16 %
house-20	**437**	265	+65 %
office-20	**596**	98	+508 %

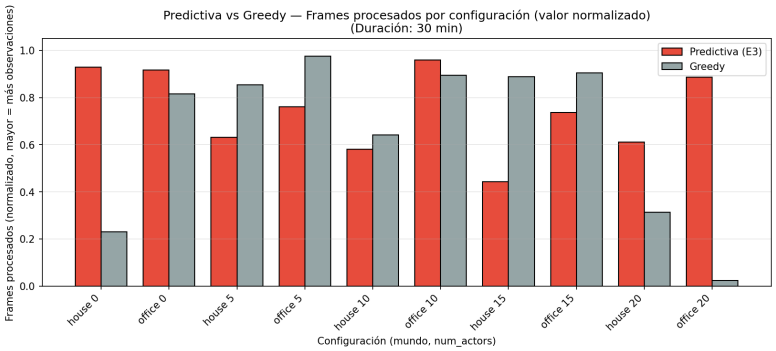

Figura 4.12: Frames procesados normalizados por configuración. Valor normalizado mayor indica mayor throughput del pipeline de visión. Predictiva supera a Greedy en 5 de las 10 configuraciones.

En frames procesados la estrategia Predictiva supera a Greedy en **5 de las 10** configuraciones. Las ventajas más marcadas se observan en house-0 (+186 %) y en office-20 (+508 %). En los casos con densidad intermedia de actores (house-5, office-5, house-10, house-15, office-15) Greedy procesa más frames, lo que es coherente con su menor tiempo de cómputo por decisión.

4.6.3. Puntuación compuesta y análisis global

La Figura 4.13 presenta la puntuación compuesta calculada con la Ecuación (4.3) para cada configuración, y la Figura 4.14 resume el recuento de victorias por métrica.

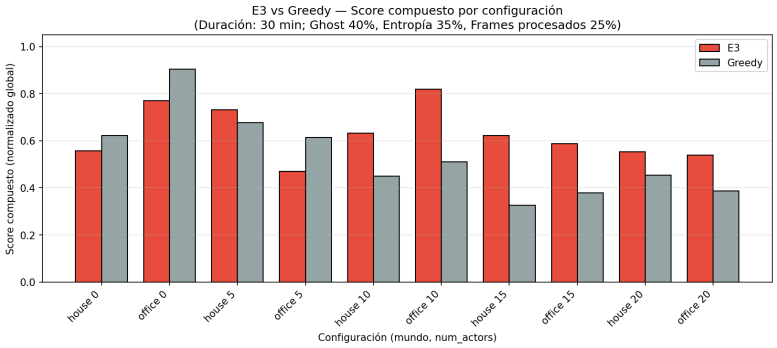

Figura 4.13: Puntuación compuesta por configuración (Predictiva vs Greedy). Pesos: celdas fantasma 40 %, entropía 35 %, frames 25 %. Predictiva supera a Greedy en 7 de las 10 configuraciones.

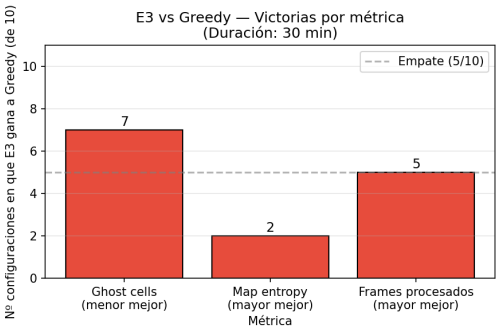

(a) Victorias por métrica individual.

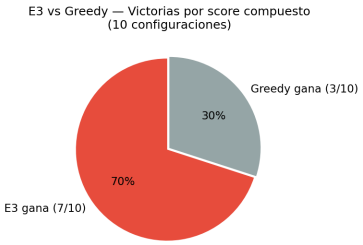

(b) Victorias por puntuación compuesta.

Figura 4.14: Resumen de victorias de la estrategia Predictiva frente a Greedy. Predictiva gana en 7/10 configuraciones por puntuación compuesta.

Por puntuación compuesta, la estrategia Predictiva es la ganadora en **7 de las 10** configuraciones: TC023 (house-5), TC025 (house-10), TC026 (office-10),

TC027 (house-15), TC028 (office-15), TC029 (house-20) y TC030 (office-20). En las tres configuraciones restantes (TC021, TC022, TC024, correspondientes a house-0, office-0 y office-5) Greedy obtiene mayor puntuación, en todos los casos sin actores o con densidad muy baja donde Predictiva no dispone de información dinámica relevante para guiar su planificación.

Aplicando el criterio de cuasi-empate ($S_{\text{Pred}} \geq 0{,}9 \cdot S_{\text{Greedy}}$), la estrategia Predictiva resulta competitiva o mejor en **7 de las 10** configuraciones. Este resultado indica que Predictiva no solo supera a la línea de base en la mayoría de los casos, sino que incluso en las configuraciones que no gana, la diferencia en puntuación compuesta es reducida en la mayor parte de ellas.

4.6.4. Análisis por entorno

Entorno house. En celdas fantasma, Predictiva supera a Greedy en todas las configuraciones con actores (5, 10, 15 y 20) y únicamente pierde en el caso sin actores. En entropía, Predictiva supera a Greedy solo en house-15; en los demás casos Greedy explora más del mapa. En frames procesados, Predictiva supera a Greedy en house-0 y house-20. La puntuación compuesta es favorable a Predictiva en cuatro de las cinco configuraciones de house (TC023, TC025, TC027, TC029).

Entorno office. En celdas fantasma, Predictiva supera a Greedy en las configuraciones con 10, 15 y 20 actores, mientras que pierde con 0 y 5. En entropía, Predictiva supera a Greedy únicamente en office-10. En frames procesados, Predictiva supera a Greedy en office-0, office-10 y con una diferencia muy marcada en office-20 (+508 %). La puntuación compuesta favorece a Predictiva en TC026, TC028 y TC030 (office-10, office-15 y office-20).

En conjunto, los resultados revelan que el beneficio de la estrategia Predictiva se incrementa con la densidad de actores en ambos entornos. La ventaja en precisión de mapa (celdas fantasma) es robusta a partir de densidades de 5 actores en house y 10 actores en office. La ventaja en exploración (entropía) es menos frecuente, lo que se discute en la sección siguiente.

4.6.5. Análisis del costo computacional

La desventaja de la estrategia Predictiva en exploración (entropía del mapa) en los experimentos de 30 minutos motivó el planteamiento de la **hipótesis del costo computacional**: la menor exploración de Predictiva puede deberse en parte a la demora en el cálculo de la utilidad dinámica, que involucra la planificación de la ruta completa hacia cada frontera candidata, el cómputo del tiempo de viaje a cada punto de la ruta y la predicción de posiciones futuras de cada persona detectada. Esta demora reduce el tiempo efectivo de movimiento del robot por ciclo de decisión.

Para contrastar esta hipótesis, se ejecutaron dos experimentos de mayor duración (aproximadamente tres horas) con la configuración de mayor densidad de actores en cada entorno:

- **VH001**: house-20, duración ≈ 2,99 h.
- **VH002**: office-20, duración ≈ 2,99 h.

La Figura 4.15 muestra la evolución temporal de la entropía del mapa y los frames procesados a lo largo de los experimentos extendidos. La Figura 4.16 compara los valores finales de los experimentos de 30 minutos con los de 3 horas.

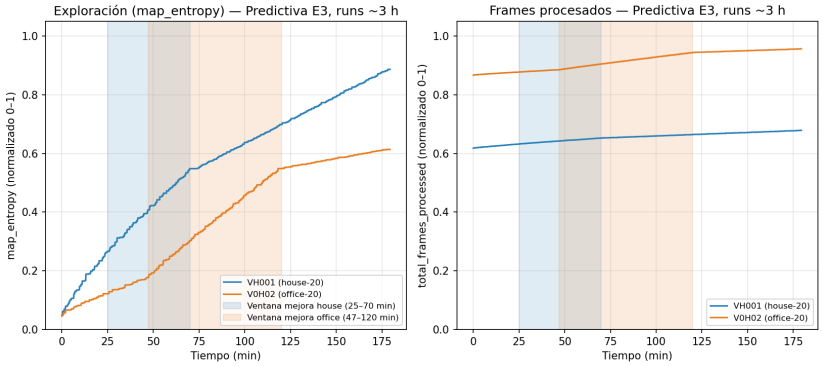

Figura 4.15: Evolución temporal de la entropía del mapa y los frames procesados en los experimentos extendidos (VH001 y VH002, ≈ 3 h). Se observa una ventana de crecimiento acelerado entre los 25–70 min en house y entre los 47 min y 2 h en office, seguida de una fase de mejora leve.

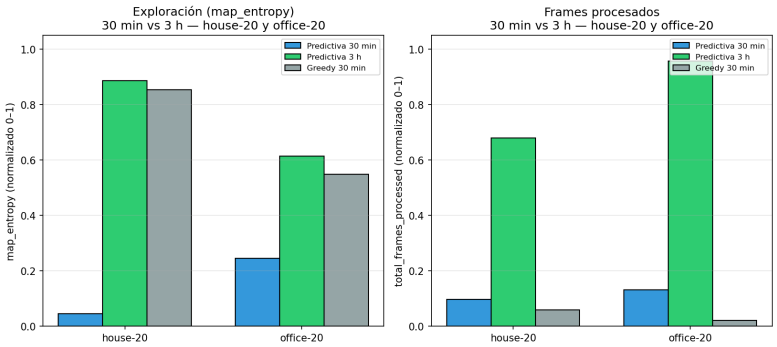

Figura 4.16: Comparación de métricas finales entre los experimentos de validación (30 min) y los experimentos extendidos (≈ 3 h) para las configuraciones house-20 y office-20. Se incluyen los valores de Greedy a 30 min como referencia.

Los resultados de los experimentos extendidos se resumen a continuación:

- **house-20 (VH001):** a 30 min, Predictiva registró 437 frames y entropía $9{,}83 \times 10^{-6}$. A 3 h, los valores alcanzaron 3054 frames y entropía $1{,}95 \times$

10^{-4}, superando ampliamente los valores de Greedy a 30 min (265 frames, $1{,}88 \times 10^{-4}$).

- **office-20 (VH002):** a 30 min, Predictiva registró 596 frames y entropía $5{,}41 \times 10^{-5}$. A 3 h, los valores alcanzaron 4304 frames y entropía $1{,}35 \times 10^{-4}$, superando también a Greedy a 30 min (98 frames, $1{,}21 \times 10^{-4}$).

Estos resultados apoyan la hipótesis: dado tiempo suficiente, la estrategia Predictiva recupera y supera la exploración de Greedy en ambos entornos. La ventana de crecimiento acelerado es distinta en cada entorno (25–70 min en house; 47 min–2 h en office), lo que sugiere que la dificultad de recuperación depende de la geometría del entorno y la complejidad de las rutas calculadas. Para que Predictiva exprese su potencial de exploración junto con su ventaja en precisión, se recomienda asignar al menos 1–2 horas de ejecución.

4.6.6. Discusión

Los resultados permiten identificar tres aspectos centrales del comportamiento de la estrategia Predictiva:

Precisión del mapa. La predicción de interferencia es el mecanismo que explica la reducción de celdas fantasma. Al estimar qué personas cruzarán la ruta hacia cada frontera, AlfredZ evita o posterga las fronteras donde la presencia futura de personas generaría ocupaciones transitorias en el mapa. Este efecto es estructural: crece con la densidad de actores y es independiente del entorno, razón por la que se observa en house y office a partir de 5–10 actores. La estrategia Greedy, que selecciona únicamente por distancia, no dispone de este mecanismo y acumula celdas fantasma en proporción a la actividad dinámica del entorno.

Exploración. La desventaja de Predictiva en entropía del mapa en los experimentos de 30 minutos no obedece a decisiones subóptimas de exploración, sino principalmente al mayor costo computacional por ciclo de decisión. Los experimentos extendidos demuestran que, con tiempo suficiente, Predictiva alcanza y supera el nivel de exploración de Greedy. Este hallazgo sugiere que la comparación a 30 minutos subestima el potencial de la estrategia Predictiva en aplicaciones de mayor duración.

Eficiencia. El comportamiento de los frames procesados es heterogéneo: Predictiva supera a Greedy en las configuraciones sin actores y en las de mayor densidad, mientras que Greedy procesa más frames en densidades intermedias. Esta variabilidad refleja la interacción entre el costo computacional adicional de Predictiva y la reducción de interrupciones por colisión con personas que proporciona la predicción de interferencia.

En conjunto, los resultados **validan la estrategia Predictiva** como alternativa superior a Greedy cuando se prioriza la precisión del mapa o cuando el tiempo de exploración disponible es suficiente. La estrategia Greedy resulta preferible únicamente cuando se requiere maximizar la exploración en ventanas de tiempo cortas y la densidad de actores es baja o nula.

4.7. Análisis comparativo de estrategias

[SCAFFOLDING — Esta sección cierra el capítulo de experimentación con una comparación directa de las tres estrategias propuestas (Frontera, Ruta Planificada y Predictiva) entre sí y frente a la línea de base Greedy. Se estructura en cuatro bloques:]

1. Tabla unificada de resultados. Una tabla con las cuatro estrategias (Frontera, Ruta Planificada, Predictiva, Greedy) como columnas y las 10 configuraciones (entorno $\times$ actores) como filas, para cada una de las tres métricas. Permite al lector identificar de un vistazo cuál estrategia domina en cada configuración y métrica.

2. Comparación por puntuación compuesta. Figura de barras agrupadas con la puntuación compuesta de las cuatro estrategias por configuración, y tabla de recuento de victorias (cuántas configuraciones gana cada estrategia en cada métrica y en score compuesto). Se discute si la progresión de complejidad (Frontera $\rightarrow$ Ruta Planificada $\rightarrow$ Predictiva) se traduce en una mejora progresiva de resultados o si el trade-off con el costo computacional neutraliza parte del beneficio.

3. Trade-offs y recomendaciones de uso. Análisis de los tres trade-offs centrales del sistema:

- **Precisión vs. exploración**: Predictiva logra la mayor precisión (menores ghost cells) pero sacrifica exploración en ejecuciones cortas. Greedy maximiza exploración pero acumula ruido en el mapa con densidad alta de actores.

- **Complejidad vs. rendimiento**: el costo computacional creciente de Frontera $\rightarrow$ Ruta Planificada $\rightarrow$ Predictiva se justifica en configuraciones con densidad media-alta de actores (≥ 10), donde la ganancia en precisión compensa la pérdida de exploración.

- **Duración del experimento**: Greedy es preferible en exploraciones cortas con pocos actores; Predictiva es preferible en exploraciones prolongadas o con muchos actores.

4. Conclusión del capítulo. Párrafo de cierre que sintetiza cuál estrategia valida mejor los objetivos del proyecto y abre la discusión hacia las conclusiones generales (Capítulo 5).

[— Completar cuando estén disponibles los análisis de Frontera y Ruta Planificada.]

Capítulo 5

Conclusiones y Trabajo Futuro

En este capítulo se evalúan los resultados alcanzados y dificultades encontradas, se establece lo que se planteó hacer y lo que se hizo realmente, cuáles fueron los aportes, se muestran posibles extensiones al trabajo, se realiza una autocrítica de lo que se hizo y lo que faltó (por problemas de tiempo, recursos, cómo se puede continuar, qué cosas hacer, prioridades, etc.) y se incluye información sobre la gestión del proyecto, si aplica.

Referencias

Cohen, P. J. (1963). The independence of the continuum hypothesis. *Proceedings of the National Academy of Sciences*, *50*(6), 1143–1148.

Holleis, P., Wagner, M., y Koolwaaij, J. (2010). Studying mobile context-aware social services in the wild. En *Proc. of the 6th nordic conf. on human-computer interaction* (pp. 207–216). New York, NY: ACM.

NASA. (2015). *Pluto: The 'other' red planet.* https://www.nasa.gov/nh/pluto-the-other-red-planet. (Accessed: 2018-12-06)

R Core Team. (2018). R: A language and environment for statistical computing [Manual de software informático]. Vienna, Austria.

Susskind, L., y Hrabovsky, G. (2014). *Classical mechanics: the theoretical minimum.* New York, NY: Penguin Random House.

Anexo 1

Los anexos contienen información adjunta al proyecto pero que no es fundamental para entender el trabajo. Por ejemplo, determinado material de los antecedentes o la implementación, que en el cuerpo principal del informe se encuentre resumido, aquí puede presentarse de forma completa. En caso de proyectos de desarrollo de software, se debería incluir un manual de usuario.

.1. Sección del Anexo

Los anexos pueden tener secciones.