Mapeo 3D autónomo con un robot de servicio AlfredZ

Informe de Proyecto de Grado presentado por

Enzo Borges, Christian Deleon, Román Alvarez

en cumplimiento parcial de los requerimientos para la graduación de la carrera de Ingeniería en Computación de Facultad de Ingeniería de la Universidad de la República

Supervisores

Federico Andrade
Facundo Benavides

Montevideo, 17 de marzo de 2026

Mapeo 3D autónomo con un robot de servicio AlfredZ
por Enzo Borges, Christian Deleon, Román Alvarez tiene licencia
CC Atribución 4.0.

Agradecimientos

Agradecer, siempre es bueno agradecer.

Resumen

El resumen (200-500 palabras) debe dar una idea completa de todo el proyecto, mencionando claramente los formalismos, técnicas, herramientas y lenguas utilizados. No debe limitarse a describir el problema abordado, sino que debe describir la solución del problema, con una evaluación de la misma. No debe incluir referencias bibliográficas ni referencias a otras partes del informe. Tampoco debe utilizar acrónimos sin explicar su significado.

Palabras clave: Template, Proyectos de Grado, Computación

Índice general

1. Introducción **1**

2. Revisión de antecedentes **3**
2.1. Primera Sección 3
2.2. Segunda Sección 3
2.2.1. La Subsección 3

3. Parte Central **5**

4. Experimentación **7**
4.1. Configuración experimental 7
4.1.1. Entornos de simulación 7
4.1.2. Configuración del sistema 8
4.1.3. Métricas de evaluación 8
4.1.4. Puntuación compuesta 9
4.2. Estrategia de comparación: Greedy 9
4.3. Etapa de calibración 10
4.4. Vecindad: utilidad dinámica por vecindad 10
4.5. Ruta Planificada: utilidad dinámica por ruta planificada 10
4.6. Predictiva: estimación de interferencia con predicción de trayectorias 11
4.6.1. Diseño de los experimentos 11
4.6.2. Resultados por métrica 11
4.6.3. Puntuación compuesta y análisis global 15
4.6.4. Análisis por entorno 16
4.6.5. Análisis del costo computacional 17
4.6.6. Discusión 18
4.7. Análisis comparativo de estrategias 19

5. Conclusiones y Trabajo Futuro **21**

Referencias **23**

Anexo 1 **25**
.1. Sección del Anexo 25

Capítulo 1

Introducción

Aquí se motiva el trabajo, se plantea y define el problema, se deja claro cuáles son los objetivos (general del proyecto, si correspondiese o si está inmerso en un proyecto de mayor alcance, y los específicos), se plantean los resultados esperados, se establecen resumidamente las conclusiones y se describe la organización general del documento.

Este y los siguientes capítulos pueden incluir referencias; algunos ejemplos pueden ser (Cohen, 1963), (Susskind y Hrabovsky, 2014), (Holleis, Wagner, y Koolwaaij, 2010), (R Core Team, 2018) y (NASA, 2015). Se sugiere citar usando el formato APA.

Capítulo 2

Revisión de antecedentes

Revisión de antecedentes (ya sea productos, procesos, publicaciones, etc., a nivel académico o comercial) en el tema del trabajo. Puede incluir además (si es necesario) una breve introducción a los conceptos necesarios para entender el trabajo.

2.1. Primera Sección

Los capítulos pueden incluir secciones como esta, que además pueden hacer referencia a otras secciones, como por ejemplo a la Sección 2.2.

2.2. Segunda Sección

Esta sección además tiene una subsección.

2.2.1. La Subsección

Esta es la subsección.

Capítulo 3

Parte Central

La parte central del trabajo refiere a lo que es producción propia o aporte del proyecto de grado, incluyendo las decisiones tomadas. Por ejemplo, puede incluir los requerimientos, el análisis y el diseño de la solución. Si el proyecto tiene una implementación, debe describirse en términos de decisiones tomadas en ese sentido. Los detalles de programación se dejan para los anexos.

Se pueden incluir figuras y tablas en el documento; las mismas deben estar referenciadas en el texto. Por ejemplo, la Figura 3.1 muestra los logos de Facultad de Ingeniería y de la Universidad de la República, mientras que la Tabla 3.1 tiene números aleatorios.

Figura 3.1: Logos de FIng y UdelaR

Col1	Col2	Col2	Col3
1	970	67	941
2	668	845	141
3	800	383	464
4	143	683	502

Tabla 3.1: Tabla con datos

Capítulo 4

Experimentación

Este capítulo describe los experimentos realizados para validar las estrategias de planificación de siguiente mejor vista (*Next Best View*, NBV) implementadas en AlfredZ. El objetivo es comparar el comportamiento de cada estrategia frente a una línea de base Greedy en entornos de simulación con distintas densidades de actores dinámicos, evaluando métricas de precisión de mapa, exploración y eficiencia de procesado.

Los experimentos se organizaron en tres etapas: una etapa de calibración para determinar los hiperparámetros óptimos del sistema, seguida de tres etapas de validación, una por cada estrategia de utilidad dinámica propuesta. En cada etapa de validación se compara la estrategia correspondiente con la misma línea de base Greedy ejecutada en condiciones idénticas.

4.1. Configuración experimental

4.1.1. Entornos de simulación

Los experimentos se ejecutaron en simulación mediante Gazebo con dos entornos de interior de diferente distribución espacial:

- **house**: planta residencial compacta, con pasillos estrechos y múltiples habitaciones de tamaño reducido. Su geometría favorece la acumulación de obstáculos dinámicos en zonas de paso.
- **office**: planta de bloque de oficinas de mayor superficie, con espacios abiertos y áreas de circulación más amplias. La distribución genera rutas de exploración más largas entre fronteras.

En cada entorno se ejecutaron experimentos con cinco niveles de densidad de actores dinámicos: 0, 5, 10, 15 y 20 personas simuladas con trayectorias autónomas. La combinación de dos entornos y cinco niveles de densidad produce **10 configuraciones** de prueba por estrategia.

Todos los experimentos tuvieron una duración de **1800 segundos** (30 minutos). AlfredZ contó con los mismos parámetros de navegación, percepción y mapa en todas las ejecuciones, con la única variación en la estrategia de planificación NBV.

4.1.2. Configuración del sistema

El sistema AlfredZ integra los siguientes componentes en cada experimento:

- **RTAB-Map**: construcción y actualización del mapa de ocupación 3D.
- **Nav2**: planificación de rutas y ejecución de la navegación autónoma.
- **YOLO**: detección de personas en tiempo real a partir de imágenes de la cámara del robot.
- **Planificador NBV semántico**: selección de la frontera destino según la estrategia configurada, implementada en el nodo `ExplorerNode`.

La función de utilidad empleada por las estrategias dinámicas sigue la forma general:

$$U(v) = IG_{\text{estático}}(v) - \lambda \cdot D(v) - \mu \cdot C_{\text{trayecto}}(v) \tag{4.1}$$

donde $IG_{\text{estático}}(v)$ representa la ganancia de información estática de la frontera v, $D(v)$ es el costo dinámico calculado según la estrategia activa, $C_{\text{trayecto}}(v)$ es el costo de la ruta planificada hacia v, y λ y μ son hiperparámetros que ponderan cada componente. Los valores óptimos $\lambda = 5$ y $\mu = 0{,}01$ se determinaron en la etapa de calibración descrita en la Sección 4.3.

4.1.3. Métricas de evaluación

El desempeño de cada estrategia se evaluó mediante tres métricas registradas al final de cada experimento:

- **Celdas fantasma (*ghost cells*)**: número de celdas del mapa de ocupación que aparecen marcadas como ocupadas en el instante final pero que estaban libres en los tres mapas anteriores del historial. Esta métrica cuantifica la presencia de falsos positivos de ocupación generados por obstáculos dinámicos que ya no se encuentran en esa posición. Un valor **menor** indica mayor precisión del mapa.
- **Entropía del mapa (*map entropy*)**: entropía de Shannon calculada sobre las celdas conocidas del mapa de ocupación final, definida como $H = -\sum p_i \log_2(p_i)$, donde $p_i = v_i/100$ para cada celda con valor $v_i \geq 0$. Cuantifica la variedad de estados observados en el mapa y se emplea como indicador del grado de exploración alcanzado. Un valor **mayor** indica mayor exploración.

- **Frames totales procesados (*total frames processed*)**: contador acumulativo del número de observaciones de cámara procesadas por el *pipeline* de visión durante toda la ejecución del experimento. Se utiliza como indicador de eficiencia y throughput del sistema perceptivo. Un valor **mayor** indica mayor cantidad de observaciones procesadas.

4.1.4. Puntuación compuesta

Para facilitar la comparación global entre estrategias se empleó una puntuación compuesta que agrega las tres métricas en un único valor escalar. Previamente, cada métrica se normalizó mediante normalización min-máx global sobre el conjunto de valores de ambas estrategias comparadas:

$$\hat{x} = \frac{x - x_{\text{mín}}}{x_{\text{máx}} - x_{\text{mín}}} \tag{4.2}$$

Dado que en celdas fantasma un valor menor corresponde a mejor desempeño, se invierte la normalización de esta métrica ($1 - \hat{x}_{\text{ghost}}$). La puntuación compuesta se calcula entonces como:

$$S = 0{,}40 \cdot (1 - \hat{x}_{\text{ghost}}) + 0{,}35 \cdot \hat{x}_{\text{entropy}} + 0{,}25 \cdot \hat{x}_{\text{frames}} \tag{4.3}$$

Los pesos asignados reflejan las prioridades del proyecto: la precisión del mapa (celdas fantasma) recibe el mayor peso (40 %), seguida de la exploración (entropía, 35 %) y la eficiencia de procesado (frames, 25 %).

La estrategia con mayor puntuación compuesta en una configuración dada se considera ganadora en esa configuración. Se utiliza adicionalmente el criterio de "cuasi-empate o mejor" cuando la puntuación compuesta de una estrategia alcanza al menos el 90 % de la puntuación de la estrategia contraria.

4.2. Estrategia de comparación: Greedy

La estrategia Greedy actúa como línea de base de referencia. En cada ciclo de decisión, selecciona la frontera inexplorada más cercana al robot según distancia euclídea, sin considerar factores dinámicos ni calcular rutas completas. Su función de selección se reduce a:

$$v^* = \arg\min_{v \in \mathcal{F}} \|p_{\text{robot}} - c_v\|_2 \tag{4.4}$$

donde $\mathcal{F}$ es el conjunto de fronteras disponibles y c_v es el centroide de la frontera v.

Esta estrategia maximiza el tiempo efectivo de movimiento al minimizar el costo computacional por decisión: no planifica rutas, no estima interferencia dinámica ni predice posiciones futuras de personas. La ausencia de modelado dinámico implica que el robot puede dirigirse repetidamente a zonas con alta actividad de personas, incrementando la probabilidad de generar celdas fantasma en el mapa. Los experimentos Greedy se identifican con los casos G001 a

G010, correspondientes a las mismas 10 configuraciones (entorno × número de actores) que las estrategias de validación.

4.3. Etapa de calibración

[SCAFFOLDING — Esta sección describe la etapa de calibración, cuyo objetivo fue determinar los valores óptimos de los hiperparámetros λ (peso del costo dinámico) y μ (peso del costo de trayectoria) de la función de utilidad (4.1). Se realizaron experimentos sistemáticos variando $\lambda \in \{0, 1, 5, 10\}$ y $\mu \in \{0{,}001, 0{,}01, 0{,}1\}$ en los entornos house y office con distintas densidades de actores. Los resultados determinaron que los valores $\lambda = 5$ y $\mu = 0{,}01$ maximizan la puntuación compuesta en el conjunto de configuraciones evaluadas; estos valores se emplean de forma fija en todas las etapas de validación. — Completar con el análisis preliminar de calibración cuando esté disponible.]

4.4. Vecindad: utilidad dinámica por vecindad

[SCAFFOLDING — Esta sección presenta los experimentos de validación para la estrategia Vecindad, que calcula el costo dinámico $D(v)$ contando el número de personas detectadas dentro de un radio fijo r alrededor del centroide de la frontera v:

$$D_{\text{Vec}}(v) = \left|\{p_i : \|c_v - p_i\|_2 \leq r\}\right|$$

Los casos de prueba son TC001–TC010, con tres réplicas por caso (V001–V030). Se comparan los resultados con la línea de base Greedy (G001–G010) en las mismas 10 configuraciones de entorno y densidad de actores. Los hallazgos principales son: Vecindad supera a Greedy en celdas fantasma en 6/10 configuraciones, en entropía en 5/10 y en frames en 3/10; por puntuación compuesta, Vecindad es competitiva o mejor en 5/10 configuraciones. — Completar con análisis detallado, tablas y figuras de Vecindad vs Greedy.]

4.5. Ruta Planificada: utilidad dinámica por ruta planificada

[SCAFFOLDING — Esta sección presenta los experimentos de validación para la estrategia Ruta Planificada, que calcula el costo dinámico $D(v)$ contando el número de personas detectadas dentro de un radio r de cualquier punto de la ruta planificada hacia la frontera v:

$$D_{\text{Ruta}}(v) = \left|\{p_i : \exists\, q \in \text{ruta}(v),\ \|q - p_i\|_2 \leq r\}\right|$$

A diferencia de la estrategia Vecindad, la estrategia Ruta Planificada evalúa la interferencia a lo largo de todo el camino que recorrerá el robot, en lugar de solo en la vecindad del destino final. Los casos de prueba son TC011–TC020, con tres

réplicas por caso (V031–V060). Los hallazgos principales son: Ruta Planificada supera a Greedy en celdas fantasma en 5/10 configuraciones, en entropía en 4/10 y en frames en 3/10; por puntuación compuesta, Ruta Planificada es competitiva o mejor en 5/10 configuraciones. — Completar con análisis detallado, tablas y figuras de Ruta Planificada vs Greedy.]

4.6. Predictiva: estimación de interferencia con predicción de trayectorias

Esta sección presenta los experimentos de validación para la **estrategia Predictiva**. La estrategia Predictiva extiende la Ruta Planificada incorporando predicción de trayectorias: en lugar de evaluar la posición actual de las personas, estima sus posiciones futuras al momento en que el robot llegará a cada punto de la ruta. El costo dinámico se calcula como el número de personas cuya posición predicha se encontrará dentro de un radio r de algún punto de la ruta planificada:

$$D_{\text{Pred}}(v) = \left|\{p_i : \exists\,(q, t_q) \in \text{ruta_temporal}(v),\ \|q - \hat{p}_i(t_q)\|_2 \leq r\}\right| \tag{4.5}$$

donde $\hat{p}_i(t_q)$ es la posición predicha de la persona i en el instante t_q, estimada a partir del historial de posiciones mediante velocidad promedio:

$$\hat{p}_i(t) = p_i^{\text{actual}} + \bar{v}_i \cdot t \tag{4.6}$$

La predicción lineal con velocidad promedio permite anticipar qué personas cruzarán la ruta futura del robot, lo que en principio reduce la frecuencia con que se seleccionan fronteras hacia zonas de alta actividad dinámica.

4.6.1. Diseño de los experimentos

Los experimentos de validación de la estrategia Predictiva comprenden **10 casos de prueba** (TC021–TC030), correspondientes a las configuraciones house $\times$ {0, 5, 10, 15, 20} y office $\times$ {0, 5, 10, 15, 20} actores, detalladas en la Tabla 4.1. Cada caso se ejecutó con **tres réplicas independientes**; el valor representativo de la estrategia Predictiva en cada configuración es la mediana de las tres réplicas. La línea de base Greedy corresponde a los experimentos G001–G010, ejecutados una vez por configuración en las mismas condiciones (duración 1800 s, $\lambda = 5$, $\mu = 0{,}01$).

La normalización global min-máx de la Ecuación (4.2) se aplicó sobre la unión de valores de Predictiva y Greedy, con los rangos globales detallados en la Tabla 4.2.

4.6.2. Resultados por métrica

La Tabla 4.3 y la Figura 4.1 presentan los resultados de celdas fantasma para cada configuración.

Tabla 4.1: Casos de prueba de validación: estrategia Predictiva y Greedy. Cada caso corresponde a una combinación de entorno y número de actores.

Caso (Predictiva)	**Caso (Greedy)**	**Entorno**	**Actores**	**Réplicas (Predictiva)**
TC021	G001	house	0	V061–V063
TC022	G002	office	0	V064–V066
TC023	G003	house	5	V067–V069
TC024	G004	office	5	V070–V072
TC025	G005	house	10	V073–V075
TC026	G006	office	10	V076–V078
TC027	G007	house	15	V079–V081
TC028	G008	office	15	V082–V084
TC029	G009	house	20	V085–V087
TC030	G010	office	20	V088–V090

Tabla 4.2: Rangos globales de normalización para la comparación Predictiva vs Greedy.

Métrica	**Mínimo**	**Máximo**
Celdas fantasma	0	153
Entropía del mapa	$9{,}42 \times 10^{-6}$	$2{,}06 \times 10^{-4}$
Frames procesados	98	648

Tabla 4.3: Celdas fantasma (valor final) por configuración: Predictiva vs Greedy. Valores en negrita indican la estrategia ganadora. Menor es mejor.

Configuración	**Predictiva (mediana)**	**Greedy**	**% dif.**
house-0	30	**15**	+100 %
office-0	14	**13**	+8 %
house-5	**0**	81	−100 %
office-5	99	**78**	+27 %
house-10	**0**	83	−100 %
office-10	**18**	125	−86 %
house-15	**0**	118	−100 %
office-15	**0**	153	−100 %
house-20	**0**	131	−100 %
office-20	**63**	83	−24 %

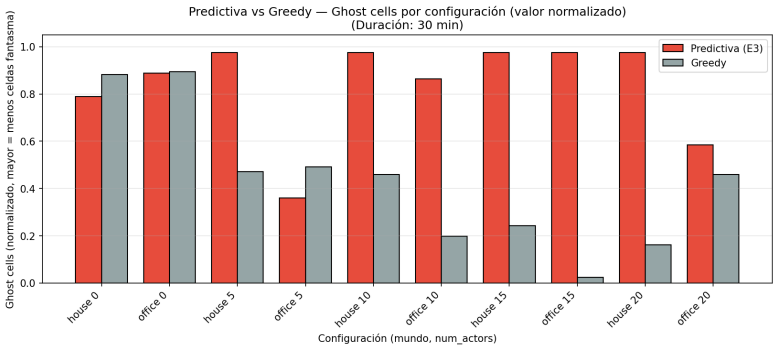

Figura 4.1: Celdas fantasma normalizadas por configuración. Valor normalizado mayor indica menor número de celdas fantasma (mejor precisión del mapa). Predictiva supera a Greedy en 7 de las 10 configuraciones.

La estrategia Predictiva supera a Greedy en celdas fantasma en **7 de las 10** configuraciones. Las tres excepciones corresponden a los escenarios sin actores o con densidad baja (house-0, office-0, office-5), donde la interferencia dinámica es nula o escasa y la predicción de trayectorias no aporta ventaja alguna. En el entorno house, la estrategia Predictiva logra cero celdas fantasma en todas las configuraciones con actores (house-5 a house-20). En office, la ventaja es también consistente a partir de 10 actores, aunque con magnitudes variables: una reducción del 86 % en office-10, eliminación total en office-15 y una reducción del 24 % en office-20.

La Tabla 4.4 y la Figura 4.2 presentan los resultados de entropía del mapa.

Tabla 4.4: Entropía del mapa (valor final) por configuración: Predictiva vs Greedy. Valores en negrita indican la estrategia ganadora. Mayor es mejor.

Configuración	**Predictiva (mediana)**	**Greedy**	**% dif.**
house-0	$1{,}0 \times 10^{-5}$	$\mathbf{1{,}3 \times 10^{-4}}$	−92 %
office-0	$1{,}1 \times 10^{-4}$	$\mathbf{2{,}1 \times 10^{-4}}$	−45 %
house-5	$1{,}1 \times 10^{-4}$	$\mathbf{1{,}7 \times 10^{-4}}$	−32 %
office-5	$8{,}5 \times 10^{-5}$	$\mathbf{1{,}1 \times 10^{-4}}$	−20 %
house-10	$6{,}2 \times 10^{-5}$	$\mathbf{6{,}6 \times 10^{-5}}$	−7 %
office-10	$\mathbf{1{,}4 \times 10^{-4}}$	$1{,}3 \times 10^{-4}$	+12 %
house-15	$\mathbf{7{,}6 \times 10^{-5}}$	$9{,}4 \times 10^{-6}$	+710 %
office-15	$1{,}2 \times 10^{-5}$	$\mathbf{8{,}9 \times 10^{-5}}$	−86 %
house-20	$1{,}0 \times 10^{-5}$	$\mathbf{1{,}9 \times 10^{-4}}$	−95 %
office-20	$5{,}4 \times 10^{-5}$	$\mathbf{1{,}2 \times 10^{-4}}$	−55 %

En entropía del mapa Greedy supera a la estrategia Predictiva en **8 de las 10** configuraciones. Predictiva únicamente supera a Greedy en office-10 (+12 %) y en house-15 (+710 %, caso particular con entropía muy baja de Greedy). Esta

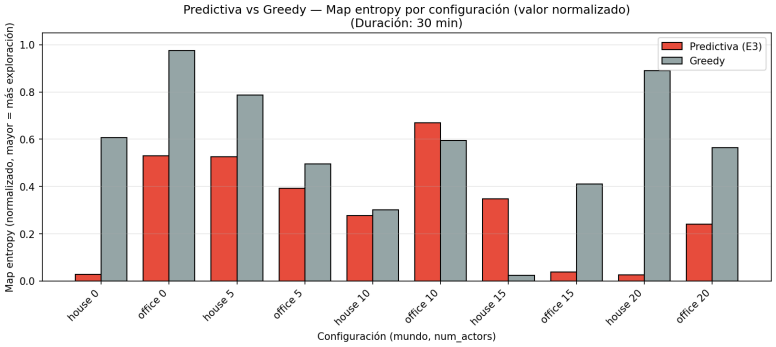

Figura 4.2: Entropía del mapa normalizada por configuración. Valor normalizado mayor indica mayor exploración. Greedy supera a Predictiva en 8 de las 10 configuraciones.

desventaja generalizada en exploración se atribuye al mayor costo computacional de la estrategia Predictiva, detallado en la Sección 4.6.5.

La Tabla 4.5 y la Figura 4.3 presentan los resultados de frames procesados.

Tabla 4.5: Frames totales procesados (valor final acumulado) por configuración: Predictiva vs Greedy. Valores en negrita indican la estrategia ganadora. Mayor es mejor.

Configuración	**Predictiva (mediana)**	**Greedy**	**% dif.**
house-0	**620**	217	+186 %
office-0	**613**	555	+10 %
house-5	449	**577**	−22 %
office-5	523	**648**	−19 %
house-10	419	**454**	−8 %
office-10	**638**	601	+6 %
house-15	340	**597**	−43 %
office-15	509	**607**	−16 %
house-20	**437**	265	+65 %
office-20	**596**	98	+508 %

En frames procesados la estrategia Predictiva supera a Greedy en **5 de las 10** configuraciones. Las ventajas más marcadas se observan en house-0 (+186 %) y en office-20 (+508 %). En los casos con densidad intermedia de actores (house-5, office-5, house-10, house-15, office-15) Greedy procesa más frames, lo que es coherente con su menor tiempo de cómputo por decisión.

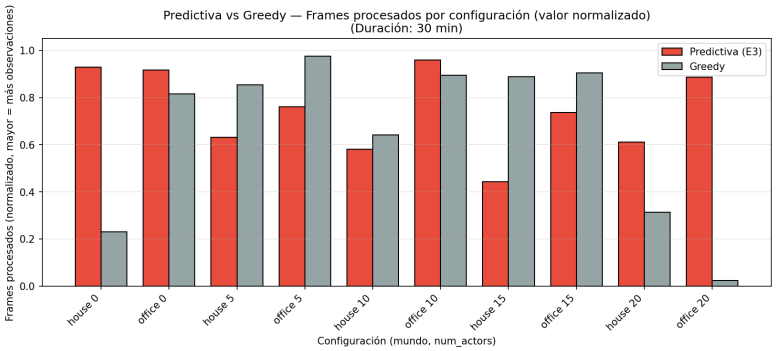

Figura 4.3: Frames procesados normalizados por configuración. Valor normalizado mayor indica mayor throughput del pipeline de visión. Predictiva supera a Greedy en 5 de las 10 configuraciones.

4.6.3. Puntuación compuesta y análisis global

La Figura 4.4 presenta la puntuación compuesta calculada con la Ecuación (4.3) para cada configuración, y la Figura 4.5 resume el recuento de victorias por métrica.

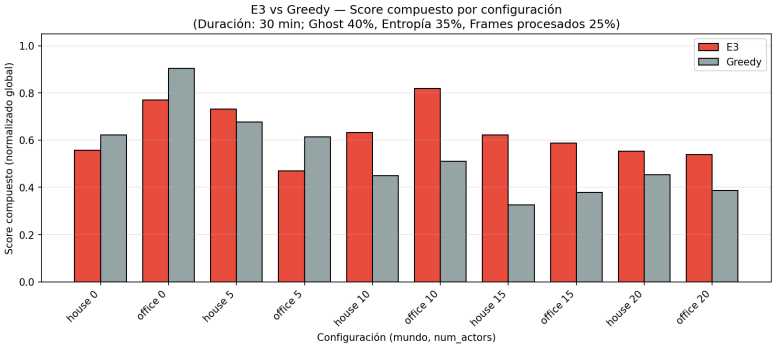

Figura 4.4: Puntuación compuesta por configuración (Predictiva vs Greedy). Pesos: celdas fantasma 40 %, entropía 35 %, frames 25 %. Predictiva supera a Greedy en 7 de las 10 configuraciones.

Por puntuación compuesta, la estrategia Predictiva es la ganadora en **7 de las 10** configuraciones: TC023 (house-5), TC025 (house-10), TC026 (office-10), TC027 (house-15), TC028 (office-15), TC029 (house-20) y TC030 (office-20). En las tres configuraciones restantes (TC021, TC022, TC024, correspondientes a house-0, office-0 y office-5) Greedy obtiene mayor puntuación, en todos los casos sin actores o con densidad muy baja donde Predictiva no dispone de información dinámica relevante para guiar su planificación.

Aplicando el criterio de cuasi-empate ($S_{\text{Pred}} \geq 0{,}9 \cdot S_{\text{Greedy}}$), la estrategia

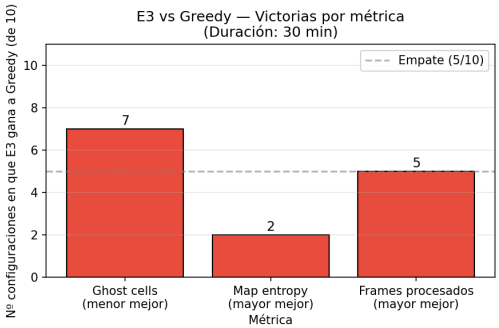

(a) Victorias por métrica individual.

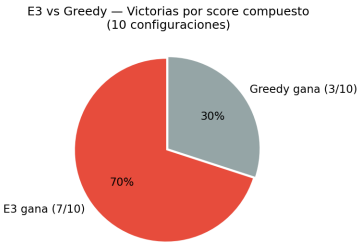

(b) Victorias por puntuación compuesta.

Figura 4.5: Resumen de victorias de la estrategia Predictiva frente a Greedy. Predictiva gana en 7/10 configuraciones por puntuación compuesta.

Predictiva resulta competitiva o mejor en **7 de las 10** configuraciones. Este resultado indica que Predictiva no solo supera a la línea de base en la mayoría de los casos, sino que incluso en las configuraciones que no gana, la diferencia en puntuación compuesta es reducida en la mayor parte de ellas.

4.6.4. Análisis por entorno

Entorno house. En celdas fantasma, Predictiva supera a Greedy en todas las configuraciones con actores (5, 10, 15 y 20) y únicamente pierde en el caso sin actores. En entropía, Predictiva supera a Greedy solo en house-15; en los demás casos Greedy explora más del mapa. En frames procesados, Predictiva supera a Greedy en house-0 y house-20. La puntuación compuesta es favorable a Predictiva en cuatro de las cinco configuraciones de house (TC023, TC025, TC027, TC029).

Entorno office. En celdas fantasma, Predictiva supera a Greedy en las configuraciones con 10, 15 y 20 actores, mientras que pierde con 0 y 5. En entropía, Predictiva supera a Greedy únicamente en office-10. En frames procesados, Predictiva supera a Greedy en office-0, office-10 y con una diferencia muy marcada en office-20 (+508 %). La puntuación compuesta favorece a Predictiva en TC026, TC028 y TC030 (office-10, office-15 y office-20).

En conjunto, los resultados revelan que el beneficio de la estrategia Predictiva se incrementa con la densidad de actores en ambos entornos. La ventaja en precisión de mapa (celdas fantasma) es robusta a partir de densidades de 5 actores en house y 10 actores en office. La ventaja en exploración (entropía) es menos frecuente, lo que se discute en la sección siguiente.

4.6.5. Análisis del costo computacional

La desventaja de la estrategia Predictiva en exploración (entropía del mapa) en los experimentos de 30 minutos motivó el planteamiento de la **hipótesis del costo computacional**: la menor exploración de Predictiva puede deberse en parte a la demora en el cálculo de la utilidad dinámica, que involucra la planificación de la ruta completa hacia cada frontera candidata, el cómputo del tiempo de viaje a cada punto de la ruta y la predicción de posiciones futuras de cada persona detectada. Esta demora reduce el tiempo efectivo de movimiento del robot por ciclo de decisión.

Para contrastar esta hipótesis, se ejecutaron dos experimentos de mayor duración (aproximadamente tres horas) con la configuración de mayor densidad de actores en cada entorno:

- **VH001**: house-20, duración $\approx 2{,}99$ h.
- **VH002**: office-20, duración $\approx 2{,}99$ h.

La Figura 4.6 muestra la evolución temporal de la entropía del mapa y los frames procesados a lo largo de los experimentos extendidos. La Figura 4.7 compara los valores finales de los experimentos de 30 minutos con los de 3 horas.

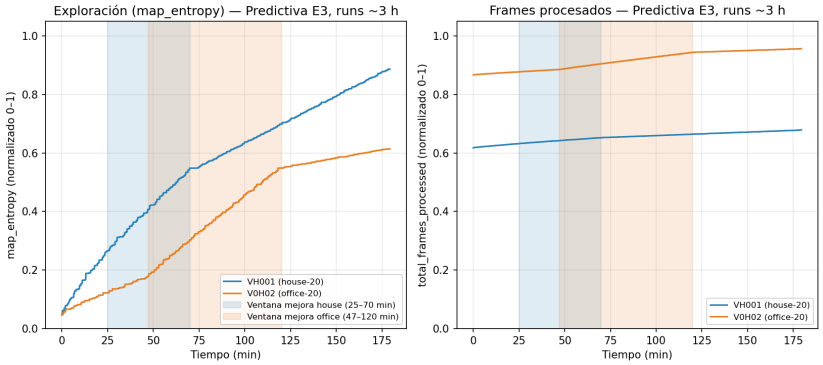

Figura 4.6: Evolución temporal de la entropía del mapa y los frames procesados en los experimentos extendidos (VH001 y VH002, ≈ 3 h). Se observa una ventana de crecimiento acelerado entre los 25–70 min en house y entre los 47 min y 2 h en office, seguida de una fase de mejora leve.

Los resultados de los experimentos extendidos se resumen a continuación:

- **house-20 (VH001):** a 30 min, Predictiva registró 437 frames y entropía $9{,}83 \times 10^{-6}$. A 3 h, los valores alcanzaron 3054 frames y entropía $1{,}95 \times 10^{-4}$, superando ampliamente los valores de Greedy a 30 min (265 frames, $1{,}88 \times 10^{-4}$).
- **office-20 (VH002):** a 30 min, Predictiva registró 596 frames y entropía $5{,}41 \times 10^{-5}$. A 3 h, los valores alcanzaron 4304 frames y entropía $1{,}35 \times 10^{-4}$, superando también a Greedy a 30 min (98 frames, $1{,}21 \times 10^{-4}$).

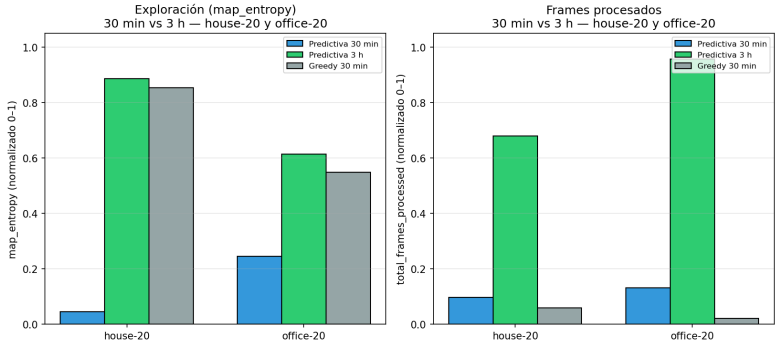

Figura 4.7: Comparación de métricas finales entre los experimentos de validación (30 min) y los experimentos extendidos ($\approx$ 3 h) para las configuraciones house-20 y office-20. Se incluyen los valores de Greedy a 30 min como referencia.

Estos resultados apoyan la hipótesis: dado tiempo suficiente, la estrategia Predictiva recupera y supera la exploración de Greedy en ambos entornos. La ventana de crecimiento acelerado es distinta en cada entorno (25–70 min en house; 47 min–2 h en office), lo que sugiere que la dificultad de recuperación depende de la geometría del entorno y la complejidad de las rutas calculadas. Para que Predictiva exprese su potencial de exploración junto con su ventaja en precisión, se recomienda asignar al menos 1–2 horas de ejecución.

4.6.6. Discusión

Los resultados permiten identificar tres aspectos centrales del comportamiento de la estrategia Predictiva:

Precisión del mapa. La predicción de interferencia es el mecanismo que explica la reducción de celdas fantasma. Al estimar qué personas cruzarán la ruta hacia cada frontera, AlfredZ evita o posterga las fronteras donde la presencia futura de personas generaría ocupaciones transitorias en el mapa. Este efecto es estructural: crece con la densidad de actores y es independiente del entorno, razón por la que se observa en house y office a partir de 5–10 actores. La estrategia Greedy, que selecciona únicamente por distancia, no dispone de este mecanismo y acumula celdas fantasma en proporción a la actividad dinámica del entorno.

Exploración. La desventaja de Predictiva en entropía del mapa en los experimentos de 30 minutos no obedece a decisiones subóptimas de exploración, sino principalmente al mayor costo computacional por ciclo de decisión. Los experimentos extendidos demuestran que, con tiempo suficiente, Predictiva alcanza y supera el nivel de exploración de Greedy. Este hallazgo sugiere que la comparación a 30 minutos subestima el potencial de la estrategia Predictiva en aplicaciones de mayor duración.

Eficiencia. El comportamiento de los frames procesados es heterogéneo:

Predictiva supera a Greedy en las configuraciones sin actores y en las de mayor densidad, mientras que Greedy procesa más frames en densidades intermedias. Esta variabilidad refleja la interacción entre el costo computacional adicional de Predictiva y la reducción de interrupciones por colisión con personas que proporciona la predicción de interferencia.

En conjunto, los resultados **validan la estrategia Predictiva** como alternativa superior a Greedy cuando se prioriza la precisión del mapa o cuando el tiempo de exploración disponible es suficiente. La estrategia Greedy resulta preferible únicamente cuando se requiere maximizar la exploración en ventanas de tiempo cortas y la densidad de actores es baja o nula.

4.7. Análisis comparativo de estrategias

[SCAFFOLDING — Esta sección cierra el capítulo de experimentación con una comparación directa de las tres estrategias propuestas (Vecindad, Ruta Planificada y Predictiva) entre sí y frente a la línea de base Greedy. Se estructura en cuatro bloques:]

1. Tabla unificada de resultados. Una tabla con las cuatro estrategias (Vecindad, Ruta Planificada, Predictiva, Greedy) como columnas y las 10 configuraciones (entorno $\times$ actores) como filas, para cada una de las tres métricas. Permite al lector identificar de un vistazo cuál estrategia domina en cada configuración y métrica.

2. Comparación por puntuación compuesta. Figura de barras agrupadas con la puntuación compuesta de las cuatro estrategias por configuración, y tabla de recuento de victorias (cuántas configuraciones gana cada estrategia en cada métrica y en score compuesto). Se discute si la progresión de complejidad (Vecindad $\rightarrow$ Ruta Planificada $\rightarrow$ Predictiva) se traduce en una mejora progresiva de resultados o si el trade-off con el costo computacional neutraliza parte del beneficio.

3. Trade-offs y recomendaciones de uso. Análisis de los tres trade-offs centrales del sistema:

- **Precisión vs. exploración**: Predictiva logra la mayor precisión (menores ghost cells) pero sacrifica exploración en ejecuciones cortas. Greedy maximiza exploración pero acumula ruido en el mapa con densidad alta de actores.

- **Complejidad vs. rendimiento**: el costo computacional creciente de Vecindad $\rightarrow$ Ruta Planificada $\rightarrow$ Predictiva se justifica en configuraciones con densidad media-alta de actores (≥ 10), donde la ganancia en precisión compensa la pérdida de exploración.

- **Duración del experimento**: Greedy es preferible en exploraciones cortas con pocos actores; Predictiva es preferible en exploraciones prolongadas o con muchos actores.

4. Conclusión del capítulo. Párrafo de cierre que sintetiza cuál estrategia valida mejor los objetivos del proyecto y abre la discusión hacia las conclusiones generales (Capítulo 5).

[— Completar cuando estén disponibles los análisis de Vecindad y Ruta Planificada.]

Capítulo 5

Conclusiones y Trabajo Futuro

En este capítulo se evalúan los resultados alcanzados y dificultades encontradas, se establece lo que se planteó hacer y lo que se hizo realmente, cuáles fueron los aportes, se muestran posibles extensiones al trabajo, se realiza una autocrítica de lo que se hizo y lo que faltó (por problemas de tiempo, recursos, cómo se puede continuar, qué cosas hacer, prioridades, etc.) y se incluye información sobre la gestión del proyecto, si aplica.

Referencias

Cohen, P. J. (1963). The independence of the continuum hypothesis. *Proceedings of the National Academy of Sciences*, *50*(6), 1143–1148.

Holleis, P., Wagner, M., y Koolwaaij, J. (2010). Studying mobile context-aware social services in the wild. En *Proc. of the 6th nordic conf. on human-computer interaction* (pp. 207–216). New York, NY: ACM.

NASA. (2015). *Pluto: The 'other' red planet.* https://www.nasa.gov/nh/pluto-the-other-red-planet. (Accessed: 2018-12-06)

R Core Team. (2018). R: A language and environment for statistical computing [Manual de software informático]. Vienna, Austria.

Susskind, L., y Hrabovsky, G. (2014). *Classical mechanics: the theoretical minimum.* New York, NY: Penguin Random House.

Anexo 1

Los anexos contienen información adjunta al proyecto pero que no es fundamental para entender el trabajo. Por ejemplo, determinado material de los antecedentes o la implementación, que en el cuerpo principal del informe se encuentre resumido, aquí puede presentarse de forma completa. En caso de proyectos de desarrollo de software, se debería incluir un manual de usuario.

.1. Sección del Anexo

Los anexos pueden tener secciones.